

KHOA HỆ THỐNG THÔNG TIN



CHUYÊN ĐỀ KIẾN TẬP

**XÂY DỰNG MÔ HÌNH DỰ BÁO GIÁ BẤT ĐỘNG SẢN TẠI
KHU VỰC THÀNH PHỐ HỒ CHÍ MINH**

GVHD: PGS. TS. Lê Hoàng Sử

SVTH: Vũ Lê Phương Thúy

MSSV: K234161858

LỜI CẢM ƠN

Sau thời gian tham gia kỳ kiến tập tại Công ty TNHH Phát Đạt Holdings, nhóm chúng em đã có cơ hội tiếp cận môi trường làm việc thực tế trong vai trò Data Analyst (DA), từ đó vận dụng những kiến thức lý thuyết đã học vào các tình huống xử lý và phân tích dữ liệu cụ thể. Thông qua quá trình thu thập, làm sạch, phân tích và trực quan hóa dữ liệu, chúng em đã hiểu rõ hơn về quy trình làm việc và vai trò của một DA trong môi trường doanh nghiệp thực tế. Trải nghiệm này đã giúp chúng em có cái nhìn cụ thể và thực tế hơn về kiến thức chuyên môn, đồng thời xác định rõ hơn định hướng nghề nghiệp trong lĩnh vực phân tích dữ liệu.

Chúng em xin chân thành cảm ơn quý thầy cô Khoa Hệ thống thông tin, Trường Đại học Kinh tế - Luật, ĐHQG TP.HCM đã tạo điều kiện để sinh viên được tham gia kiến tập tại doanh nghiệp, cũng như đã tổ chức các buổi seminar hướng nghiệp nhằm hỗ trợ sinh viên tiếp cận thực tế và định hướng nghề nghiệp phù hợp với năng lực bản thân. Chúng em cũng xin gửi lời cảm ơn đến thầy Lê Hoàng Sử - giảng viên hướng dẫn, đã theo sát, hỗ trợ và góp ý trong suốt quá trình thực hiện báo cáo kiến tập. Nhờ sự hỗ trợ của thầy, chúng em không chỉ củng cố kiến thức chuyên môn về phân tích dữ liệu mà còn rèn luyện được nhiều kỹ năng quan trọng như làm việc nhóm, tư duy logic và giải quyết vấn đề.

Chúng em xin chân thành cảm ơn anh Lê Nguyễn Hoàng Minh, người đã trực tiếp hướng dẫn chuyên môn cho nhóm trong suốt thời gian kiến tập tại Công ty TNHH Phát Đạt Holdings.

Do thời gian và kiến thức còn hạn chế, chúng em khó tránh khỏi những sai sót trong quá trình thực hiện báo cáo lần này. Chúng em rất mong nhận được sự chỉ dẫn, góp ý từ quý thầy cô để có thể hoàn thiện tốt hơn, đồng thời rút ra thêm nhiều kinh nghiệm cho bản thân trong quá trình học tập và làm việc sau này.

Chúng em xin chân thành cảm ơn.

Thành phố Hồ Chí Minh, ngày 06 tháng 06 năm 2026

Nhóm sinh viên

PHIẾU ĐÁNH GIÁ KẾT QUẢ KIẾN TẬP

MSSV: K234161858

Họ tên: Vũ Lê Phương Thúy

Tên Cơ quan kiến tập: Công ty TNHH Phát Đạt Holdings

Địa chỉ Cơ quan: 39 Phạm Ngọc Thạch, Phường Xuân Hòa, TP. Hồ Chí Minh.

Điện thoại Cơ quan: (028) 2226 6868

Họ tên người đại diện cơ quan: Lê Nguyễn Hoàng Minh

Chức vụ: Chief Information Officer Điện thoại: +84 902 565 657

Thời gian kiến tập tại Cơ quan: Từ ngày 10/04/2026 Đến ngày: 30/05/2026

** Đề nghị **Quý Cơ quan** đánh giá bằng cách đánh dấu **X** vào cột xếp loại các nội dung đánh giá trong bảng sau.*

Ghi chú:

Loại A: 2đ; Loại B: 1,5đ

Loại C: 1đ; Loại D: 0,5đ

Nội dung đánh giá	Xếp loại			
	A	B	C	D
1. Tinh thần kỷ luật, thái độ				
1.1 Thực hiện nội quy của cơ quan	X			
1.2 Chấp hành giờ giấc làm việc	X			
1.3 Thái độ giao tiếp với đồng nghiệp, cộng sự	X			
1.4 Ý thức bảo vệ tài sản	X			
1.5 Tích cực trong công việc	X			
2. Kỹ năng chuyên môn, nghiệp vụ				
2.1 Đáp ứng yêu cầu công việc	X			
2.2 Tinh thần học hỏi, nâng cao trình độ chuyên môn	X			
2.3 Có sáng kiến, năng động trong công việc	X			
3. Kết quả thực tập				
3.1 Có sản phẩm ứng dụng thực tế đem lại lợi ích cho Cơ quan	X			
3.2 Mức độ hoàn thành nhiệm vụ thực tập	X			

PHIẾU NHẬN XÉT CƠ QUAN KIẾN TẬP

Đề tài đã được thực hiện với phương pháp nghiên cứu tương bài bản và có chiều sâu. Nhóm sinh viên đã xây dựng được quy trình hoàn chỉnh từ thu thập dữ liệu bất động sản, làm sạch và chuẩn hóa dữ liệu, thực hiện phân tích khám phá dữ liệu, xây dựng đặc trưng, huấn luyện các mô hình học máy (LightGBM, XGBoost, CatBoost) và áp dụng kỹ thuật Ensemble để nâng cao độ chính xác dự báo. Việc sử dụng phương pháp Cross Validation và SHAP để giải thích mô hình cho thấy nhóm đã tiếp cận được các kỹ thuật hiện đại trong lĩnh vực Khoa học dữ liệu và Trí tuệ nhân tạo.

Đề tài có tính thực tiễn cao do xuất phát từ bài toán thực tế của thị trường bất động sản TP.HCM. Kết quả nghiên cứu không chỉ phục vụ mục đích học thuật mà còn có khả năng hỗ trợ các hoạt động định giá, phân tích thị trường và ra quyết định đầu tư trong doanh nghiệp bất động sản. Việc kết hợp AI/LLM vào quá trình chuẩn hóa dữ liệu cũng thể hiện khả năng tiếp cận các xu hướng công nghệ mới.

Bên cạnh những kết quả đạt được, Chúng tôi có một số ý gợi mở để có thể phát triển chuyên sâu vào thương mại hóa như:

9) Nguồn dữ liệu cần có từ giá giao dịch thực tế trên thị trường và giả giao dịch thành công cho các loại sản phẩm.

10) Yếu tố kinh tế vĩ mô như lãi suất, quy hoạch, hạ tầng giao thông hoặc biến động kinh tế - xã hội khu vực thành thị, tỉnh, nông thôn... đều có ảnh hưởng đến giá bất động sản.

11) Bổ sung các biến số như sản phẩm căn hộ, nhà phố, biệt thự, shop house, BĐS nghỉ dưỡng để nâng cao giá trị thực tiễn của kết quả.

12) Trong BĐS có rất nhiều dạng dữ liệu, ngoài dữ liệu bảng còn có dữ liệu hình ảnh, GIS, BIM, Digital Twin... nó sẽ rất có giá trị trong việc thể hiện đánh giá BĐS. Cần có thêm dashboard và cách đưa thông tin đến tay người dùng đầu cuối nơi phát sinh nhu cầu.

Nhìn chung, nhóm đã thể hiện tinh thần nghiên cứu nghiêm túc, khả năng tự học tốt và sự chủ động trong việc tiếp cận các công nghệ mới. Báo cáo được trình bày có hệ thống, logic, cho thấy sự phối hợp hiệu quả giữa các thành viên trong nhóm. Đây là một đề tài


có chất lượng tốt, vượt yêu cầu thông thường của học phần kiến tập và thể hiện tiềm năng phát triển thành nghiên cứu chuyên sâu hoặc ứng dụng thực tế trong doanh nghiệp

Đề tài có khả năng tiếp tục phát triển theo hướng xây dựng hệ thống định giá bất động sản tự động (AVM), nền tảng phân tích thị trường hoặc các giải pháp hỗ trợ đầu tư và quản trị dữ liệu bất động sản trong tương lai. Với những kết quả đã đạt được, nhóm xứng đáng được ghi nhận và khuyến khích tiếp tục nghiên cứu, hoàn thiện sản phẩm ở mức độ cao hơn.

TP.HCM, ngày 01 tháng 06 năm 2026

XÁC NHẬN CỦA CƠ QUAN

Ký, ghi rõ họ tên, đóng dấu



Lê Nguyễn Hoàng Minh

PHIẾU ĐÁNH GIÁ BÁO CÁO KIẾN TẬP CỦA GIẢNG VIÊN HƯỚNG DẪN

MSSV: K234161858

Họ tên: Vũ Lê Phương Thúy

Lớp: K23416

Ngành/Chuyên ngành: Kinh doanh số và Trí tuệ nhân tạo

Tên đề tài: Xây dựng mô hình dự báo giá bất động sản tại khu vực Thành phố Hồ Chí Minh

GVHD: PGS. TS. Lê Hoàng Sử

STT	Tiêu chí cụ thể	Tỉ lệ	Điểm đã nhân tỉ lệ
1	Tuân thủ quy định học phần, đúng tiến độ, đầy đủ xác nhận của đơn vị/leader, tinh thần học tập nghiêm túc	10%	
2	Tìm hiểu doanh nghiệp, môi trường làm việc, vị trí nghề nghiệp, xác định định hướng chuyên sâu rõ ràng	10%	
3	Mô tả bối cảnh thực tế, xác định vấn đề/tình huống rõ ràng, có logic và phù hợp với định hướng nghề nghiệp	15%	
4	Vận dụng kiến thức chuyên ngành, kiến thức kinh doanh quản lý, công nghệ, để phân tích vấn đề	20%	
5	Thu thập dữ liệu, xử lý dữ liệu, phân tích, diễn giải kết quả, sử dụng bảng biểu/hình minh họa phù hợp	15%	
6	Đề xuất giải pháp phù hợp, có tính ứng dụng, khả thi trong bối cảnh thực tế	15%	
7	Bố cục logic, trình bày khoa học, ngôn ngữ học thuật, trích dẫn tài liệu, hình thức đúng quy định	15%	
Tổng điểm:			

....., ngày.....tháng.....năm.....

Giảng viên hướng dẫn

Ký, ghi rõ họ tên

PHIẾU NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

....., ngày.....tháng.....năm.....

Giảng viên hướng dẫn

Ký, ghi rõ họ tên

NHẬT KÝ KIẾN TẬP

STT	TUẦN	THỜI GIAN	NỘI DUNG CÔNG VIỆC
1	Tuần 1	08/03/2026 - 14/03/2026	Bắt đầu thực hiện Phần 01 của đồ án. Tìm hiểu tổng quan về ngành Data Analyst (DA): vai trò, trách nhiệm trong doanh nghiệp.
2	Tuần 2	15/03/2026 - 21/03/2026	Phân tích vai trò của DA ở từng lĩnh vực khác nhau. Nghiên cứu bối cảnh và tình hình của nghề trong và ngoài nước. Tổng hợp các xu hướng mới của ngành. Tham dự Seminar do Khoa tổ chức và thực hiện viết bài thu hoạch.
3	Tuần 3	22/03/2026 - 28/03/2026	Xây dựng lộ trình thăng tiến và định hướng phát triển nghề nghiệp DA. Viết và nộp bài thu hoạch Seminar.
4	Tuần 4	29/03/2026 - 05/03/2026	Rà soát, hoàn thiện nội dung cho Phần 01 của đồ án.
5	Tuần 5	06/03/2026 - 12/04/2026	Tiếp nhận yêu cầu và bài toán thực tế từ doanh nghiệp, nghiên cứu phạm vi dữ liệu cần thu thập và xây dựng cấu trúc dữ liệu cho hai cấp độ dự án và tin đăng bất động sản. Thực hiện thu thập dữ liệu dự án từ Batdongsan, đồng thời kiểm tra, đối chiếu và bổ sung các trường thông tin còn thiếu nhằm nâng cao chất lượng bộ dữ liệu phục vụ các bước phân tích tiếp theo.
6	Tuần 6 +7	13/04/2026 - 26/04/2026	Tiếp tục hoàn thiện và chuẩn hóa bộ dữ liệu cấp dự án, đồng thời triển khai thu thập dữ liệu tin đăng bất

			động sản từ Batdongsan.vn. Thực hiện thu thập dữ liệu các tiện ích xung quanh tại khu vực TP. Hồ Chí Minh để phục vụ xây dựng các biến đặc trưng về vị trí. Song song đó, nghiên cứu khả năng ứng dụng AI trong việc tự động bổ sung dữ liệu thiếu và tìm hiểu các hướng tiếp cận phổ biến trong xây dựng mô hình dự báo giá bất động sản.
7	Tuần 8	27/04/2026 - 03/05/2026	Thu thập tin đăng từ các nguồn hỗ trợ (Homedy, Nhadatcanban) và thực hiện ghép nối với dữ liệu dự án để xây dựng bộ dữ liệu tổng hợp. Tiến hành chuẩn hóa định dạng dữ liệu, xử lý các trường thông tin không đồng nhất và ứng dụng AI để bổ sung các thuộc tính định tính còn thiếu, từng bước hoàn thiện bộ dữ liệu phục vụ xây dựng mô hình.
8	Tuần 9 + 10	04/05/2026 - 17/05/2026	Thực hiện làm sạch và tiền xử lý dữ liệu, bao gồm xử lý giá trị thiếu, loại bỏ dữ liệu bất thường và chuẩn hóa các biến đầu vào. Tiến hành phân tích khám phá dữ liệu (EDA), xây dựng các biến đặc trưng và triển khai các mô hình dự báo giá bất động sản để đánh giá kết quả ban đầu.
9	Tuần 11	18/05/2026 - 24/05/2026	Hoàn thiện việc xây dựng và đánh giá các mô hình dự báo giá bất động sản, phân tích kết quả và lựa chọn mô hình tối ưu. Đồng thời bắt đầu viết báo cáo cho Phần 02 của đề án.

10	Tuần 12	25/05/2026 - 31/05/2026	Tiếp tục cải thiện hiệu quả các mô hình dự báo thông qua điều chỉnh tham số và đánh giá kết quả trên các tập dữ liệu kiểm thử. Tổng hợp, chuẩn hóa và kiểm tra lại mã nguồn, dữ liệu sử dụng trong bài.
11	Tuần 13	01/06/2026 - 07/06/2026	Viết Phần 03 (phần cá nhân) và hoàn thiện toàn bộ báo cáo. Rà soát toàn bộ nội dung dự án, chỉnh sửa các phần còn thiếu theo yêu cầu.

BẢNG PHÂN CÔNG CÔNG VIỆC CHI TIẾT

CÔNG VIỆC	THỜI GIAN	NGƯỜI THỰC HIỆN
PCCV THỰC HIỆN ĐỒ ÁN		
GIAI ĐOẠN 1: XÂY DỰNG DỮ LIỆU CẤP DỰ ÁN		
Xây dựng schema dữ liệu	10/04 - 14/04	Khoa
		Thảo
		Thư
Crawl dữ liệu dự án từ Batdongsan		Thảo
Kiểm định và chỉnh sửa dữ liệu dự án		Tất cả
GIAI ĐOẠN 2: MỞ RỘNG DỮ LIỆU VÀ NGHIÊN CỨU TÀI LIỆU		
Hoàn thiện dữ liệu cấp dự án	15/04 - 06/05	Thảo
Crawl tin đăng từ Batdongsan		Khoa
Thu thập dữ liệu POI tại TP.HCM		Thảo
Xây dựng Pivot Table		Thư
Nghiên cứu tổng quan tài liệu		Thúy
		Vy
GIAI ĐOẠN 3: HOÀN THIỆN BỘ DỮ LIỆU		
Crawl tin đăng từ Homedy	07/05 - 12/05	Thảo
Crawl tin đăng từ Nhadatcanban		Khoa

Nghiên cứu và ứng dụng AI để xử lý dữ liệu	13/05 - 17/05	Thư
Nghiên cứu hướng xây dựng mô hình		Thúy
Ghép nối và hoàn thiện bộ dữ liệu tổng hợp		Tất cả
GIAI ĐOẠN 4: TIỀN XỬ LÝ DỮ LIỆU		
Làm sạch và chuẩn hóa dữ liệu	13/05 - 15/05	Thư
Phân tích khám phá dữ liệu (EDA)	16/05 - 20/05	Thúy
Tiền xử lý dữ liệu		Vy
Hoàn thiện pipeline thu thập dữ liệu	18/05 - 22/05	Khoa
		Thảo
GIAI ĐOẠN 5: XÂY DỰNG VÀ TỐI ƯU MÔ HÌNH		
Xây dựng đặc trưng	21/05 - 24/05	Tất cả
Xây dựng mô hình		
Tối ưu mô hình		
Đánh giá mô hình		
Feature Importance và SHAP	25/05	Thúy

GIAI ĐOẠN 6: HOÀN THIỆN BÀI LÀM		
Tổng hợp mã nguồn	24/05 - 30/05	Tất cả
Tổng hợp Word	31/05 - 07/06	Tất cả
PCCV VIẾT BÁO CÁO		
PHẦN 1: TÌM HIỂU HƯỚNG NGHỀ NGHIỆP		
Chương 1: Tổng quan về Data Analyst	08/03 - 21/03	Thảo
		Thư
Chương 2: Bức tranh thị trường Data Analyst		Khoa
Chương 3: Lộ trình nghề nghiệp và định hướng chung		Khoa
Chương 1 + Chương 6 (Báo cáo lần 1)		Thúy
PHẦN 2: NGHIÊN CỨU VÀ XÂY DỰNG MÔ HÌNH DỰ BÁO		
Chương 1: Giới thiệu đề tài		
1.1 Giới thiệu đơn vị kiến tập	18/05 - 20/05	Khoa
1.2 Bối cảnh nghiên cứu		Vy
		Thư
		Thảo
1.3 Mục tiêu nghiên cứu		Khoa

1.4 Đối tượng và phạm vi nghiên cứu		Thúy
1.5 Phương pháp nghiên cứu		Thảo
1.6 Cấu trúc bài nghiên cứu		
Chương 2: Cơ sở lý thuyết		
2.1 Mô hình dự báo	20/05 - 21/05	Thúy
2.2 Kỹ thuật xử lý dữ liệu		Thư
2.3 Kỹ thuật kết hợp mô hình		Vy
2.4 Chỉ số đánh giá mô hình		Thảo
2.5 Kỹ thuật giải thích mô hình		Khoa
Chương 3: Thu thập dữ liệu		
3.1 Nguồn dữ liệu	22/05 - 24/05	Thảo
3.2 Quy trình thu thập dữ liệu		Khoa
		Thảo
3.3 Kết quả thu thập		Khoa
Chương 4: Khám phá và tiền xử lý dữ liệu		
4.1 Quy trình xử lý dữ liệu	22/05 - 24/05	Vy
4.2 Tiền xử lý dữ liệu		Thư
4.3 Khám phá dữ liệu (EDA)		Vy
		Thúy

4.4 Tiền xử lý sau phân tích và Feature Engineering		Vy
4.5 Kết quả xử lý		Vy
Chương 5: Xây dựng và đánh giá mô hình		
5.1 Xây dựng mô hình	25/05 - 27/05	Thúy
5.2 Tối ưu mô hình		
5.3 Đánh giá mô hình		
5.4 Feature Importance và SHAP Analysis		
Chương 6: Kết luận		
6.1 Kết luận chính của nghiên cứu	25/05 - 27/05	Thảo
6.2 Trả lời các câu hỏi nghiên cứu		Thư
		Thúy
6.3 Hạn chế của nghiên cứu		Vy
6.4 Hướng nghiên cứu tiếp theo		Khoa
PHẦN 3: BÁO CÁO CÁ NHÂN	28/05 - 07/06	Tất cả

MỤC LỤC

LỜI CẢM ƠN	i
PHIẾU ĐÁNH GIÁ KẾT QUẢ KIẾN TẬP	ii
PHIẾU NHẬN XÉT CƠ QUAN KIẾN TẬP	iii
PHIẾU ĐÁNH GIÁ BÁO CÁO KIẾN TẬP CỦA GIẢNG VIÊN HƯỚNG DẪN.v	
PHIẾU NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN	vi
NHẬT KÝ KIẾN TẬP	vii
BẢNG PHÂN CÔNG CÔNG VIỆC CHI TIẾT	x
DANH MỤC BẢNG BIỂU	xxii
DANH MỤC HÌNH ẢNH	xxiii
DANH MỤC VIẾT TẮT	xxv
PHẦN 1: TÌM HIỂU VỀ HƯỚNG NGHIỆP.....	1
1.1 Định nghĩa chung	1
1.1.1 Định nghĩa về ngành Data Analytics	1
1.1.2 Định nghĩa về Data Analyst.....	1
1.2 Vai trò và nhiệm vụ của Data Analyst	2
1.2.1 Vai trò của Data Analyst.....	2
1.2.2 Nhiệm vụ của Data Analyst.....	2
1.3 Những kiến thức và kỹ năng cần có.....	4
1.3.1 Kỹ năng kỹ thuật và công cụ	4
1.3.2 Kiến thức toán học và thống kê	6
1.3.3 Kỹ năng phân tích và tư duy (Soft Skills)	6
1.3.4 Đạo đức dữ liệu và xu hướng công nghệ.....	7
1.4 Bằng cấp và các chứng chỉ liên quan	7

1.4.1 Bảng cấp học thuật.....	7
1.4.2 Chứng chỉ.....	8
1.5 Vị trí Data Analyst trong các lĩnh vực khác nhau.....	11
1.6 Phân biệt Data Analyst với các vai trò liên quan.....	14
CHƯƠNG 2: BỨC TRANH THỊ TRƯỜNG DATA ANALYST	17
2.1 Thị trường quốc tế.....	17
2.1.1 Sự bùng nổ về quy mô	17
2.1.2 Xu hướng chuyển dịch trong tương lai.....	17
2.1.3 Cơ hội việc làm tại thị trường quốc tế	18
2.2 Thị trường Việt Nam.....	19
2.2.1 Tình hình chuyển đổi số tại Việt Nam.....	19
2.2.2 Nhận thức và mức độ ứng dụng phân tích dữ liệu trong doanh nghiệp	19
2.2.3 Tương lai ngành phân tích dữ liệu.....	20
2.2.4 Cơ hội làm việc của DA tại Việt Nam.....	20
CHƯƠNG 3: LỘ TRÌNH NGHỀ NGHIỆP VÀ ĐỊNH HƯỚNG CHUNG	22
3.1 Lộ trình thăng tiến.....	22
3.2 Định hướng	25
PHẦN 2: NGHIÊN CỨU VÀ XÂY DỰNG MÔ HÌNH DỰ BÁO	28
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI.....	28
1.1 Giới thiệu đơn vị kiến tập	28
1.1.1 Tổng quan về doanh nghiệp.....	28
1.1.2 Vai trò và nội dung kiến tập	28
1.2 Bối cảnh nghiên cứu.....	29

1.2.1 Tổng quan thị trường bất động sản TPHCM	29
1.2.2 Tổng quan nghiên cứu trước đó.....	30
1.2.3 Khoảng trống nghiên cứu	33
1.3 Mục tiêu nghiên cứu.....	34
1.3.1 Mục tiêu tổng quát	34
1.3.2 Mục tiêu cụ thể	34
1.3.3 Câu hỏi nghiên cứu	35
1.4 Đối tượng và phạm vi nghiên cứu.....	36
1.4.1 Đối tượng nghiên cứu	36
1.4.2 Phạm vi	36
1.5 Phương pháp nghiên cứu.....	37
1.6 Cấu trúc bài nghiên cứu	37
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	39
2.1 Mô hình dự báo	39
2.1.1 LightGBM.....	39
2.1.2 XGBoost	40
2.1.3 CatBoost	40
2.2 Kỹ thuật xử lý dữ liệu	41
2.2.1 Xử lý dữ liệu thiếu	41
2.2.2 Mã hóa biến phân loại.....	43
2.2.3 Xây dựng đặc trưng	44
2.3 Kỹ thuật kết hợp mô hình.....	46
2.3.1 Khái niệm và nguyên lý	46

2.3.2 Các phương pháp ensemble phổ biến	47
2.4 Chỉ số đánh giá.....	48
2.4.1 MAE	48
2.4.2 MedAE.....	48
2.4.3 RMSE	49
2.4.4 R^2	49
2.4.5 MdAPE	49
2.5 Kỹ thuật giải thích mô hình.....	50
CHƯƠNG 3: THU THẬP DỮ LIỆU	53
3.1 Nguồn dữ liệu.....	53
3.2 Quy trình thu thập dữ liệu	53
3.2.1 Thu thập dữ liệu cấp dự án	53
3.2.2 Thu thập dữ liệu cấp tin đăng	59
3.2.3 Gộp dữ liệu	66
3.3 Kết quả thu thập	68
CHƯƠNG 4: KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU	70
4.1 Quy trình xử lý dữ liệu.....	70
4.2 Tiền xử lý dữ liệu	71
4.2.1 Kiểm tra cấu trúc dữ liệu	71
4.2.2 Chuẩn hóa định dạng dữ liệu	71
4.2.3 Chuyển đổi kiểu dữ liệu.....	72
4.2.4 Xử lý dữ liệu trùng lặp.....	72
4.2.5 Xử lý dữ liệu ngoại lai	73

4.2.6 Chuẩn hóa danh mục bằng quy tắc kết hợp Trí tuệ nhân tạo (AI Fill)	73
4.3 Khám phá dữ liệu	75
4.3.1 Thống kê mô tả dữ liệu	75
4.3.2 Phân tích phân phối dữ liệu	79
4.3.3 Phân tích tương quan dữ liệu	83
4.3.4 Phân tích dữ liệu thiếu	85
4.3.5 Phân tích ngoại lệ.....	87
4.3.6 Phân tích phân bố dữ liệu mục tiêu	88
4.4 Tiền xử lý dữ liệu sau phân tích.....	89
4.4.1 Lọc ngoại lệ nâng cao	89
4.4.2 Phân chia tập huấn luyện và tập kiểm tra	90
4.4.3 Xử lý dữ liệu thiếu theo nhóm	90
4.4.4 Xây dựng đặc trưng mới (Feature Engineering).....	92
4.4.5 Log Transformation	94
4.4.6 K-Fold Target Encoding	95
4.4.7 One-hot Encoding	96
4.5 Kết quả xử lý	97
CHƯƠNG 5: XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH.....	98
5.1 Xây dựng mô hình.....	98
5.1.1 Lựa chọn lớp mô hình.....	98
5.1.2 Chiến lược đánh giá: K-Fold Cross Validation	98
5.1.3 Thiết lập siêu tham số	99
5.2 Tối ưu mô hình.....	100

5.2.1 Các cải tiến từ phiên bản v1 sang v2	100
5.2.2 Chiến lược early stopping và xác định số cây tối ưu.....	101
5.2.3 Ensemble weighted theo kết quả cross-validation.....	102
5.3 Đánh giá mô hình.....	102
5.3.1 Kết quả Cross-Validation	102
5.3.2 Kết quả trên tập kiểm tra (Test Set).....	103
5.3.3 Kiểm tra overfit: Cross-Validation vs Test.....	104
5.3.4 Phân tích hiệu suất theo phân khúc giá.....	104
5.3.5 Phân tích phần dư và căn dự báo sai nhiều nhất.....	105
5.4 Feature Importance	106
5.4.1 Global Feature Importance	107
5.4.2 SHAP Summary Interpretation.....	108
5.4.3 SHAP Dependence Plot Analysis.....	110
5.4.4 Phân tích các trường hợp đặc biệt bằng SHAP Waterfall Plot.....	115
CHƯƠNG 6: KẾT LUẬN.....	121
6.1 Kết luận chính của nghiên cứu.....	121
6.2 Trả lời các câu hỏi nghiên cứu.....	121
6.3 Hạn chế của nghiên cứu	127
6.4 Hướng nghiên cứu tiếp theo.....	128
PHẦN 3: QUÁ TRÌNH NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH DỰ BÁO GIÁ BẤT ĐỘNG SẢN	129
CHƯƠNG 1: VAI TRÒ CÁ NHÂN TRONG DỰ ÁN	129
CHƯƠNG 2: QUÁ TRÌNH NGHIÊN CỨU TÀI LIỆU	130

2.1 Nghiên cứu các mô hình định giá bất động sản	130
2.2 Nghiên cứu các biến tương tác.....	132
2.3 Nghiên cứu về phương pháp Target Encoding cho các biến phân loại có số lượng giá trị lớn	133
CHƯƠNG 3: QUÁ TRÌNH CẢI TIẾN MÔ HÌNH.....	135
3.1 Khám phá dữ liệu và xác định hướng tiền xử lý	135
3.2 Phát hiện tầm quan trọng đặc biệt của project_name	135
3.3 Loại bỏ đặc trưng gây nhiễu.....	135
3.4 Bổ sung các biến tương tác sau khi tham khảo tài liệu nghiên cứu	136
CHƯƠNG 4: ĐỊNH HƯỚNG PHÁT TRIỂN ĐỀ TÀI.....	137
CHƯƠNG 5: KIẾN THỨC, KINH NGHIỆM TÍCH LŨY ĐƯỢC.....	138
CHƯƠNG 6: ĐỊNH HƯỚNG NGHỀ NGHIỆP CÁ NHÂN	140
TÀI LIỆU THAM KHẢO.....	142

DANH MỤC BẢNG BIỂU

Bảng A.1.1: Bảng so sánh Data Analyst và các vai trò liên quan	14
Bảng A.3.1: Lộ trình thăng tiến theo nghề Data Analyst	22
Bảng A.3.2: Kế hoạch phát triển nghề nghiệp.....	26
Bảng B.1.1: Các câu hỏi nghiên cứu	35
Bảng B.3.1: Ánh xạ nhãn HTML sang trường dữ liệu	56
Bảng B.3.2: Các biến nhị phân tiện ích và từ khóa nhận dạng.....	56
Bảng B.3.3: Schema bộ dữ liệu cấp dự án.....	57
Bảng B.3.4: Kiến trúc của hệ thống thu thập dữ liệu cấp tin đăng.....	59
Bảng B.3.5: Ba giai đoạn xử lý trong pipeline thu thập dữ liệu cấp tin đăng	60
Bảng B.3.6: Kết quả từng ngưỡng trùng lặp khi áp dụng fuzzy matching.....	64
Bảng B.3.7: Phân bố số tin đăng theo từng nguồn	68
Bảng B.4.1: Thống kê outlier theo phương pháp IQR	87
Bảng B.4.2: Thống kê outlier theo phương pháp Z-score	87
Bảng B.4.3: Chiến lược xử lý dữ liệu thiếu theo nhóm.....	90
Bảng B.4.4: Các biến tương tác được tạo từ các biến trước target encoding	93
Bảng B.4.5: Các biến tương tác được tạo từ các biến sau target encoding	95
Bảng B.5.1: Siêu tham số của ba mô hình LightGBM, XGBoost và CatBoost	99
Bảng B.5.2: Các cải tiến từ phiên bản v1 sang v2.....	100
Bảng B.5.3: Kết quả cross-validation trên tập huấn luyện và trọng số ensemble	102
Bảng B.5.4: Kết quả đánh giá trên tập kiểm tra (test set).....	103
Bảng B.5.5: So sánh R2 cross-validation (CV) và R2 Test để kiểm tra overfit.....	104
Bảng B.5.6: Hiệu suất Ensemble theo phân khúc giá trên tập kiểm tra	105

DANH MỤC HÌNH ẢNH

Hình A.1.1: Các chứng chỉ Data Analytics được doanh nghiệp đánh giá cao (Nguồn: Franklin University)	9
Hình A.3.1: Mức lương trung vị của các ngành IT 2025-2026 (Nguồn: ITviec).....	25
Hình B.2.1: Ví dụ về One-hot Encoding (Nguồn: Datacamp)	44
Hình B.3.1. Tổng quan quy trình thu thập và xử lý dữ liệu cấp dự án.....	53
Hình B.4.1: Thống kê số lượng và mức độ đa dạng của các thuộc tính trong bộ dữ liệu	77
Hình B.4.2: Thống kê mô tả các biến định lượng	77
Hình B.4.3: Biểu đồ phân phối giá trước và sau khi biến đổi log	80
Hình B.4.4: Biểu đồ phân phối giá/m ² trước và sau khi biến đổi log.....	80
Hình B.4.5: Biểu đồ phân phối của các biến thông số căn hộ và dự án	81
Hình B.4.6: Biểu đồ phân phối của các biến thời gian.....	81
Hình B.4.7: Biểu đồ phân phối của các biến khoảng cách.....	82
Hình B.4.8: Phân bố 2 lớp giữa các biến nhị phân tiện ích nội khu.....	82
Hình B.4.9: Phân bố tần suất các giá trị của các biến phân loại.....	83
Hình B.4.10: Ma trận tương quan của các thuộc tính số với biến mục tiêu.....	84
Hình B.4.11: Thống kê missing value theo feature	86
Hình B.4.12: Phân bố diện tích theo giá trên mỗi mét vuông và tổng giá trị căn hộ ...	88
Hình B.5.1: Global Feature Importance dựa trên mean(SHAP value)	107
Hình B.5.2: SHAP Summary Beeswarm Plot	109
Hình B.5.3: Biểu đồ SHAP Dependence của biến project_name_te.....	111
Hình B.5.4: Biểu đồ SHAP Dependence của biến listing_age_days	112
Hình B.5.5: Biểu đồ SHAP Dependence của biến ward_te_x_area.....	113
Hình B.5.6: Biểu đồ SHAP Dependence của biến posted_year	114
Hình B.5.7: SHAP Waterfall Plot cho trường hợp dự báo chính xác nhất của mô hình Ensemble	116
Hình B.5.8: SHAP Waterfall Plot cho trường hợp dự báo sai lớn nhất của mô hình	

Ensemble	117
Hình B.5.9: SHAP Waterfall Plot cho trường hợp dự báo mức trung bình của mô hình Ensemble	119
Hình B.6.1: Tỷ lệ đóng góp của Rule-based và LLM trong quá trình xử lý dữ liệu..	124
Hình B.6.2: Mức độ giảm phân mảnh dữ liệu trước và sau chuẩn hóa	125

DANH MỤC VIẾT TẮT

Từ viết tắt	Diễn giải
AI	Artificial Intelligence (Trí tuệ nhân tạo)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
AVM	Automated Valuation Model (Mô hình định giá tự động)
CBD	Central Business District (Khu trung tâm thương mại)
CSV	Comma-Separated Values (Định dạng dữ liệu phân tách bằng dấu phẩy)
CV	Cross-Validation (Kiểm định chéo)
DID	Difference-in-Differences (Khác biệt trong khác biệt)
EDA	Exploratory Data Analysis (Phân tích khám phá dữ liệu)
EFB	Exclusive Feature Bundling (Gộp đặc trưng loại trừ)
GBDT	Gradient Boosting Decision Trees (Cây quyết định tăng cường độ dốc)
GBRT	Gradient Boosted Regression Trees (Cây hồi quy tăng cường độ dốc)
GOSS	Gradient-based One-Side Sampling (Lấy mẫu một chiều dựa trên độ dốc)
GPS	Global Positioning System (Hệ thống định vị toàn cầu)
GRDP	Gross Regional Domestic Product (Tổng sản phẩm trên địa bàn)

HTML	HyperText Markup Language (Ngôn ngữ đánh dấu siêu văn bản)
HTTP	HyperText Transfer Protocol (Giao thức truyền siêu văn bản)
IQR	Interquartile Range (Khoảng tứ phân vị)
JSON	JavaScript Object Notation (Định dạng dữ liệu JavaScript)
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
LSA	Latent Semantic Analysis (Phân tích ngữ nghĩa tiềm ẩn)
MAE	Mean Absolute Error (Sai số tuyệt đối trung bình)
MAR	Missing At Random (Dữ liệu thiếu ngẫu nhiên)
MCAR	Missing Completely At Random (Dữ liệu thiếu hoàn toàn ngẫu nhiên)
MdAPE	Median Absolute Percentage Error (Trung vị sai số phần trăm tuyệt đối)
MNAR	Missing Not At Random (Dữ liệu thiếu không ngẫu nhiên)
MSE	Mean Squared Error (Sai số bình phương trung bình)
R^2	Coefficient of Determination (Hệ số xác định)
RMSE	Root Mean Squared Error (Căn bậc hai sai số bình phương trung bình)
SHAP	SHapley Additive exPlanations (Giải thích cộng gộp theo Shapley)
TP.HCM	Thành phố Hồ Chí Minh

URL	Uniform Resource Locator (Địa chỉ tài nguyên thống nhất)
VNĐ	Việt Nam Đồng
YAML	YAML Ain't Markup Language (Định dạng dữ liệu cấu hình)

PHẦN 1: TÌM HIỂU VỀ HƯỚNG NGHỀ NGHIỆP

Trong bối cảnh chuyển đổi số diễn ra mạnh mẽ và dữ liệu ngày càng trở thành tài nguyên chiến lược của nền kinh tế, nhu cầu nhân lực trong lĩnh vực phân tích dữ liệu đang tăng trưởng nhanh chóng trên toàn cầu cũng như tại Việt Nam. Phần 1 của bài báo cáo tập trung tìm hiểu về nghề Data Analyst, bao gồm vai trò, nhiệm vụ, kỹ năng, chứng chỉ, bức tranh thị trường lao động, cũng như lộ trình thăng tiến và định hướng nghề nghiệp

CHƯƠNG 1: TỔNG QUAN VỀ DATA ANALYST

1.1 Định nghĩa chung

1.1.1 Định nghĩa về ngành Data Analytics

Data Analytics (Phân tích dữ liệu) là một lĩnh vực liên ngành, bao gồm các quy trình và kỹ thuật nhằm thu thập, xử lý, phân tích và diễn giải dữ liệu để rút ra thông tin hữu ích, hỗ trợ ra quyết định và tối ưu hiệu quả hoạt động. Theo Harvard Business School, Data Analytics là quá trình phân tích dữ liệu để trả lời các câu hỏi cụ thể, khai thác insight và xác định xu hướng trong tổ chức. Theo Korkontzelos (2014), trình bày trong chương "Mining Big Textual Data" thuộc ấn phẩm Big Data, Mining, and Analytics, phân tích dữ liệu là quá trình vận dụng các kỹ thuật khai phá dữ liệu để trích xuất tri thức từ các tập dữ liệu lớn, đặc biệt là các dữ liệu văn bản phi cấu trúc. Theo Eurostat, Data Analytics liên quan đến việc sử dụng công nghệ và công cụ phân tích để phát hiện các mẫu và thông tin chuyên sâu, từ đó cải thiện hiệu suất như tăng năng suất hoặc giảm chi phí. Đồng thời, HubSpot Guide định nghĩa đây là quá trình chuyển đổi dữ liệu thô thành các chỉ số có ý nghĩa, giúp doanh nghiệp đưa ra các quyết định chiến lược một cách chính xác và hiệu quả. Từ các quan điểm trên, có thể khái quát rằng Data Analytics chính là quá trình biến dữ liệu thô thành tri thức có giá trị phục vụ cho việc hiểu, dự đoán và ra quyết định.

1.1.2 Định nghĩa về Data Analyst

Data Analyst, hay chuyên viên phân tích dữ liệu, là một mắt xích quan trọng và không thể thiếu trong hệ sinh thái dữ liệu của doanh nghiệp. Về định nghĩa, từ điển Cambridge, họ là những người thực hiện công việc kiểm tra, xem xét thông tin nhằm tìm kiếm insight hoặc để hỗ trợ việc đưa ra các quyết định. Hay theo trang Coursera Career Guide, Data Analyst được hiểu là là những người phụ trách việc thu thập, làm

sạch và diễn giải các tập dữ liệu nhằm trả lời các câu hỏi hoặc giải quyết vấn đề. Họ có thể hoạt động đa lĩnh vực bao gồm kinh doanh, tài chính, tư pháp hình sự, khoa học, y tế và chính phủ.

1.2 Vai trò và nhiệm vụ của Data Analyst

1.2.1 Vai trò của Data Analyst

- *Cầu nối giữa phòng kỹ thuật và phòng kinh doanh:* Data Analyst đóng vai trò trung gian quan trọng giữa bộ phận kỹ thuật (IT, Data Engineering, Data Science) và bộ phận kinh doanh (Marketing, Sales, Finance...). Trong khi các bộ phận kỹ thuật tập trung vào việc xây dựng hệ thống và xử lý dữ liệu, thì các bộ phận kinh doanh lại quan tâm đến kết quả và giá trị thực tiễn. Data Analyst giúp “dịch” các dữ liệu phức tạp và kết quả phân tích thành ngôn ngữ dễ hiểu, gắn liền với mục tiêu kinh doanh cụ thể. Nhờ đó, doanh nghiệp có thể áp dụng các insight vào thực tế như tối ưu chiến dịch marketing, cải thiện trải nghiệm khách hàng hoặc nâng cao hiệu quả vận hành.
- *Hỗ trợ ra quyết định dựa trên dữ liệu:* Thông qua việc phân tích dữ liệu lịch sử và dữ liệu hiện tại, họ cung cấp các bằng chứng rõ ràng để hỗ trợ nhà quản lý trong việc lựa chọn chiến lược phù hợp. Điều này giúp giảm thiểu rủi ro, hạn chế sai sót và tối ưu hóa việc sử dụng nguồn lực. Ví dụ, thay vì dự đoán nhu cầu sản phẩm theo kinh nghiệm, doanh nghiệp có thể dựa vào dữ liệu bán hàng để đưa ra kế hoạch sản xuất chính xác hơn.
- *Người kể chuyện bằng dữ liệu (Data telling):* Thay vì chỉ đưa ra các con số khô khan, Data Analyst trực quan hóa dữ liệu dưới dạng biểu đồ, dashboard hoặc báo cáo dễ hiểu, giúp mọi người nhanh chóng nắm được xu hướng và thông tin quan trọng.

1.2.2 Nhiệm vụ của Data Analyst

Về nhiệm vụ, Data Analyst đảm nhận vai trò xuyên suốt dòng đời dữ liệu.

- *Thu thập và tổng hợp dữ liệu:* Đây là bước khởi đầu quan trọng trong toàn bộ quy trình phân tích dữ liệu. Data Analyst cần thu thập dữ liệu từ nhiều nguồn khác nhau như cơ sở dữ liệu nội bộ (databases), bảng tính (Excel, Google Sheets), mạng xã hội, website, API hoặc thậm chí từ các thiết bị IoT và cảm biến. Việc tổng hợp dữ liệu không chỉ dừng lại ở việc “lấy dữ liệu” mà còn bao gồm việc

hiểu rõ cấu trúc, định dạng và ý nghĩa của từng nguồn dữ liệu. Điều này giúp đảm bảo dữ liệu được thu thập phù hợp với mục tiêu phân tích và có thể sử dụng hiệu quả trong các bước tiếp theo.

- *Làm sạch và xử lý dữ liệu (Data Cleaning/Wrangling)*: Đây là một trong những công đoạn tốn nhiều thời gian và công sức nhất, nhưng lại đóng vai trò cực kỳ quan trọng trong việc đảm bảo chất lượng phân tích. Data Analyst cần xử lý các vấn đề như dữ liệu bị thiếu (missing values), dữ liệu trùng lặp (duplicates), dữ liệu không nhất quán hoặc sai định dạng. Ngoài ra, việc phát hiện và xử lý các giá trị ngoại lai (outliers) cũng rất cần thiết để tránh làm sai lệch kết quả phân tích. Trong bước này, dữ liệu được chuẩn hóa, biến đổi và tái cấu trúc để phù hợp với các phương pháp phân tích.
- *Phân tích dữ liệu*: Sau khi dữ liệu đã được xử lý, Data Analyst sẽ tiến hành phân tích để tìm ra các insight có giá trị. Quá trình này có thể bao gồm việc sử dụng các phương pháp thống kê mô tả (descriptive statistics), phân tích suy luận (inferential statistics), hồi quy (regression analysis), hoặc các kỹ thuật khai phá dữ liệu (data mining). Mục tiêu là trả lời các câu hỏi quan trọng như: “Điều gì đã xảy ra?”, “Tại sao lại xảy ra?” và “Yếu tố nào ảnh hưởng đến kết quả?”. Tùy vào mục tiêu kinh doanh, các phân tích này có thể giúp doanh nghiệp hiểu rõ hơn về hiệu suất hoạt động, hành vi khách hàng hoặc xu hướng thị trường.
- *Trực quan hóa dữ liệu*: Sau khi phân tích, việc trình bày dữ liệu một cách trực quan là rất quan trọng để giúp người không chuyên cũng có thể hiểu được. Data Analyst sử dụng các công cụ như Power BI, Tableau hoặc Excel để xây dựng biểu đồ, dashboard và các báo cáo trực quan. Việc lựa chọn loại biểu đồ phù hợp (bar chart, line chart, pie chart, v.v.) giúp làm nổi bật các xu hướng, mô hình và bất thường trong dữ liệu.
- *Báo cáo và đề xuất*: Dựa trên kết quả phân tích, Data Analyst cần tổng hợp và trình bày các phát hiện dưới dạng báo cáo định kỳ hoặc theo yêu cầu (hàng tháng, quý hoặc theo dự án). Báo cáo không chỉ dừng lại ở việc trình bày dữ liệu mà còn cần diễn giải ý nghĩa của các con số, chỉ ra các vấn đề tiềm ẩn và đưa ra các đề xuất cụ thể, có tính khả thi. Ví dụ, từ dữ liệu hành vi khách hàng, Analyst có

thể đề xuất chiến lược marketing phù hợp hoặc cải thiện trải nghiệm người dùng. Đây là bước giúp biến dữ liệu thành giá trị thực tiễn cho doanh nghiệp.

- *Duy trì và cải thiện hệ thống dữ liệu*: Ngoài việc phân tích, Data Analyst còn có vai trò hỗ trợ xây dựng và tối ưu hệ thống dữ liệu. Điều này bao gồm việc thiết kế quy trình thu thập và xử lý dữ liệu, đảm bảo dữ liệu luôn được cập nhật chính xác và nhất quán. Họ cũng có thể phối hợp với Data Engineer để cải thiện pipeline dữ liệu, tối ưu hiệu suất truy vấn hoặc đảm bảo tính bảo mật.
- *Dự báo xu hướng*: Ở mức nâng cao hơn, Data Analyst có thể áp dụng các mô hình dự báo (forecasting) để dự đoán xu hướng trong tương lai. Điều này có thể bao gồm dự báo doanh thu, nhu cầu sản phẩm, hành vi khách hàng hoặc biến động thị trường. Các kỹ thuật thường được sử dụng bao gồm mô hình chuỗi thời gian (time series), hồi quy nâng cao hoặc các phương pháp machine learning cơ bản.

1.3 Những kiến thức và kỹ năng cần có

Để trở thành một chuyên viên phân tích dữ liệu (Data Analyst) chuyên nghiệp, người học cần trang bị một hệ thống năng lực toàn diện, bao gồm kiến thức kỹ thuật, tư duy phân tích, hiểu biết kinh doanh và khả năng thích ứng với công nghệ mới. Trong bối cảnh dữ liệu ngày càng đóng vai trò trung tâm trong mọi lĩnh vực, Data Analyst không chỉ đơn thuần là người xử lý dữ liệu mà còn là người tạo ra giá trị từ dữ liệu. Dưới đây là các nhóm kỹ năng và kiến thức cốt lõi:

1.3.1 Kỹ năng kỹ thuật và công cụ

Đây là nền tảng cốt lõi giúp Data Analyst có thể trực tiếp thao tác với dữ liệu, xây dựng mô hình phân tích và tạo ra các giá trị thực tiễn cho doanh nghiệp. Một Data Analyst chuyên nghiệp cần thành thạo nhiều công cụ và công nghệ khác nhau để đáp ứng yêu cầu ngày càng đa dạng của công việc.

- *Truy vấn dữ liệu với SQL*: là kỹ năng bắt buộc đối với hầu hết các vị trí Data Analyst, đặc biệt khi làm việc với các hệ quản trị cơ sở dữ liệu quan hệ như MySQL, PostgreSQL hoặc SQL Server. Data Analyst cần nắm vững từ các câu lệnh cơ bản (SELECT, WHERE, GROUP BY) đến nâng cao như JOIN nhiều bảng, subqueries và window functions. Khả năng viết truy vấn tối ưu không chỉ

giúp khai thác dữ liệu hiệu quả mà còn cải thiện hiệu suất xử lý, đặc biệt khi làm việc với dữ liệu lớn.

- *Lập trình (Python hoặc R)*: Trong đó, Python là ngôn ngữ phổ biến nhất nhờ hệ sinh thái thư viện phong phú như Pandas (xử lý dữ liệu), NumPy (tính toán), Matplotlib và Seaborn (trực quan hóa), Scikit-learn (machine learning). Việc sử dụng ngôn ngữ lập trình giúp Data Analyst tự động hóa các quy trình lặp lại, xử lý dữ liệu phức tạp và xây dựng các mô hình phân tích nâng cao. R cũng là một lựa chọn mạnh trong lĩnh vực thống kê và nghiên cứu học thuật.
- *Xử lý bảng tính (Excel/Google Sheets)*: Mặc dù có nhiều công cụ hiện đại, Excel vẫn giữ vai trò quan trọng trong môi trường doanh nghiệp nhờ tính linh hoạt và dễ sử dụng. Data Analyst cần thành thạo các hàm nâng cao (VLOOKUP, XLOOKUP, INDEX-MATCH), Pivot Tables, cũng như các công cụ như Power Query để xử lý và phân tích dữ liệu nhanh chóng. Đây thường là công cụ đầu tiên để khám phá dữ liệu (data exploration).
- *Trực quan hóa dữ liệu (Data Visualization)*: Việc sử dụng các công cụ như Power BI hoặc Tableau giúp Data Analyst xây dựng dashboard và báo cáo trực quan, hỗ trợ việc truyền đạt thông tin một cách hiệu quả.
- *Làm sạch và biến đổi dữ liệu (Data Cleaning/Wrangling)*: Đây là bước quan trọng nhất trong quy trình phân tích, giúp đảm bảo dữ liệu chính xác, nhất quán và sẵn sàng cho việc phân tích.
- *Hiểu về Data Warehouse & ETL*: Data Analyst cần hiểu cách dữ liệu được thu thập, lưu trữ và xử lý trong hệ thống thông qua các pipeline ETL/ELT. Kiến thức này giúp họ truy xuất dữ liệu hiệu quả hơn, đồng thời phối hợp tốt với Data Engineer trong việc xây dựng và tối ưu hệ thống dữ liệu.
- *Làm việc với Big Data*: Trong bối cảnh dữ liệu ngày càng lớn và phức tạp, Data Analyst nên làm quen với các công cụ như Apache Spark hoặc các nền tảng điện toán đám mây (AWS, Google Cloud, Azure). Điều này giúp họ có khả năng xử lý và phân tích dữ liệu ở quy mô lớn, đáp ứng nhu cầu của các doanh nghiệp hiện đại.

1.3.2 Kiến thức toán học và thống kê

Mặc dù không cần chuyên sâu như nhà nghiên cứu, Data Analyst cần nắm vững các khái niệm cơ bản để đảm bảo tính chính xác và ý nghĩa của kết quả phân tích:

- *Thống kê mô tả*: Bao gồm các chỉ số như trung bình (mean), trung vị (median), độ lệch chuẩn (standard deviation) và phân phối dữ liệu. Đây là bước cơ bản để tóm tắt và hiểu đặc điểm của dữ liệu trước khi đi sâu vào phân tích.
- *Thống kê suy luận & kiểm định giả thuyết*: Cho phép Data Analyst đưa ra kết luận từ dữ liệu mẫu và kiểm chứng các giả định kinh doanh. Các phương pháp như kiểm định t-test, ANOVA hoặc kiểm định chi-square giúp xác định liệu một kết quả có mang ý nghĩa thống kê hay không.
- *Phân tích hồi quy và tương quan*: Giúp xác định mối quan hệ giữa các biến trong dữ liệu. Ví dụ, hồi quy tuyến tính có thể được sử dụng để dự đoán doanh thu dựa trên chi phí marketing, trong khi hệ số tương quan giúp đo lường mức độ liên kết giữa các biến.
- *Machine Learning cơ bản*: Data Analyst không cần xây dựng mô hình quá phức tạp nhưng cần hiểu các thuật toán cơ bản như hồi quy (regression), phân loại (classification), phân cụm (clustering). Những kỹ thuật này hỗ trợ phân tích nâng cao và dự báo xu hướng.
- *Kiến thức về Time-series analysis*: Đây là kỹ năng quan trọng khi làm việc với dữ liệu theo thời gian như doanh thu, nhu cầu hoặc lưu lượng truy cập. Các phương pháp này giúp nhận diện xu hướng và dự báo tương lai.

1.3.3 Kỹ năng phân tích và tư duy (Soft Skills)

Bên cạnh kỹ thuật, các kỹ năng mềm cũng đóng một vai trò quan trọng trong những kỹ thuật cần thiết của một Data Analyst.

- *Tư duy phản biện (Critical Thinking)*: Data Analyst cần có khả năng đặt câu hỏi đúng, kiểm tra tính hợp lý của dữ liệu và tránh các kết luận sai lệch. Điều này giúp đảm bảo rằng các insight được đưa ra là chính xác và có ý nghĩa.
- *Giải quyết vấn đề (Problem-solving)*: Không chỉ phân tích dữ liệu, Data Analyst cần hiểu rõ vấn đề kinh doanh cần giải quyết, từ đó lựa chọn phương pháp và công cụ phù hợp để đưa ra giải pháp hiệu quả.

- *Kể chuyện bằng dữ liệu (Data Storytelling)*: Việc trình bày kết quả phân tích dưới dạng một câu chuyện logic giúp người nghe dễ hiểu và dễ hành động hơn. Đây là kỹ năng quan trọng khi làm việc với các nhà quản lý hoặc đối tượng không có nền tảng kỹ thuật.
- *Kỹ năng giao tiếp (Communication)*: Data Analyst thường xuyên làm việc với nhiều phòng ban khác nhau. Vì vậy, họ cần có khả năng giải thích các khái niệm phức tạp một cách đơn giản, rõ ràng và dễ tiếp cận.
- *Hiểu biết lĩnh vực (Domain Knowledge)*: Am hiểu ngành nghề giúp Data Analyst xác định đúng vấn đề cần phân tích và đưa ra các insight có giá trị thực tiễn cao. Ví dụ, trong lĩnh vực bán lẻ, việc hiểu hành vi khách hàng sẽ giúp phân tích hiệu quả hơn.

1.3.4 Đạo đức dữ liệu và xu hướng công nghệ

Trong bối cảnh hiện đại, yếu tố đạo đức và xu hướng công nghệ cũng trở thành một phần không thể thiếu đối với Data Analyst.

- *Đạo đức và quyền riêng tư dữ liệu*: Data Analyst cần tuân thủ các nguyên tắc bảo mật dữ liệu, đảm bảo thông tin cá nhân được bảo vệ và sử dụng đúng mục đích. Ngoài ra, cũng cần chú ý đến vấn đề thiên lệch dữ liệu (bias) để tránh đưa ra các kết luận sai lệch hoặc gây ảnh hưởng tiêu cực.
- *Ứng dụng AI trong phân tích*: Data Analyst hiện đại cần biết tận dụng các công cụ AI như ChatGPT, Claude hoặc các nền tảng hỗ trợ phân tích để tự động hóa quy trình, tăng tốc xử lý và nâng cao hiệu quả làm việc.
- *Tự động hóa và DataOps*: Xu hướng hiện nay yêu cầu Data Analyst không chỉ dừng lại ở phân tích mà còn tham gia vào việc tối ưu hóa và tự động hóa pipeline dữ liệu. DataOps giúp cải thiện tốc độ xử lý, đảm bảo tính nhất quán và nâng cao hiệu quả vận hành hệ thống dữ liệu.

1.4 Bảng cấp và các chứng chỉ liên quan

1.4.1 Bảng cấp học thuật

Trước hết, về bảng cấp học thuật, các chuyên ngành liên quan đến dữ liệu, công nghệ và kinh doanh được xem là nền tảng phù hợp nhất cho định hướng trở thành Data Analyst. Theo các báo cáo nghề nghiệp từ Coursera, phần lớn các Data Analyst hiện nay xuất thân từ những lĩnh vực có liên quan đến toán học, thống kê, khoa học máy tính

hoặc kinh tế định lượng. Đây đều là những ngành giúp người học phát triển tư duy logic, khả năng xử lý dữ liệu và năng lực phân tích.

Cụ thể, các ngành như Khoa học dữ liệu và Khoa học máy tính cung cấp nền tảng kỹ thuật vững chắc, giúp người học phát triển kỹ năng lập trình (Python, R), xử lý dữ liệu lớn và hiểu các thuật toán phân tích. Trong khi đó, Thống kê đóng vai trò nền tảng về phương pháp luận, giúp người học hiểu bản chất của dữ liệu, từ việc thu thập, lấy mẫu đến kiểm định giả thuyết và xây dựng mô hình dự báo. Đối với các ngành Kinh tế - Tài chính, người học lại có lợi thế về tư duy phân tích kinh doanh, hiểu các chỉ số tài chính và hành vi thị trường, từ đó có khả năng áp dụng dữ liệu vào các bài toán thực tiễn trong doanh nghiệp.

Bên cạnh đó, các báo cáo nghề nghiệp cũng nhấn mạnh rằng hiệu quả làm việc của một Data Analyst không chỉ phụ thuộc vào kỹ năng kỹ thuật mà còn đến từ sự kết hợp với hiểu biết kinh doanh. Điều này cho thấy một Data Analyst giỏi không chỉ biết xử lý dữ liệu mà còn phải hiểu dữ liệu đó có ý nghĩa gì trong bối cảnh hoạt động của doanh nghiệp.

Trong số các ngành đào tạo, Hệ thống thông tin quản lý (MIS - Management Information Systems) thường được đánh giá là một trong những lựa chọn phù hợp nhất cho định hướng Data Analyst. Điểm nổi bật của MIS nằm ở việc kết hợp hài hòa giữa kiến thức công nghệ và tư duy kinh doanh. Sinh viên theo học MIS không chỉ được trang bị kiến thức về cơ sở dữ liệu, hệ thống thông tin và quản trị dữ liệu mà còn hiểu rõ cách doanh nghiệp vận hành, cách các phòng ban sử dụng dữ liệu trong thực tế, cũng như cách chuyển hóa dữ liệu thành thông tin phục vụ ra quyết định. Chính sự kết hợp này tạo nên khác biệt quan trọng của MIS so với các ngành thuần kỹ thuật. Nếu như các ngành như Khoa học máy tính tập trung nhiều vào xử lý và xây dựng hệ thống, thì MIS lại chú trọng vào việc ứng dụng dữ liệu trong bối cảnh doanh nghiệp. Nhờ đó, người học MIS có khả năng “dịch” dữ liệu thành insight kinh doanh - một năng lực cốt lõi giúp Data Analyst tạo ra giá trị thực tiễn cho tổ chức.

1.4.2 Chứng chỉ

Bên cạnh bằng cấp học thuật, các chứng chỉ chuyên môn đóng vai trò quan trọng trong việc chuẩn hóa kỹ năng và nâng cao khả năng cạnh tranh trên thị trường lao động.

Theo tổng hợp từ Franklin University, các nhà tuyển dụng đặc biệt đánh giá cao những chứng chỉ sau

5 Platform-Specific Data Analytics Certificates Desired By Top Employers				
				
IBM Data Science Professional Certificate	Microsoft Certified: Power BI Data Analyst Associate	Microsoft Certified: Azure Data Science Associate	Google Data Analytics Certificate	Cloudera Data Platform Generalist
WHAT YOU'LL LEARN Data visualization, machine learning modeling, and IBM Data Libraries	WHAT YOU'LL LEARN Prepare, model, visualize, and deploy data using Power BI	WHAT YOU'LL LEARN Machine learning, predictive models and data experiments using Azure's platform	WHAT YOU'LL LEARN Analyze & visualize data to solve business problems	WHAT YOU'LL LEARN System administration, data analysis, and solution development using CDP platform
 COURSES 9	 COURSES ~12	 COURSES ~12	 COURSES 8	 COURSES 1
 TIME TO COMPLETE 6 Months	 TIME TO COMPLETE ~3 Weeks (+ 1 3-hour Exam)	 TIME TO COMPLETE ~3 Weeks (+ 1 3-hour Exam)	 TIME TO COMPLETE 5 Months (10 hours / week)	 TIME TO COMPLETE 90 Minutes
Sources: Google, Microsoft, IBM, Coursera				

Hình A.1.1: Các chứng chỉ Data Analytics được doanh nghiệp đánh giá cao (Nguồn: Franklin University)

❖ Google Data Analytics Professional Certificate

Đây là một trong những chứng chỉ phổ biến nhất dành cho người mới bắt đầu, được phát triển bởi Google thông qua nền tảng Coursera. Chương trình được thiết kế nhằm cung cấp kiến thức toàn diện về quy trình phân tích dữ liệu, bao gồm thu thập, làm sạch, phân tích và trực quan hóa dữ liệu.

Điểm nổi bật của chứng chỉ này là tính dễ tiếp cận và lộ trình học rõ ràng, phù hợp với những người chưa có nền tảng. Ngoài ra, chương trình còn tích hợp các công cụ phổ biến như Spreadsheet, SQL và R, giúp người học nhanh chóng tiếp cận công việc thực tế. Do đó, đây thường được xem là “bước khởi đầu” cho những ai muốn theo đuổi nghề Data Analyst.

❖ IBM Data Analyst Professional Certificate

Chứng chỉ này được cung cấp bởi IBM, tập trung vào việc phát triển kỹ năng phân tích dữ liệu kết hợp với yếu tố kỹ thuật, đặc biệt là Python.

So với Google, chương trình của IBM mang tính kỹ thuật cao hơn, giúp người học hiểu sâu hơn về xử lý dữ liệu và lập trình. Điều này phù hợp với xu hướng tuyển dụng hiện nay khi các doanh nghiệp ngày càng ưu tiên Data Analyst có khả năng làm việc với dữ liệu lớn và tự động hóa quy trình phân tích.

❖ Microsoft Certified: Power BI Data Analyst Associate (PL-300)

Chứng chỉ này do Microsoft cấp và được đánh giá rất cao trong môi trường doanh nghiệp. Nội dung tập trung vào việc xây dựng mô hình dữ liệu, xử lý dữ liệu và thiết kế dashboard bằng Power BI - một trong những công cụ Business Intelligence phổ biến nhất hiện nay.

Điểm mạnh của chứng chỉ này là tính ứng dụng thực tiễn cao, giúp người học đáp ứng trực tiếp nhu cầu công việc như xây dựng báo cáo, dashboard và hỗ trợ ra quyết định. Đây là chứng chỉ đặc biệt phù hợp với những ai muốn làm việc trong môi trường doanh nghiệp hoặc theo hướng Business Intelligence.

❖ AWS Certified Data Analytics

Chứng chỉ này được cung cấp bởi Amazon Web Services, tập trung vào phân tích dữ liệu trên nền tảng điện toán đám mây. Nội dung bao gồm xử lý Big Data, xây dựng Data Warehouse và triển khai các hệ thống phân tích dữ liệu quy mô lớn.

Đây là chứng chỉ ở mức nâng cao, yêu cầu người học có kinh nghiệm với hệ sinh thái AWS. Trong bối cảnh các doanh nghiệp chuyển dịch sang Cloud và Big Data, chứng chỉ này giúp Data Analyst mở rộng cơ hội sang các vai trò kỹ thuật hơn như Data Engineer hoặc Cloud Data Analyst.

❖ SAS Statistical Business Analyst Professional Certificate

Chứng chỉ này do SAS Institute cung cấp, tập trung vào phân tích thống kê và mô hình dự báo trong bối cảnh kinh doanh. Nội dung bao gồm phân tích dữ liệu thống kê, xây dựng mô hình dự đoán và đánh giá mô hình. Chứng chỉ SAS đặc biệt phù hợp với các lĩnh vực yêu cầu phân tích chuyên sâu như tài chính, bảo hiểm, y tế hoặc marketing. Đây là lựa chọn tốt cho những Data Analyst muốn đi theo hướng phân tích định lượng và mô hình hóa dữ liệu.

1.5 Vị trí Data Analyst trong các lĩnh vực khác nhau

Trong bối cảnh chuyển đổi số diễn ra mạnh mẽ, hầu hết các lĩnh vực đều cần đến dữ liệu và kéo theo đó vị trí chuyên viên phân tích dữ liệu có mặt hầu hết ở các doanh nghiệp, công ty. Dù cùng sử dụng các kỹ năng phân tích dữ liệu, nhưng cách áp dụng, mục tiêu phân tích và loại dữ liệu xử lý sẽ có sự khác biệt đáng kể giữa các lĩnh vực, tùy thuộc vào đặc thù hoạt động của từng ngành

❖ Tài chính và Ngân hàng

Tài chính - Ngân hàng được xem là một trong những lĩnh vực tiêu biểu và tiên phong nhất trong việc ứng dụng phân tích dữ liệu ở mức độ chuyên sâu. Tại đây, vai trò của Data Analyst mang tính sống còn, bởi các quyết định tài chính luôn liên quan trực tiếp đến dòng tiền, tài sản và sự ổn định của hệ thống kinh tế. Trong cấu trúc ngân hàng hiện đại, nhà phân tích dữ liệu tham gia vào toàn bộ vòng đời của một giao dịch tài chính, từ lúc thiết lập sản phẩm đến khi quản trị rủi ro và thu hồi vốn.

Một trong những nhiệm vụ trọng yếu nhất của Data Analyst trong ngân hàng là quản trị rủi ro tín dụng. Thông qua việc thu thập các dữ liệu về rủi ro của từng cá nhân hoặc tổ chức, nhà phân tích thực hiện tổng hợp và lưu trữ thành các bộ dữ liệu chân dung rủi ro (Risk Profile). Việc xác định các dấu hiệu cảnh báo sớm thông qua dữ liệu giúp ngân hàng điều chỉnh chính sách tín dụng kịp thời, giảm thiểu nguy cơ tổn thất và tối ưu hóa danh mục cho vay.

Bên cạnh đó, hệ thống phòng chống gian lận (Fraud Detection) dựa trên dữ liệu là một thành trì bảo vệ ngân hàng trước các tội phạm tài chính ngày càng tinh vi. Data Analyst sử dụng các mẫu dữ liệu giao dịch lịch sử để xây dựng mô hình, sau đó thử nghiệm và triển khai các thuật toán Học máy (Machine Learning) để phát hiện các hành vi bất thường theo thời gian thực. Khi một giao dịch có dấu hiệu sai lệch so với mô hình

hành vi thông thường của người dùng, hệ thống sẽ ngay lập tức phát ra cảnh báo hoặc tạm dừng giao dịch để kiểm tra chéo, giúp giảm thiểu rủi ro bị đánh cắp tài sản.

Ngoài ra, sự phát triển của các công nghệ tài chính (FinTech) đã thúc đẩy vai trò của phân tích dự báo. Data Analyst hỗ trợ đánh giá các biến động thị trường, từ đó xây dựng các mô hình dự báo dòng tiền và tối ưu hóa danh mục đầu tư. Việc hiểu rõ giá trị vòng đời khách hàng và thực hiện phân cụm khách hàng giúp ngân hàng xác định được nhóm khách hàng mang lại lợi nhuận cao, từ đó phát triển các mối quan hệ gắn kết và cung cấp các dịch vụ tài chính cá nhân hóa, nâng cao sự hài lòng và lòng trung thành của người dùng.

❖ Marketing và Truyền thông

Trong lĩnh vực Marketing và Truyền thông, sự thâm nhập của dữ liệu đã thay đổi hoàn toàn phương thức tiếp cận thị trường, đặc biệt là trong môi trường kỹ thuật số (Digital Marketing). Marketing Data Analyst hiện đóng vai trò là người giải mã hành vi khách hàng, giúp doanh nghiệp thoát khỏi sự phụ thuộc vào cảm tính chủ quan để tiến tới việc ra quyết định dựa trên bằng chứng có thể đo lường và kiểm chứng.

Nhiệm vụ của một Marketing Data Analyst bắt đầu từ việc thu thập dữ liệu đa kênh. Dữ liệu từ Google Analytics, Facebook Ads, hệ thống quản trị quan hệ khách hàng (CRM), cho đến các phản hồi từ Email Marketing đều được tập hợp để tạo ra một cái nhìn toàn cảnh về hành trình khách hàng. Quá trình làm sạch và chuẩn hóa dữ liệu (Data Cleaning & Wrangling) là bước tiên quyết để đảm bảo tính chính xác của các phân tích sau này. Từ đây, nhà phân tích sẽ đo lường các chỉ số hiệu suất then chốt (KPI) như tỷ suất hoàn vốn (ROI), chi phí để có một khách hàng mới (CAC), tỷ lệ nhấp (CTR) và tỷ lệ chuyển đổi.

Sự khác biệt lớn nhất của Marketing hiện đại chính là khả năng tối ưu hóa theo thời gian thực. Thông qua việc phân tích hiệu quả của từng chiến dịch quảng cáo, Data Analyst có thể đề xuất việc điều chỉnh ngân sách, thay đổi nội dung hoặc cải thiện trải nghiệm người dùng (UX) và giao diện người dùng (UI) trên website hay ứng dụng di động. Các kỹ thuật như thử nghiệm A/B (A/B Testing) được áp dụng thường xuyên để đánh giá phản ứng của thị trường đối với các thay đổi nhỏ nhất, từ màu sắc nút bấm đến tiêu đề bài quảng cáo, nhằm tìm ra phương án tối ưu nhất để thúc đẩy doanh thu.

Hơn thế nữa, việc xây dựng các mô hình dự báo xu hướng (Trend Analysis) và phân khúc khách hàng chuyên sâu (Customer Segmentation) giúp các chuyên gia Marketing thấu hiểu được nhu cầu tiềm ẩn của từng nhóm đối tượng. Thay vì tiếp thị đại trà, doanh nghiệp có thể thực hiện cá nhân hóa thông điệp đến đúng đối tượng, đúng thời điểm và trên đúng kênh truyền thông, từ đó tối đa hóa hiệu quả của từng đồng ngân sách marketing bỏ ra.

❖ Y tế và sức khỏe

Trong lĩnh vực Y khoa, vai trò của Data Analyst được phân định thành hai hướng tiếp cận chính: nhóm tập trung vào cải thiện kết quả lâm sàng và nhóm hỗ trợ vận hành hệ thống y tế. Nhóm thứ nhất tập trung vào dữ liệu lâm sàng và chăm sóc bệnh nhân. Tại đây, Data Analyst đóng vai trò phân tích dữ liệu và chẩn đoán hình ảnh, xác định các yếu tố nguy cơ và dự đoán bệnh. Những phân tích này là đầu vào quý giá để đội ngũ y bác sĩ đưa ra quyết định điều trị chính xác hơn, từ đó nâng cao chất lượng chăm sóc và giảm tỷ lệ tái nhập viện.

Ngược lại, nhóm Data Analyst hỗ trợ vận hành hệ thống (Operational) lại tập trung vào việc tối ưu hóa cách thức mà các cơ sở y tế vận hành. Họ đứng sau các bộ phận như Quản lý bệnh viện, Tài chính y tế và Chuỗi cung ứng để cung cấp các báo cáo phân tích về hiệu quả sử dụng giường bệnh, dự báo nhu cầu thuốc và vật tư y tế, xác định các điểm nghẽn trong quy trình khám chữa bệnh. Sự kết hợp giữa hai nhóm này đảm bảo rằng các cơ sở y tế không chỉ mang lại kết quả điều trị tốt mà còn vận hành bộ máy một cách tinh gọn và hiệu quả.

❖ Sản xuất và Chuỗi cung ứng

Lĩnh vực sản xuất và chuỗi cung ứng đang trải qua một giai đoạn chuyển mình mạnh mẽ với sự ra đời của khái niệm "Nhà máy thông minh" (Smart Manufacturing). Trong môi trường này, Data Analyst đóng vai trò trung tâm trong việc phân tích hiệu suất máy móc, tối ưu hóa quy trình sản xuất và quản trị chuỗi cung ứng một cách toàn diện. Việc thu thập dữ liệu từ các cảm biến IoT trên dây chuyền sản xuất cho phép nhà phân tích thực hiện bảo trì dự báo, xác định thời điểm máy móc có khả năng gặp sự cố để can thiệp trước khi xảy ra hỏng hóc gây dừng máy, từ đó tiết kiệm chi phí sửa chữa và giảm thiểu thời gian chết.

Trong quản trị chuỗi cung ứng, phân tích dữ liệu giúp giải quyết bài toán tối ưu hóa hàng tồn kho. Bằng cách phân tích dữ liệu bán hàng lịch sử cùng các yếu tố ngoại cảnh như thời tiết, sự kiện xã hội và xu hướng thị trường, Data Analyst có thể dự báo nhu cầu sản phẩm với độ chính xác cao. Điều này giúp doanh nghiệp duy trì mức tồn kho tối ưu, tránh tình trạng ứ đọng vốn ở những mặt hàng chậm luân chuyển hoặc mất cơ hội bán hàng do thiếu hụt sản phẩm.

Hơn thế nữa, phân tích chuỗi cung ứng (Supply Chain Analytics) còn mở rộng sang việc tối ưu hóa vận tải và hậu cần. Nhà phân tích thực hiện đánh giá hiệu suất của các nhà cung cấp dựa trên các tiêu chí như thời gian giao hàng, chất lượng sản phẩm và chi phí. Việc sử dụng các mô hình tối ưu hóa định tuyến giúp giảm thiểu chi phí vận chuyển và rút ngắn thời gian giao hàng, nâng cao sự hài lòng của khách hàng cuối cùng. Đặc biệt, sự ra đời của các giải pháp "Bản sao số" (Digital Twins) cho phép nhà phân tích mô phỏng các kịch bản đứt gãy chuỗi cung ứng để xây dựng các kế hoạch dự phòng, từ đó tăng cường khả năng chống chịu của doanh nghiệp trước các rủi ro địa chính trị hay thiên tai.

1.6 Phân biệt Data Analyst với các vai trò liên quan

Vì Data Analyst không phải là vị trí duy nhất làm việc với dữ liệu, việc phân biệt rõ giữa Data Analyst với các vị trí có liên quan như Data Scientist, Data Engineer hay Business Analyst là rất cần thiết để hiểu đúng định hướng nghề nghiệp.

Bảng A.1.1: Bảng so sánh Data Analyst và các vai trò liên quan

Tiêu chí	Data Analyst	Data Scientist	Data Engineer	Business Analyst
Chức năng chính	Biến dữ liệu thô thành thông tin trực quan, dễ hiểu để hỗ trợ ra quyết định	Xây dựng mô hình dự báo và machine learning, phát hiện các mẫu hình phức tạp	Xây dựng và vận hành đường ống dữ liệu (data pipeline), đảm bảo dữ	Xác định vấn đề kinh doanh, thu thập yêu cầu từ các bộ phận, đề xuất giải pháp cải

		ẩn sâu trong dữ liệu	liệu sẵn sàng, sạch sẽ và đáng tin cậy	tiến quy trình
Câu hỏi trả lời	"Điều gì đã xảy ra?" và "Tại sao?"	"Điều gì sẽ xảy ra tiếp theo?" và "Làm thế nào để tối ưu?"	"Làm thế nào để dữ liệu được thu thập, lưu trữ và xử lý hiệu quả?"	"Với những insights này, doanh nghiệp nên làm gì?" và "Giải pháp nào phù hợp?"
Hoạt động hàng ngày	Làm sạch và xử lý dữ liệu (data wrangling); phân tích khám phá (EDA); xây dựng dashboard và báo cáo trực quan; trình bày insights cho các bên liên quan	Xây dựng và tối ưu mô hình machine learning; thử nghiệm thuật toán mới; phân tích thống kê nâng cao; kết hợp với Data Engineer để triển khai mô hình vào thực tế	Thiết kế pipeline ETL/ELT; quản lý kho dữ liệu (Data Warehouse) và hồ dữ liệu (Data Lake); đảm bảo chất lượng, bảo mật và hiệu suất hệ thống	Phân tích quy trình nghiệp vụ; thu thập và phân tích yêu cầu từ các bộ phận; đề xuất giải pháp cải tiến; làm cầu nối giữa đội ngũ kỹ thuật và quản lý
Công cụ chính	SQL, Excel, Power BI, Tableau,	Python/R nâng cao, TensorFlow,	Python, Java, Scala, SQL, Spark,	Excel, SQL, BI tools, kỹ năng thu thập

	Python/R (cơ bản)	PyTorch, Scikit-learn	Airflow, AWS/Azure/GCP	yêu cầu, quy trình nghiệp vụ
Kỹ năng trọng tâm	Trực quan hóa dữ liệu; làm sạch dữ liệu; thống kê mô tả; kể chuyện bằng dữ liệu	Machine learning; thống kê nâng cao; xây dựng mô hình dự báo; feature engineering	ETL/ELT; kho dữ liệu (Data Warehouse); hệ thống phân tán; big data frameworks	Hiểu biết sâu về lĩnh vực kinh doanh; giao tiếp và thuyết trình; quản lý stakeholder; phân tích quy trình
Vị trí trong quy trình	Cuối quy trình - nhận dữ liệu đã được xử lý từ Data Engineer, phân tích và trả về insights cho business	Đan xen - làm việc với dữ liệu sạch, xây dựng mô hình, có thể đề xuất mở rộng thu thập dữ liệu mới	Đầu quy trình - xây dựng hạ tầng và đường ống, cung cấp dữ liệu "sạch" cho Analyst và Scientist	Đan xen - làm việc ở cả đầu (xác định vấn đề) và cuối (áp dụng insights vào chiến lược)

CHƯƠNG 2: BỨC TRANH THỊ TRƯỜNG DATA ANALYST

2.1 Thị trường quốc tế

2.1.1 Sự bùng nổ về quy mô

Thị trường phân tích dữ liệu, những năm gần đây có tốc độ tăng trưởng đáng kinh ngạc. Năm 2025, giá trị thị trường ngành phân tích dữ liệu nói chung đạt 394,70 tỷ USD và được dự báo sẽ vượt mốc 447 tỷ USD trong năm 2026. Với tốc độ tăng trưởng kép hàng năm (CAGR) là 12,8%, đến năm 2034 được dự đoán đạt quy mô 1.100 tỷ USD.

Ở Bắc Mỹ, ngành phân tích dữ liệu đang chiếm ưu thế hơn so với các thị trường khác chiếm đến hơn 36% thị phần toàn cầu, do đây là nơi tập trung của nhiều tập đoàn công nghệ lớn. Tuy nhiên ở các thị trường khác như Trung Đông và Châu Á - Thái Bình Dương, đang có xu hướng chuyển đổi số mạnh hơn, việc xây dựng các hạ tầng điện toán đám mây đang được đầu tư mạnh, tạo ra nhiều vị trí, cơ hội việc làm trong ngành Phân tích dữ liệu.

Nhìn chung ở thị trường về Bắc Mỹ đang là nơi có nhiều nhân lực và vị trí về cơ hội làm phân tích dữ liệu nhất, còn ở thị trường đang phát triển như Châu Á - Thái Bình Dương lại đang rất tiềm năng vì đang tập trung mạnh vào việc tận dụng triệt để dữ liệu trong kinh doanh, dự báo trong tương lai gần nhu cầu nhân lực ở đây sẽ tăng mạnh.

2.1.2 Xu hướng chuyển dịch trong tương lai

Điểm nổi bật trong giai đoạn 2025 - 2026 của ngành Phân tích dữ liệu là có sự giao thoa giữa việc phân tích dữ liệu và sử dụng trí tuệ nhân tạo. Trước những lo ngại về việc sự phát triển của trí tuệ nhân tạo sẽ thay thế các vị trí làm việc của con người, tuy nhiên các báo cáo thực tế lại cho thấy một xu hướng khác khi mà với sự trợ giúp của AI các DA hoàn thành công việc phân tích dữ liệu của mình nhanh hơn so với trước. Như vậy với xu hướng phát triển mạnh của AI hiện tại, các DA không phải lo sợ việc sẽ bị AI thay thế, mà phải chuyển mình tìm cách thích nghi với AI, ở hiện tại một DA biết sử dụng AI thuần thục để hỗ trợ cho việc phân tích sẽ có nhiều lợi thế hơn với các DA khác nếu có cùng số năm kinh nghiệm.

Hiện nay, khoảng 87% các nhà phân tích dữ liệu quốc tế tham gia khảo sát khẳng định rằng vai trò của họ trong doanh nghiệp trở nên mang tính chiến lược hơn từ khi có sự xuất hiện của AI. Sự hỗ trợ từ các công cụ AI Agent tự động hóa giúp giảm bớt các tác vụ thủ công như clean data, hay viết code cơ bản, từ đó các DA có nhiều thời gian

hơn để tập trung vào việc đưa ra quyết định từ dữ liệu đã phân tích được. Theo một dự báo của Gartner, đến năm 2026, có đến 40% các câu hỏi query data sẽ được thực hiện thông qua ngôn ngữ tự nhiên, cho thấy rằng các rào cản về kỹ thuật đang giảm dần nhưng yêu cầu về khả năng tư duy, phản biện và đưa ra quyết định dựa trên dữ liệu đang tăng cao.

2.1.3 Cơ hội việc làm tại thị trường quốc tế

Dựa trên các phân tích định lượng từ Cục Thống kê Lao động Hoa Kỳ (BLS) và các báo cáo nhân sự toàn cầu năm 2025, cơ hội nghề nghiệp cho vị trí Data Analyst không chỉ tăng và mặt số lượng mà còn mở rộng về chiều sâu chuyên môn. Đây được đánh giá là một trong những ngành nghề có tính “đề kháng” tốt nhất trước các biến động kinh tế.

Theo dự báo, nhu cầu tuyển dụng ở vị trí DA sẽ tăng trưởng 23% trong giai đoạn từ 2026 đến 2032, cao hơn nhiều lần khi so với các ngành nghề khác. Điểm đáng chú ý trong năm 2025 - 2026 là sự phủ sóng của data trong mọi ngõ ngách của nền kinh tế tiêu biểu như:

- Y tế và Dược phẩm: Đây là lĩnh vực có nhu cầu bùng nổ nhất. DA đóng vai trò then chốt trong việc phân tích hồ sơ bệnh nhân, quản lý chuỗi cung ứng vaccine/thuốc.
- Tài chính và ngân hàng (BFSI): Cơ hội tập trung vào các mảng phân tích rủi ro, phát hiện gian lận tài chính bằng AI và cá nhân hóa trải nghiệm khách hàng
- Bán lẻ và Thương mại điện tử: DA giúp doanh nghiệp dự báo xu hướng tiêu dùng, tối ưu hóa tồn kho và xây dựng các chiến dịch marketing theo phân khúc khách hàng

Thêm vào đó nữa, đặc thù của DA trong giai đoạn hiện nay có sự linh hoạt về địa lý. Nhờ có các hạ tầng Cloud (AWS, Google Cloud, Azure), các DA có thể làm việc từ xa cho các tập đoàn đa quốc gia. Với các dự án hạ tầng dữ liệu lớn tại các khu vực như Qatar hay Singapore đang tạo ra nhiều vị trí làm việc remote từ xa cho các DA quốc tế. Ở hiện tại, cơ hội nghề nghiệp cho các DA không còn nằm ở việc biết làm báo cáo mà nằm ở khả năng giải quyết các bài toán kinh doanh mà doanh nghiệp đang gặp phải bằng dữ liệu.

2.2 Thị trường Việt Nam

2.2.1 Tình hình chuyển đổi số tại Việt Nam

Trong những năm gần đây, chuyển đổi số đã trở thành một trong những chiến lược trọng tâm của Việt Nam nhằm thúc đẩy tăng trưởng kinh tế và nâng cao năng lực cạnh tranh quốc gia. Chính phủ đã ban hành nhiều chủ trương quan trọng, tiêu biểu là Chương trình Chuyển đổi số quốc gia theo Quyết định 749/QĐ-TTg (2020), đặt mục tiêu đến năm 2030 đưa Việt Nam trở thành quốc gia số, với kinh tế số đóng góp khoảng 30% GDP.

Bên cạnh đó, Nghị quyết 52-NQ/TW (2019) về Cách mạng công nghiệp 4.0 và gần đây là Nghị quyết 57-NQ/TW (2024) tiếp tục khẳng định vai trò của khoa học công nghệ, đổi mới sáng tạo và chuyển đổi số như một động lực trọng yếu cho phát triển kinh tế - xã hội. Các nghị quyết này nhấn mạnh việc xây dựng hạ tầng số, phát triển dữ liệu lớn (Big Data), trí tuệ nhân tạo (AI) và nguồn nhân lực số để thúc đẩy chuyển đổi toàn diện trong mọi lĩnh vực.

Thực tế cho thấy, quá trình chuyển đổi số tại Việt Nam đang diễn ra mạnh mẽ. Nền kinh tế số đạt quy mô khoảng 36 tỷ USD năm 2024, tăng trưởng nhanh nhất khu vực Đông Nam Á và chiếm khoảng 18 - 18,6% GDP. Điều này cho thấy kinh tế số không chỉ là xu hướng mà đã trở thành động lực tăng trưởng mới của nền kinh tế.

2.2.2 Nhận thức và mức độ ứng dụng phân tích dữ liệu trong doanh nghiệp

Thị trường về ngành dữ liệu tại Việt Nam đang bước vào giai đoạn tăng trưởng bùng nổ bởi làn sóng chuyển đổi và sự tích hợp sâu của AI. Mặc dù đại đa số doanh nghiệp ở Việt Nam vẫn đang ở giai đoạn đầu của việc quản trị dữ liệu, nhưng nhu cầu về nhân sự ở DA chất lượng cao đang tăng vọt để đáp ứng được mục tiêu tối ưu hóa vận hành và kinh doanh trên dữ liệu.

Theo một báo cáo từ IMARC Group (2026) và Carptech, quy mô thị trường ngành Phân tích dữ liệu Việt Nam đạt khoảng 325,6 triệu USD vào năm 2025 và dự báo sẽ tăng gấp đôi 714,1 triệu USD vào năm 2034. Tuy nhiên, bức tranh thực tế cho thấy có sự phân hóa rõ rệt:

- Dù chiến lược số được phủ rộng, nhưng thực tế chỉ có khoảng 2,2% doanh nghiệp Việt Nam đạt mức độ trưởng thành hoàn chỉnh. Dựa trên framework 5 cấp độ (từ Aware đến Optimizing), phần lớn các doanh nghiệp hiện nay vẫn còn đang kẹt

ở cấp 1 và 2, nơi data còn bị phân mảnh, chủ yếu xử lý thủ công qua Excel và thiếu đi tính hệ thống (Báo cáo Carptech 2026).

- Ngành BFSI và E-commerce đang là đầu tàu trong lĩnh vực về data này. Các đơn vị nổi bật như Techcombank, MoMo là ví dụ điển hình cho việc làm chủ công nghệ dữ liệu.
- Data quality là rào cản lớn nhất đối với thị trường Việt Nam, có đến 56% các DA thừa nhận việc chất lượng của data không cao đang là rào cản trong việc ứng dụng AI vào phân tích nâng cao.

2.2.3 Tương lai ngành phân tích dữ liệu

Trong 5 đến 10 năm tới, vai trò của DA sẽ không còn dừng lại ở chỗ trích xuất báo cáo mà sẽ chuyển sang các xu hướng mới ảnh hưởng bởi AI như:

- AI sẽ không còn chỉ là công cụ hỗ trợ mà sẽ cải tiến hỗ trợ DA như là những trợ lý có khả năng phân tích dữ liệu và từ đó nhìn ra insight đề xuất. Theo báo cáo Feedforce (2025), sự chuyển dịch từ các dashboard tĩnh sang phân tích dựa trên hội thoại và tối ưu hóa tự động bởi AI sẽ trở thành tiêu chuẩn mới.
- Các nền tảng dữ liệu hợp nhất như Microsoft Fabric đang thay đổi cách thức làm việc. Xóa bỏ đi ranh giới DE và DA, cho phép DA tiếp cận dữ liệu trực tiếp trên Cloud với tốc độ nhanh hơn và ít rào cản kỹ thuật hơn.
- Với sự ra đời của khung pháp lý về việc bảo vệ dữ liệu cá nhân tại Việt nam vào năm 2026, các doanh nghiệp sẽ phải chuyển trọng tâm sang Data Governance. Điều này có nghĩa việc tuân thủ sự riêng tư về data cá nhân và đạo đức dữ liệu trở thành yếu tố bắt buộc với một DA

2.2.4 Cơ hội làm việc của DA tại Việt Nam

Thị trường đang mở ra những cánh cửa lớn hơn cho các vị trí ở ngành dữ liệu, nhưng đi kèm với đó là yêu cầu khắt khe hơn về kỹ năng:

- Có một vị trí là sự giao thoa giữa DA và DE có thể gọi là Analytics Engineer là những DA có khả năng xây dựng lên các luồng dữ liệu sạch và tối ưu hóa query
- Nhờ sự phát triển từ các công cụ Low-code và AI mà các Non-tech có kiến thức domain chuyên sâu về Marketing, tài chính, Logistics đang có cơ hội lớn để chuyển sang DA trong chính domain đó.

- Theo dự kiến, ngân sách cho mảng dữ liệu của các doanh nghiệp sẽ tăng 30% và nhu cầu nhân sự tăng 40% cho những năm tới để phục vụ cho mục tiêu tăng 30% GDP của Chính phủ.

CHƯƠNG 3: LỘ TRÌNH NGHỀ NGHIỆP VÀ ĐỊNH HƯỚNG CHUNG

3.1 Lộ trình thăng tiến

Trong lĩnh vực Data Analysis (Phân tích dữ liệu), lộ trình nghề nghiệp thường được xây dựng theo hướng phát triển từ các vị trí nền tảng đến các vai trò có mức độ chuyên môn và trách nhiệm cao hơn. Mỗi giai đoạn đòi hỏi người làm nghề phải không ngừng nâng cao năng lực phân tích, tư duy dữ liệu, cũng như kỹ năng công nghệ và hiểu biết về lĩnh vực kinh doanh. Một lộ trình thăng tiến phổ biến trong ngành Data Analysis có thể được mô tả như sau:

Bảng A.3.1: Lộ trình thăng tiến theo nghề Data Analyst

Vị trí	Trách nhiệm	Công việc chính	Yêu cầu kỹ năng
Entry-Level Data Analyst	- Học cách làm quen với hệ thống dữ liệu, công cụ phân tích, quy trình làm việc trong công ty. - Học hỏi nhanh, làm việc cẩn thận.	- Thu thập dữ liệu từ database công ty (viết truy vấn query SQL hoặc Python). - Làm sạch dữ liệu. - Sau khi phân tích cơ bản, viết báo cáo tóm tắt về những phát hiện của mình.	- Kiến thức về SQL, NoSQL: truy xuất, lọc, tổng hợp dữ liệu. - Kỹ năng phân tích thống kê với Excel. - Tăng kinh nghiệm bằng cách làm project càng sớm càng tốt dù là giả lập.
Junior Data Analyst	- Có khả năng thực hiện quy trình phân tích trọn vẹn: trích xuất dữ liệu - trực quan hóa - viết báo cáo. - Chủ động với	- Công việc như ở cấp độ đầu vào. - Xác định mẫu: Tìm kiếm các xu hướng và mối liên hệ có ý nghĩa trong dữ liệu. - Trực quan hóa dữ	- Kinh nghiệm làm việc với cơ sở dữ liệu lớn. - Kỹ năng làm việc theo nhóm. - Excel nâng cao. - Thành thạo công

	những task hoặc mini project trong team. - Hiểu rõ bài toán, đưa ra insight đơn giản.	liệu, tạo dashboard - Chẩn đoán, khắc phục sự cố cho các hệ thống quản trị cơ sở dữ liệu.	cụ trực quan hóa: Power BI hoặc Tableau.
Senior Data Analyst	- Chịu trách nhiệm toàn diện cho một hoặc nhiều dự án. - Chủ động tìm vấn đề, đề xuất hướng giải quyết và đưa ra insight mang tính chiến lược. - Đảm bảo chất lượng phân tích toàn team. - Làm mentor cho Entry - Level Data Analyst và Junior.	- Hướng dẫn team thu thập, xử lý, phân tích dữ liệu. - Xác định xu hướng, đưa ra dự báo về hiệu quả hoạt động. - Đưa ra giải pháp kinh doanh hiệu quả, nâng cao quy trình làm việc. - Viết mã, debug, viết document, hỗ trợ phát triển các ứng dụng mới.	- Kinh nghiệm trong việc dự báo xu hướng, lập mô hình và tạo báo cáo. - Thành thạo R, Python,... - Kiến thức về Hadoop, Aster, Teradata... - Kỹ năng giao tiếp, thuyết trình tốt. - Khả năng làm việc độc lập và làm việc nhóm hiệu quả.

Data Analytics Manager	- Định hướng chiến lược phân tích, phân bổ nguồn lực, tuyển dụng và phát triển đội ngũ. - Trở thành cầu nối giữa các phòng ban. - Chịu trách nhiệm về độ chính xác báo cáo, thời gian xử lý yêu cầu và tác động của insight tới kết quả kinh doanh.	- Thiết kế các quy trình kỹ thuật, hướng khai thác và phân tích thị trường. - Xây dựng và phát triển các mô hình dữ liệu, hệ thống tự động hóa dữ liệu, đo lường hiệu suất và hệ thống báo cáo. - Báo cáo kết quả phân tích cho lãnh đạo, các bên liên quan.	- Kỹ năng lập trình cao cấp với SAS,.. - Hiểu biết chuyên sâu về phân tích nâng cao và mô hình dự báo. - Kỹ năng giao tiếp và lắng nghe. - Kỹ năng quản lý dự án và lãnh đạo xuất sắc.
Chief Data Officer	- Đưa ra được chiến lược tận dụng dữ liệu để thúc đẩy doanh nghiệp đi đúng hướng. - Biết phân bổ nguồn lực theo ưu tiên kinh doanh. - Thuyết phục các bên liên quan và nhà đầu tư.	- Phát triển các hệ thống phân tích dữ liệu hiệu quả. - Dẫn dắt thiết kế kiến trúc và hạ tầng dữ liệu. - Thực hiện các biện pháp bảo vệ dữ liệu. - Thúc đẩy văn hóa chia sẻ dữ liệu trong tổ chức.	- Kinh nghiệm 5-10 năm trong vai trò quản lý hoặc phân tích dữ liệu cấp cao. - Kỹ năng giao tiếp và lãnh đạo mạnh mẽ. - Tư duy phân tích sắc bén. - Kỹ năng thuyết trình và quản lý dự án

Data Analyst là vị trí có mức thu nhập khá hấp dẫn. Theo Báo cáo Lương và Thị trường Tuyển dụng IT 2025-2056 của ITviec, mức lương của Data Analyst theo khoảng năm kinh nghiệm như sau:

Vị trí IT / Khoảng năm kinh nghiệm	Mức lương trung vị (triệu VNĐ)					
	TỔNG	<1 năm	1-2 năm	3-4 năm	5-8 năm	>8 năm
Data Analytics						
15. Data Analyst/Data Scientist/ Business Intelligence Analyst	40,65	N/A	23,8	N/A	42,5	N/A
16. Data Engineer	41,3	N/A	N/A	56,9	N/A	N/A

Hình A.3.1: Mức lương trung vị của các ngành IT 2025-2026 (Nguồn: ITviec)

Ngành Data Analyst tưởng chừng chỉ xoay quanh con số, bảng biểu, biểu đồ nhưng càng đi sâu, ta sẽ thấy đây là cuộc chơi của tư duy, chiến lược và con người. Không có lộ trình nào giống hệt nhau nhưng nếu chúng ta hiểu rõ mình đang ở đâu, muốn đi đâu, và sẵn sàng học đúng thứ cần thiết cho từng giai đoạn thì Data không chỉ là nghề mà mình chọn, mà sẽ trở thành sự nghiệp thật sự.

3.2 Định hướng

Sau khi tìm hiểu về đặc thù công việc cũng như yêu cầu tuyển dụng của thị trường lao động đối với vị trí Data Analyst, nhóm nhận thấy rằng việc theo đuổi lĩnh vực này đòi hỏi sự chuẩn bị bài bản về cả kiến thức chuyên môn, kỹ năng công nghệ và hiểu biết về hoạt động kinh doanh. Do đó, việc vạch ra một kế hoạch phát triển nghề nghiệp cụ thể theo từng giai đoạn sẽ giúp định hướng quá trình học tập và rèn luyện một cách hiệu quả.

Xuyên suốt ba năm học vừa qua, nhóm đã có cơ hội tiếp cận với các môn học nền tảng như cơ sở dữ liệu, tư duy lập trình, xác suất thống kê, phân tích dữ liệu nâng cao, phân tích và thiết kế hệ thống thông tin quản lý. Những kiến thức này giúp nhóm hình thành nền tảng quan trọng để tiếp cận lĩnh vực phân tích dữ liệu. Bên cạnh đó, thông qua các bài tập, đồ án và quá trình tự học, nhóm cũng bước đầu làm quen với việc tư duy logic trong xử lý dữ liệu, xây dựng cơ sở dữ liệu và khai thác thông tin từ dữ liệu cũng như hiểu được vai trò của dữ liệu trong hoạt động của doanh nghiệp.

Dựa trên những kiến thức đã tích lũy và mục tiêu nghề nghiệp đã xác định, nhóm xây dựng kế hoạch phát triển theo ba giai đoạn: ngắn hạn, trung hạn và dài hạn.

Bảng A.3.2: Kế hoạch phát triển nghề nghiệp

Giai đoạn	Thời gian	Mục tiêu chính	Hoạt động cụ thể	Kết quả mong muốn
Ngắn hạn	6 - 12 tháng	- củng cố nền tảng kiến thức - Phát triển kỹ năng phân tích dữ liệu	- Thực hiện các dự án phân tích dữ liệu cá nhân - Hoàn thành kiến tập cho lĩnh vực DA	- Phát triển năng lực cá nhân, phân tích - Có portfolio gồm các dự án phân tích dữ liệu để phục vụ ứng tuyển thực tập
Thực tập	Năm cuối đại học	Tiếp cận môi trường làm việc thực tế	- Ứng tuyển vị trí DA Intern - Tham gia vào dự án phân tích dữ liệu trong doanh nghiệp	Tích lũy kinh nghiệm thực tế và hiểu quy trình làm việc với dữ liệu trong tổ chức
Trung hạn 1	1 - 3 năm sau tốt nghiệp	Trở thành Data Analyst chuyên nghiệp	- Làm việc tại doanh nghiệp - thực hiện các báo cáo phân tích và hỗ trợ ra quyết định kinh doanh	Có khả năng độc lập thực hiện các dự án phân tích dữ liệu
Trung hạn 2	3 - 5 năm sau tốt nghiệp	Nâng cao chuyên môn	Tham gia các dự án dữ liệu lớn, học thêm các công nghệ xử lý dữ liệu	Trở thành Senior Data Analyst
Dài hạn	5 - 10 năm sau	Phát triển chuyên sâu	Phát triển kỹ năng lãnh đạo, quản lý	Trở thành Analytics

	tốt nghiệp		nhóm dữ liệu, tham gia hoạch định chiến lược dữ liệu	Manager, Data Scientist
--	------------	--	--	-------------------------

Việc xây dựng kế hoạch phát triển nghề nghiệp cụ thể giúp nhóm có cái nhìn rõ ràng hơn về con đường theo đuổi nghề Data Analyst trong tương lai. Thông qua việc xác định mục tiêu và những kỹ năng cần phát triển, nhóm có thể chủ động hơn trong quá trình học tập, rèn luyện và tích lũy kinh nghiệm thực tế.

Lộ trình và định hướng được trình bày trong bài báo cáo này là kết quả của quá trình nghiên cứu và thảo luận của nhóm nhằm xác định con đường phát triển phù hợp với lĩnh vực Data Analysis. Tuy nhiên, đây chỉ là định hướng chung, bởi mỗi cá nhân có thể lựa chọn những hướng phát triển khác nhau tùy theo sở thích, năng lực, cơ hội nghề nghiệp và sự phát triển của thị trường lao động. Dù theo đuổi hướng đi nào, điều quan trọng nhất vẫn là sự chuẩn bị nghiêm túc, tinh thần học hỏi liên tục, khả năng thích nghi với sự thay đổi của công nghệ và niềm đam mê trong việc khai thác giá trị từ dữ liệu. Với sự chuẩn bị từ giai đoạn đại học và định hướng rõ ràng, nhóm tin rằng mình có thể từng bước phát triển và đóng góp tích cực trong lĩnh vực phân tích dữ liệu trong tương lai.

PHẦN 2: NGHIÊN CỨU VÀ XÂY DỰNG MÔ HÌNH DỰ BÁO

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1 Giới thiệu đơn vị kiến tập

1.1.1 Tổng quan về doanh nghiệp

Công ty TNHH Phát Đạt Holdings là doanh nghiệp hoạt động theo mô hình công ty nắm giữ vốn (Holding Company), tập trung vào quản lý đầu tư, điều phối nguồn lực tài chính và phát triển chiến lược trong hệ sinh thái Phát Đạt. Doanh nghiệp được thành lập ngày 24/11/2021, đặt trụ sở chính tại số 39 Phạm Ngọc Thạch, Phường Võ Thị Sáu, Quận 3, Thành phố Hồ Chí Minh.

Trong hệ sinh thái Phát Đạt, Công ty TNHH Phát Đạt Holdings giữ vai trò định hướng đầu tư và quản lý các danh mục tài sản chiến lược. Hoạt động của doanh nghiệp tập trung vào việc tối ưu hóa hiệu quả sử dụng nguồn vốn, mở rộng cơ hội đầu tư và hỗ trợ định hướng phát triển cho các đơn vị liên quan trong lĩnh vực bất động sản và tài chính.

Doanh nghiệp hoạt động trong nhiều lĩnh vực, trong đó tập trung chủ yếu vào đầu tư tài chính, hoạt động mua bán và sáp nhập doanh nghiệp (M&A), phát triển bất động sản khu công nghiệp và tư vấn quản lý. Cuối năm 2023, doanh nghiệp tham gia tiếp nhận và phát triển mảng bất động sản khu công nghiệp nhằm định hướng mở rộng danh mục đầu tư dài hạn và tăng cường khả năng khai thác quỹ đất chiến lược.

Bên cạnh hoạt động đầu tư và quản lý tài sản, doanh nghiệp cũng chú trọng đến việc nghiên cứu thị trường, đánh giá tiềm năng phát triển và ứng dụng công nghệ trong quá trình quản trị và vận hành. Trong bối cảnh thị trường bất động sản và đầu tư ngày càng cạnh tranh, việc ứng dụng dữ liệu và các phương pháp phân tích đang trở thành yếu tố hỗ trợ quan trọng cho quá trình hoạch định chiến lược và ra quyết định đầu tư.

1.1.2 Vai trò và nội dung kiến tập

Trong quá trình kiến tập, sinh viên được tiếp cận bài toán phân tích dữ liệu trong lĩnh vực bất động sản thông qua việc nghiên cứu, thu thập và xử lý dữ liệu từ nhiều nền tảng trực tuyến. Nội dung thực hiện tập trung vào xây dựng pipeline crawl dữ liệu, thiết kế schema lưu trữ thông tin dự án và tin đăng bất động sản, đồng thời thực hiện các bước làm sạch, chuẩn hóa và tiền xử lý dữ liệu phục vụ cho bài toán phân tích và dự báo giá bất động sản tại Thành phố Hồ Chí Minh.

Bên cạnh đó, nghiên cứu cũng tiến hành xây dựng đặc trưng dữ liệu và thử nghiệm một số mô hình học máy. Thông qua quá trình kiến tập, sinh viên có cơ hội vận dụng kiến thức về xử lý, phân tích dữ liệu và học máy vào bài toán ứng dụng trong lĩnh vực bất động sản.

1.2 Bối cảnh nghiên cứu

1.2.1 Tổng quan thị trường bất động sản TP.HCM

Thành phố Hồ Chí Minh là trung tâm kinh tế lớn nhất cả nước, đồng thời cũng là thị trường bất động sản có quy mô vốn hóa và mức độ sôi động dẫn đầu Việt Nam. Với tốc độ đô thị hóa nhanh chóng cùng áp lực gia tăng dân số cơ học liên tục qua các năm đã đẩy nhu cầu sở hữu nhà ở tại đây lên một ngưỡng rất cao, tạo tiền đề cho sự tăng trưởng mạnh mẽ của thị giá. Giá bất động sản tại TP.HCM đã có xu hướng tăng mạnh trong nhiều năm qua và trở thành một trong những vấn đề được quan tâm hàng đầu đối với người dân, nhà đầu tư lẫn các nhà nghiên cứu dữ liệu.

Tuy nhiên, thị trường tại TP.HCM không vận hành một cách đồng đều mà ghi nhận sự phân hóa rõ rệt về mặt bằng giá bán theo vị trí địa lý, loại hình nhà ở, phân khúc sản phẩm và mức độ phát triển đô thị, hình thành nên một hệ thống dữ liệu có độ lệch lớn và cấu trúc biến động phức tạp. Theo báo cáo của Savills Việt Nam, mặt bằng giá căn hộ tại TP.HCM liên tục tăng do sự mất cân đối giữa cung và cầu, thiếu hụt nguồn cung nhà ở trung cấp và bình dân, số lượng dự án mới được triển khai lại bị hạn chế bởi các vấn đề pháp lý, quỹ đất và chi phí đầu tư gia tăng. Điều này góp phần làm cho giá bất động sản tại nhiều khu vực tăng nhanh theo thời gian.

Các khu vực trung tâm như Quận 1, Quận 3 và Bình Thạnh cũ luôn duy trì mức giá rất cao nhờ lợi thế về vị trí, hạ tầng và khả năng kết nối giao thông. Các khu vực đô thị mới như Thành phố Thủ Đức hay Quận 7 lại biến động mạnh theo danh tiếng của chủ đầu tư, tiến độ dự án và hệ thống tiện ích nội khu đi kèm. Trong khi đó, các khu vực ngoại thành như Bình Chánh, Hóc Môn hay Nhà Bè tuy có biên độ giá khởi điểm thấp hơn nhưng lại sở hữu tốc độ tăng trưởng thị giá vượt trội nhờ vào tiến trình chuyển đổi mục đích sử dụng đất sang đất đô thị.

Hạ tầng giao thông tiếp tục là động lực quan trọng thúc đẩy thị trường bất động sản TP.HCM. Các dự án trọng điểm như tuyến Metro số 1 Bến Thành - Suối Tiên, Vành đai 3, cao tốc TP.HCM - Long Thành - Dầu Giây hay sân bay quốc tế Long Thành được

kỳ vọng sẽ tạo ra sự thay đổi lớn về khả năng kết nối khu vực. Theo báo cáo của Savills, trong ba năm tới sẽ có gần 5.000 căn hộ được phát triển dọc các tuyến metro và hơn 14.000 căn dọc theo các tuyến Vành đai 2 và Vành đai 3.

Sự phức tạp và phân hóa của thị trường đặt ra yêu cầu cấp thiết về việc xây dựng các công cụ phân tích dựa trên dữ liệu nhằm hỗ trợ các bên tham gia thị trường trong việc đánh giá và dự báo giá bất động sản một cách có căn cứ.

1.2.2 Tổng quan nghiên cứu trước đó

1.2.2.1 Các nghiên cứu quốc tế

Trên thế giới, các nghiên cứu về định giá bất động sản và dự báo giá nhà đã trải qua nhiều giai đoạn phát triển mạnh mẽ, từ các mô hình kinh tế lượng truyền thống đến các thuật toán học máy (Machine Learning) tiên tiến. Để phản ánh toàn diện giá trị của bất động sản, các nhà nghiên cứu quốc tế thường thiết lập bộ dữ liệu dựa trên các yếu tố cốt lõi: (1) Đặc trưng vật lý và cấu trúc nội khu, (2) Yếu tố vị trí và tiện ích ngoại khu, (3) Dữ liệu phi cấu trúc và tính biến động của thị trường, (4) Các mô hình thực nghiệm và thuật toán áp dụng.

Nhóm 1: Các đặc trưng vật lý và cấu trúc nội khu

Các đặc trưng vật lý luôn được khẳng định là những biến số nền tảng quyết định giá trị của bất động sản. Trong nghiên cứu của Yamannage (2024), thực nghiệm đã chứng minh được biến diện tích xây dựng (BuildingArea) và diện tích đất (Landsize) là những yếu tố đóng vai trò quyết định với mức độ tác động vượt trội, theo sau đó là năm xây dựng (YearBuilt) - biến phản ánh mức độ hao mòn và vòng đời của tài sản. Tương tự là bài nghiên cứu “House Price prediction using Machine Learning” của J.Kalidass và cộng sự vào năm 2024, đã sử dụng số phòng ngủ và số phòng vệ sinh (WC) như những chỉ số đại diện cho công năng sử dụng để phân loại hiệu quả các phân khúc nhà ở.

Bên cạnh các thuộc tính hữu hình của riêng căn nhà, hệ thống tiện ích nội khu thuộc dự án cũng đóng vai trò là chất xúc tác gia tăng giá trị đáng kể. Nghiên cứu của Pongprasert (2022) tại khu vực trung tâm (CBD) Bangkok đã cụ thể hóa các yếu tố này dưới dạng biến giả (dummy variables), tiêu biểu như biến Facility (đại diện cho hồ bơi, phòng gym, xông hơi) hay Car_Park và không gian xanh, công viên nội khu (Park). Kết quả thực nghiệm chỉ ra rằng bãi đỗ xe và công viên nội khu là một trong những nhân tố

có tác động mạnh mẽ nhất đến giá trị của phân khúc nhà ở cao cấp. Tuy nhiên việc gộp chung các tiện ích thành một biến vô tình trung làm suy giảm đến mức độ ảnh hưởng chi tiết của từng loại hình tiện ích biệt lập.

Nhóm 2: Yếu tố vị trí, không gian và tiện ích ngoại khu

Ngoài đặc trưng vật lý, nhóm yếu tố không gian và khả năng tiếp cận với tiện ích ngoại khu cũng đóng góp cho việc định hình giá trị bất động sản. Yamannage (2024) đã tái khẳng định tầm quan trọng của yếu tố không gian thông qua các biến vị trí vi mô như khu vực (Suburb), mã bưu chính (Postcode) và tọa độ địa lý (Latitude/Longitude). Nhằm khóa lấp khoảng trống nghiên cứu về hệ thống tiện ích ngoại vi mà Yamannage chưa đào sâu, Viet-Ngu Hoang và cộng sự (2024) đã nhấn mạnh vai trò của các biến khoảng cách (distance-based variables) từ tài sản đến công viên, trường học, bệnh viện, khu CBD và hệ thống giao thông công cộng bài nghiên cứu “Unlocking visual data to enhance the accuracy of AI-enabled mass valuation of urban houses: An Australian city case study”.

Đặc biệt, tác động của hạ tầng giao thông trọng điểm đến giá trị bất động sản đã được bóc tách chuyên sâu bởi A.Rojas (2024) qua trường hợp đại dự án đường hầm đô thị tại Malmö (Thụy Điển). Thông qua việc thiết lập biến điều trị (Treatment) cho các bất động sản nằm trong bán kính 1.000 m từ ga tàu mới, nghiên cứu chỉ ra cơ chế tác động kép: hiệu ứng trực tiếp (cải thiện năng lực kết nối giao thông) và hiệu ứng gián tiếp (thu hút các dự án mới, dịch vụ bán lẻ và tiện ích thương mại về quanh ga) ảnh hưởng lên giá nhà.

Nhóm 3: Dữ liệu phi cấu trúc và tính biến động của thị trường

Một xu hướng mang tính đột phá trong các nghiên cứu gần đây là việc khai thác dữ liệu phi cấu trúc và các yếu tố phi truyền thống nhằm nắm bắt tính biến động của thị trường. N.Hajiyianni & V.Stylianou (2024) lập luận rằng việc chuẩn hóa dữ liệu thông qua đơn giá (giá/m²) là bước tiền xử lý quyết định để loại bỏ nhiễu quy mô và triệt tiêu các giá trị ngoại lai (outliers).

Bên cạnh dữ liệu từ các nền tảng rao vặt, tâm lý thị trường được định hình bởi dòng chảy tin tức báo chí chính thống cũng tác động mạnh đến hành vi người mua. Biktimirov và cộng sự (2024) đã đi đầu khi ứng dụng thuật toán khai phá chủ đề (Topic

Modeling) bằng phương pháp Phân tích ngữ nghĩa tiềm ẩn (LSA) trên 20.000 bài báo để xây dựng Chỉ số tâm thế nhà ở (Housing Sentiment Index - HSI).

Nhóm 4: Các mô hình thực nghiệm và thuật toán áp dụng

Về mặt phương pháp luận, các nghiên cứu quốc tế đang dịch chuyển mạnh mẽ từ hồi quy tuyến tính cổ điển sang các thuật toán học máy (Machine Learning) nhằm tối ưu hóa hàm tổn thất và giảm thiểu sai số dự báo. Ở nhóm mô hình dữ liệu bảng nâng cao, Biktimirov (2024) vận dụng phương pháp Hồi quy dữ liệu bảng kết hợp sai số chuẩn Driscoll-Kraay để xử lý triệt để hiện tượng tự tương quan và phụ thuộc thiết diện ngang. Trong khi đó, Rojas (2024) kết hợp mô hình Khác biệt trong Khác biệt với định giá Hedonic (Hedonic DID), tích hợp hiệu ứng cố định hai chiều (Two-way Fixed Effects) để bóc tách ảnh hưởng của hiệu ứng trực tiếp và gián tiếp của hạ tầng lên giá nhà đất.

Song song với các tiếp cận kinh tế lượng, xu hướng ứng dụng thuật toán nhóm Ensemble Learning cũng ghi nhận nhiều kết quả đột phá. Adetunji (2022) ứng dụng thuật toán Random Forest đạt độ chính xác thực nghiệm cao trên bộ dữ liệu Boston. Tuy nhiên, thực nghiệm tại Bắc Kinh của Truong và cộng sự (2020) cảnh báo rằng dù Random Forest tối ưu rất tốt trên tập huấn luyện, mô hình này lại rất nhạy cảm và dễ rơi vào hiện tượng quá khớp (Overfitting).

Nhằm khắc phục nhược điểm của từng mô hình đơn lẻ, Truong và cộng sự (2020) đã phát triển kiến trúc Học máy xếp chồng (Stacked Generalization) hai cấp, tích hợp đồng thời các thuật toán mạnh bao gồm Random Forest, XGBoost, và LightGBM. Kết quả chứng minh kiến trúc lai (hybrid) này đạt độ chính xác tối ưu nhất trên tập kiểm tra, đồng thời định danh LightGBM là thuật toán có tốc độ hội tụ nhanh nhất và tiết kiệm bộ nhớ hiệu quả nhất trong các bài toán định giá quy mô lớn.

1.2.2.2 Các nghiên cứu trong nước

Tại thị trường bất động sản Việt Nam, việc ứng dụng các mô hình định giá và dự báo tiên tiến cũng đang được các học giả trong nước tiếp cận một cách mạnh mẽ, phản ánh nhiều nét đặc thù của một nền kinh tế đang phát triển. Khi đối chiếu với bốn nhóm nhân tố từ các nghiên cứu quốc tế cốt lõi đã nêu, bức tranh nghiên cứu thực nghiệm tại Việt Nam ghi nhận những bước tiến mới.

Nghiên cứu thực nghiệm của Tran và cộng sự (2024) tại thành phố Vinh khẳng định diện tích căn hộ không chỉ là biến số quyết định quy mô giá trị mà còn đóng góp trọng số lớn nhất vào độ chính xác của mô hình Cây quyết định (GBRT). Xu hướng này tiếp tục được củng cố mạnh mẽ bởi nghiên cứu định giá nhà tại Việt Nam sử dụng thuật toán Ensemble và giải thích bằng SHAP qua bài nghiên cứu “Using Machine Learning Regression Algorithms to Predict House Prices in Viet Nam” của tác giả Minh và cộng sự (2025) khi xác nhận Diện tích (Area) là yếu tố cốt lõi quan trọng nhất chi phối giá nhà, vượt trội hơn các đặc trưng vật lý khác như chiều ngang mặt tiền, số tầng hay số phòng ngủ.

Về yếu tố không gian và dữ liệu phi cấu trúc, bên cạnh việc tích hợp các biến khoảng cách và vĩ mô (mật độ dân số, GRDP) như trong bài của Minh và cộng sự (2025), nghiên cứu của Pham đã phát hiện một quy luật địa lý bất đối xứng. Trong khi Hà Nội bị chi phối bởi diện tích, giá nhà TP.HCM lại bị kiểm soát mạnh bởi vị trí so với các trung tâm mới (Distance to Sub-CBD).

Về kiến trúc mô hình và tính đặc thù pháp lý, các nghiên cứu nội địa đã chứng minh sự vượt trội của nhóm thuật toán Ensemble Learning so với hồi quy truyền thống. Song song đó, biến pháp lý (Legal status) đã được đưa vào mô hình như một đặc trưng bắt buộc nhằm phản ánh lý thuyết chiết khấu rủi ro tương tự như nghiên cứu quốc tế của R.Naz và cộng sự (2024).

1.2.3 Khoảng trống nghiên cứu

Từ bối cảnh thị trường bất động sản TP.HCM và tổng quan các nghiên cứu trong và ngoài nước, có thể thấy bài toán dự báo giá bất động sản đang nhận được sự quan tâm ngày càng lớn nhờ sự phát triển của dữ liệu lớn và các phương pháp học máy. Các nghiên cứu trước đã chỉ ra rằng giá bất động sản chịu ảnh hưởng bởi nhiều nhóm yếu tố khác nhau, từ đặc điểm vật lý, vị trí địa lý, tiện ích xung quanh cho đến thương hiệu chủ đầu tư và đặc trưng dự án, đồng thời khẳng định sự vượt trội của nhóm thuật toán Gradient Boosting so với các phương pháp hồi quy truyền thống trên dữ liệu bảng.

Tuy nhiên, khi nhìn vào bối cảnh thực tế tại Việt Nam, vẫn còn một số điểm chưa được khai thác đầy đủ. Dữ liệu bất động sản trong nước thường phân tán trên nhiều nền tảng trực tuyến với sự khác biệt về cấu trúc, định dạng và chất lượng thông tin, trong khi phần lớn nghiên cứu hiện có vẫn dựa vào dữ liệu từ một nguồn duy nhất. Điều này

cho thấy việc nghiên cứu và xử lý dữ liệu bất động sản đa nguồn vẫn còn nhiều tiềm năng để tiếp tục khai thác.

Bên cạnh đó, dữ liệu thu thập từ các nền tảng trực tuyến tại Việt Nam thường có tỷ lệ thiếu cao ở nhiều thuộc tính phân loại quan trọng, một phần vì thông tin không được điền vào trường có cấu trúc mà nằm rải rác trong nội dung văn bản tự do của tiêu đề và mô tả tin đăng. Việc khai thác tín hiệu từ lớp văn bản này để hỗ trợ quá trình chuẩn hóa và điền khuyết dữ liệu, đặc biệt khi kết hợp với các mô hình ngôn ngữ lớn, là một hướng tiếp cận còn khá mới trong bối cảnh xử lý dữ liệu bất động sản tại Việt Nam.

Ngoài ra, thị trường TP.HCM có đặc điểm phân hóa rõ rệt giữa các phân khúc giá, từ căn hộ bình dân đến bất động sản cao cấp với mức biến động và tập mẫu rất khác nhau. Phần lớn nghiên cứu hiện có tập trung báo cáo hiệu suất tổng thể của mô hình mà chưa đi sâu vào việc mô hình hoạt động như thế nào trong từng phân khúc cụ thể, điều này có thể che khuất những giới hạn thực tế của mô hình khi triển khai trên một thị trường có tính phân hóa cao.

Xuất phát từ những khoảng trống đó, nghiên cứu này hướng đến xây dựng bộ dữ liệu bất động sản đa nguồn tại TP.HCM, ứng dụng pipeline xử lý dữ liệu kết hợp rule-based và AI/LLM để chuẩn hóa các thuộc tính phân loại, đồng thời huấn luyện và đánh giá mô hình với phân tích SHAP nhằm làm rõ các yếu tố ảnh hưởng đến giá theo từng phân khúc thị trường.

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng hệ thống dữ liệu bất động sản tại Thành phố Hồ Chí Minh và ứng dụng các phương pháp học máy nhằm phân tích các yếu tố ảnh hưởng đến giá bất động sản, từ đó xây dựng mô hình dự báo giá hỗ trợ hoạt động phân tích và đánh giá thị trường bất động sản.

1.3.2 Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát nêu trên, nghiên cứu hướng đến thực hiện các mục tiêu cụ thể sau:

- Xây dựng hệ thống thu thập dữ liệu bất động sản từ nhiều nền tảng trực tuyến nhằm tạo ra bộ dữ liệu phục vụ cho bài toán phân tích và dự báo giá bất động sản tại Thành phố Hồ Chí Minh.
- Xây dựng schema dữ liệu chuẩn hóa cho thông tin dự án và tin đăng bất động sản nhằm đảm bảo tính đồng nhất trong quá trình lưu trữ, xử lý và khai thác dữ liệu từ nhiều nguồn khác nhau.
- Thực hiện quá trình chuẩn hóa, làm sạch và hợp nhất dữ liệu để xây dựng bộ dữ liệu tổng hợp có chất lượng cao phục vụ cho việc phân tích và huấn luyện mô hình.
- Tiền xử lý dữ liệu nhằm xử lý dữ liệu thiếu, dữ liệu trùng lặp, dữ liệu bất thường và chuẩn hóa các thuộc tính định tính, định lượng nhằm nâng cao độ tin cậy của dữ liệu đầu vào.
- Xây dựng và trích xuất các đặc trưng quan trọng từ dữ liệu bất động sản nhằm cải thiện khả năng biểu diễn dữ liệu và nâng cao hiệu quả dự báo của mô hình.
- Thực hiện phân tích khám phá dữ liệu nhằm xác định các yếu tố ảnh hưởng đến giá bất động sản và đánh giá mức độ tác động của các đặc trưng trong bộ dữ liệu.
- Xây dựng, huấn luyện và đánh giá các mô hình học máy cho bài toán dự báo giá bất động sản, từ đó lựa chọn mô hình có hiệu suất phù hợp nhất cho dữ liệu nghiên cứu.

1.3.3 Câu hỏi nghiên cứu

Bảng B.1.1: Các câu hỏi nghiên cứu

Mã câu hỏi	Câu hỏi nghiên cứu
RQ1	Mô hình nào phù hợp nhất đối với bộ dữ liệu bất động sản tại Thành phố Hồ Chí Minh trong nghiên cứu?
RQ2	Những yếu tố nào có ảnh hưởng đáng kể đến giá bất động sản tại Thành phố Hồ Chí Minh?

RQ3	Việc khai thác dữ liệu văn bản kết hợp với các mô hình AI/LLM hỗ trợ như thế nào trong quá trình xử lý dữ liệu khuyết và chuẩn hóa các thuộc tính?
RQ4	Hiệu suất của mô hình dự báo thay đổi như thế nào giữa các phân khúc giá khác nhau?
RQ5	Phương pháp weighted ensemble dựa trên cross-validation prediction có giúp cải thiện hiệu suất dự báo so với từng mô hình đơn lẻ hay không?

1.4 Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là giá bất động sản tại khu vực Thành phố Hồ Chí Minh cùng các yếu tố có ảnh hưởng đến giá bán trên thị trường. Nghiên cứu tập trung khai thác và phân tích dữ liệu từ các dự án bất động sản đang mở bán cũng như các tin đăng giao dịch thực tế nhằm tìm ra mối quan hệ giữa giá bất động sản với các đặc trưng về vị trí, quy mô, tiện ích, đặc điểm dự án và thông tin mô tả tin đăng.

Bên cạnh đó, đề tài hướng đến việc ứng dụng các phương pháp học máy để xây dựng mô hình dự báo giá bất động sản dựa trên dữ liệu thu thập được. Thông qua quá trình phân tích dữ liệu và xây dựng mô hình, nghiên cứu kỳ vọng có thể hỗ trợ việc đánh giá xu hướng giá và cung cấp cơ sở tham khảo cho hoạt động phân tích thị trường bất động sản tại Thành phố Hồ Chí Minh.

1.4.2 Phạm vi

Đề tài được thực hiện trên phạm vi thị trường bất động sản tại Thành phố Hồ Chí Minh, bao gồm tất cả các phường có dự án đang mở bán hoặc sắp mở bán. Nghiên cứu không giới hạn ở một loại hình bất động sản cụ thể mà bao gồm nhiều loại hình khác nhau trên thị trường như căn hộ chung cư, nhà phố, biệt thự, shophouse và các sản phẩm thuộc khu đô thị hoặc khu dân cư. Quá trình thu thập dữ liệu được thực hiện trong khoảng thời gian từ ngày 26/04/2026 đến ngày 13/05/2026.

Mặc dù nghiên cứu sử dụng dữ liệu được tổng hợp từ nhiều nguồn khác nhau, đề tài vẫn tồn tại một số giới hạn nhất định. Dữ liệu sử dụng trong nghiên cứu chủ yếu là dữ liệu tin đăng trực tuyến nên giá bán có thể chưa phản ánh hoàn toàn giá giao dịch

thực tế trên thị trường. Một số tin đăng có thể bị trùng lặp, thiếu thông tin hoặc chứa nội dung chưa được chuẩn hóa hoàn toàn. Ngoài ra, nghiên cứu tập trung chủ yếu vào các dự án đang mở bán tại Thành phố Hồ Chí Minh nên chưa phản ánh đầy đủ toàn bộ thị trường bất động sản của khu vực. Một số yếu tố kinh tế vĩ mô như lãi suất, biến động thị trường, chính sách quy hoạch hoặc các yếu tố pháp lý chuyên sâu cũng chưa được đưa vào mô hình do hạn chế về dữ liệu và thời gian thực hiện nghiên cứu.

1.5 Phương pháp nghiên cứu

Nghiên cứu này sử dụng phương pháp học máy có giám sát nhằm xây dựng mô hình dự báo giá bất động sản tại thị trường Thành phố Hồ Chí Minh. Các thuật toán thuộc nhóm Gradient Boosting Decision Trees (GBDT) được lựa chọn làm nền tảng chính cho bài toán hồi quy, kết hợp với phương pháp kết hợp mô hình có trọng số (weighted ensemble) dựa trên cross-validation prediction nhằm cải thiện hiệu quả dự báo. Để giải thích kết quả đầu ra của mô hình và phân tích mức độ ảnh hưởng của từng đặc trưng, nghiên cứu áp dụng phương pháp SHAP.

Về dữ liệu, nghiên cứu thu thập đồng thời hai loại thông tin gồm dữ liệu có cấu trúc (diện tích, giá bán, vị trí, đặc điểm bất động sản) và dữ liệu phi cấu trúc (tiêu đề và mô tả tin đăng). Dữ liệu văn bản được khai thác nhằm trích xuất thêm đặc trưng bổ sung, đồng thời nghiên cứu khảo sát khả năng ứng dụng các mô hình AI/LLM trong việc hỗ trợ xử lý thông tin khuyết và chuẩn hóa thuộc tính.

Về huấn luyện và đánh giá, các mô hình được huấn luyện với chiến lược Cross-Validation nhằm đảm bảo tính ổn định và khả năng tổng quát hóa. Hiệu suất được đánh giá thông qua bộ chỉ số MAE, RMSE, R^2 và MdAPE, bao gồm cả đánh giá tổng thể lẫn phân tích theo từng phân khúc giá nhằm phản ánh đặc điểm phân hóa của thị trường TP.HCM.

1.6 Cấu trúc bài nghiên cứu

Nghiên cứu được tổ chức thành sáu chương với nội dung như sau.

❖ *Chương 1: Giới thiệu*

Trình bày tổng quan về đơn vị kiến tập, bối cảnh hình thành đề tài, xác định vấn đề nghiên cứu, mục tiêu, câu hỏi, phạm vi và phương pháp nghiên cứu.

❖ *Chương 2: Cơ sở lý thuyết*

Trình bày các nền tảng lý thuyết về các thuật toán boosting (LightGBM, XGBoost, CatBoost), kỹ thuật xử lý dữ liệu thiếu, mã hóa biến, xây dựng đặc trưng, ensemble learning, chỉ số đánh giá và giải thích mô hình bằng SHAP.

❖ *Chương 3: Thu thập dữ liệu*

Mô tả quy trình xây dựng pipeline crawl hai cấp độ (dự án và tin đăng) từ ba nền tảng Batdongsan.com.vn, Homedy và Nhadatcanban, cùng quy trình tích hợp dữ liệu.

❖ *Chương 4: Khám phá và tiền xử lý dữ liệu*

Trình bày các bước làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa nhãn phân loại, phân tích khám phá dữ liệu (EDA), feature engineering và mã hóa biến phân loại.

❖ *Chương 5: Xây dựng và đánh giá mô hình*

Trình bày quá trình huấn luyện các mô hình LightGBM, XGBoost, CatBoost và kết hợp ensemble, kết quả đánh giá tổng thể và theo phân khúc giá, cùng phân tích giải thích mô hình bằng SHAP.

❖ *Chương 6: Kết luận*

Tổng kết các kết quả chính, trả lời các câu hỏi nghiên cứu, thảo luận hạn chế và đề xuất hướng phát triển tiếp theo.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Mô hình dự báo

Nghiên cứu này áp dụng ba thuật toán học máy thuộc nhóm Gradient Boosting Decision Trees (GBDT) bao gồm LightGBM, XGBoost và CatBoost. Đây là nhóm thuật toán được xây dựng trên nền tảng học tăng cường (boosting), trong đó các cây quyết định được huấn luyện tuần tự, mỗi cây tập trung vào việc giảm thiểu phần sai số còn lại từ cây trước đó. Các nghiên cứu thực nghiệm trong và ngoài nước đã chứng minh sự vượt trội của nhóm thuật toán này so với hồi quy tuyến tính truyền thống trong bài toán định giá bất động sản (Truong và cộng sự, 2020; Ha và cộng sự, 2025).

2.1.1 LightGBM

LightGBM (Light Gradient Boosting Machine) là thuật toán boosting do Microsoft phát triển, được thiết kế đặc biệt nhằm giải quyết các hạn chế về tốc độ và bộ nhớ của các phương pháp GBDT truyền thống khi xử lý dữ liệu có quy mô lớn và số lượng đặc trưng cao (Ke và cộng sự, 2017).

Điểm khác biệt cốt lõi của LightGBM nằm ở hai kỹ thuật nền tảng. Thứ nhất là Gradient-based One-Side Sampling (GOSS), trong đó thay vì sử dụng toàn bộ tập dữ liệu để tính toán độ lợi thông tin (information gain) tại mỗi bước phân nhánh, thuật toán chỉ giữ lại các mẫu có đang được dự báo kém chính xác nhất và lấy mẫu ngẫu nhiên từ phần còn lại. Cơ chế này giúp rút ngắn đáng kể thời gian huấn luyện mà vẫn bảo toàn phần lớn thông tin quan trọng. Thứ hai là Exclusive Feature Bundling (EFB), kỹ thuật gộp các đặc trưng thưa (sparse features) loại trừ lẫn nhau vào cùng một bundle, từ đó giảm số chiều hiệu quả của dữ liệu đầu vào mà không làm mất thông tin.

Ngoài ra, LightGBM áp dụng chiến lược phát triển cây theo chiều lá (leaf-wise growth) thay vì theo chiều ngang (level-wise) như các thuật toán GBDT thông thường. Chiến lược này ưu tiên mở rộng nhánh lá có độ giảm tổn thất lớn nhất, dẫn đến cây có độ sâu không đều nhưng thường đạt sai số thấp hơn trong cùng số lượng lá.

Trong bài toán định giá bất động sản, LightGBM đã được Truong và cộng sự (2020) xác định là thuật toán có tốc độ hội tụ nhanh nhất và tiết kiệm bộ nhớ hiệu quả nhất trong kiến trúc Stacked Generalization khi thực nghiệm trên dữ liệu nhà ở tại Bắc Kinh. Ha và cộng sự (2025) cũng ghi nhận LightGBM cho hiệu suất cạnh tranh trên dữ

liệu bất động sản Việt Nam với thời gian huấn luyện vượt trội so với các thuật toán cùng nhóm.

2.1.2 XGBoost

XGBoost (Extreme Gradient Boosting) là thuật toán boosting do Chen và Guestrin (2016) phát triển, trở thành một trong những công cụ học máy được ứng dụng rộng rãi nhất trong các bài toán hồi quy và phân loại nhờ vào sự kết hợp giữa hiệu suất dự báo cao.

Về mặt lý thuyết, XGBoost tối ưu hóa hàm mục tiêu bao gồm hai thành phần: hàm tổn thất (loss function) đo lường sai số dự báo trên tập huấn luyện và thành phần chính quy hóa (regularization term) kiểm soát độ phức tạp của cây. Cụ thể, hàm mục tiêu của XGBoost có dạng:

$$L = \sum_i^n l(\hat{y}_i, y_i) + \sum_k^n \Omega(f_k)$$

Trong đó $\Omega(f) = \gamma T + \frac{1}{2} \lambda ||w||^2$ với T là số lá của cây và w là trọng số các lá. Thành phần chính quy hóa này là điểm khác biệt then chốt so với các thuật toán GBDT truyền thống, giúp XGBoost kiểm soát hiện tượng quá khớp một cách tường minh ngay trong quá trình xây dựng cây.

XGBoost cũng hỗ trợ xử lý giá trị thiếu tích hợp (built-in missing value handling), trong đó thuật toán tự học hướng phân nhánh tối ưu cho các mẫu có giá trị thiếu dựa trên dữ liệu huấn luyện, thay vì yêu cầu imputation thủ công trước khi huấn luyện. Đây là đặc điểm có giá trị thực tiễn cao trong bối cảnh dữ liệu bất động sản thu thập từ các nền tảng trực tuyến thường tồn tại nhiều trường thông tin không đầy đủ.

Trong lĩnh vực định giá bất động sản, XGBoost đã được Phạm (2026) áp dụng thành công trên dữ liệu căn hộ tại Hà Nội và TP.HCM, đồng thời kết hợp với phân tích SHAP để giải thích mức độ đóng góp của từng đặc trưng. Tuy nhiên, Truong và cộng sự (2020) cũng lưu ý rằng XGBoost đòi hỏi quá trình tinh chỉnh siêu tham số kỹ lưỡng để đạt hiệu suất tối ưu, đặc biệt trên các bộ dữ liệu có mức độ nhiễu cao.

2.1.3 CatBoost

CatBoost (Categorical Boosting) là thuật toán GBDT do Yandex phát triển, được thiết kế với trọng tâm đặc biệt vào khả năng xử lý dữ liệu phân loại (categorical features)

một cách tự nhiên mà không yêu cầu mã hóa thủ công trước khi huấn luyện (Prokhorenkova và cộng sự, 2018).

Đóng góp kỹ thuật cốt lõi của CatBoost là cơ chế Ordered Target Encoding tích hợp sẵn trong quá trình huấn luyện. Thay vì tính toán target encoding trên toàn bộ tập dữ liệu như các phương pháp truyền thống - vốn dễ gây ra hiện tượng rò rỉ dữ liệu (data leakage) - CatBoost sử dụng một thứ tự ngẫu nhiên giả (random permutation) của các mẫu, trong đó giá trị encoding của mẫu thứ i chỉ được tính dựa trên các mẫu xuất hiện trước nó trong thứ tự đó. Cơ chế này đảm bảo tính không thiên lệch của encoding và cải thiện khả năng tổng quát hóa của mô hình trên tập kiểm tra.

Bên cạnh đó, CatBoost áp dụng chiến lược Ordered Boosting nhằm giải quyết hiện tượng target leakage trong quá trình xây dựng cây, đồng thời sử dụng cây đối xứng (oblivious trees) - trong đó cùng một điều kiện phân nhánh được áp dụng đồng nhất cho toàn bộ một tầng của cây - giúp tăng tốc độ dự báo và giảm nguy cơ overfitting.

Trong bối cảnh dữ liệu bất động sản tại Việt Nam, CatBoost có lợi thế đặc biệt khi dữ liệu chứa nhiều trường phân loại có số lượng nhãn lớn (high-cardinality) như tên dự án, quận/huyện, phường/xã hay loại hình bất động sản. Việc xử lý tự động các trường này không chỉ đơn giản hóa quy trình tiền xử lý mà còn giúp mô hình khai thác thông tin từ các biến phân loại một cách hiệu quả hơn so với One-Hot Encoding thông thường trên các tập dữ liệu thưa.

2.2 Kỹ thuật xử lý dữ liệu

2.2.1 Xử lý dữ liệu thiếu

2.2.1.1 Cơ chế Missing Completely At Random (MCAR), Missing At Random (MAR)

❖ Cơ chế Missing Completely At Random (MCAR)

Khuyết hoàn toàn ngẫu nhiên (Missing Completely At Random - MCAR) là cơ chế dữ liệu thiếu xảy ra khi xác suất một giá trị bị khuyết không phụ thuộc vào bất kỳ biến nào trong tập dữ liệu, bao gồm cả các giá trị đã quan sát và chưa quan sát. Trong trường hợp này, dữ liệu bị thiếu xuất hiện một cách hoàn toàn ngẫu nhiên, không tồn tại yếu tố hệ thống làm cho một nhóm dữ liệu cụ thể dễ bị thiếu hơn nhóm khác. Vì vậy, phần dữ liệu còn lại vẫn giữ được tính đại diện cho tổng thể nghiên cứu ban đầu và không tạo ra sai lệch đáng kể trong phân tích thống kê.

❖ *Cơ chế Missing At Random (MAR)*

Khuyết ngẫu nhiên (Missing At Random - MAR) là cơ chế dữ liệu thiếu xảy ra khi xác suất một giá trị bị khuyết có liên quan đến các biến đã được quan sát trong tập dữ liệu, nhưng không phụ thuộc trực tiếp vào chính giá trị bị thiếu sau khi đã kiểm soát các biến quan sát đó. Nói cách khác, việc thiếu dữ liệu không hoàn toàn ngẫu nhiên mà phụ thuộc vào một số đặc điểm đã biết của đối tượng nghiên cứu. Ví dụ, trong khảo sát thu nhập, nhóm người trẻ tuổi có thể ít trả lời câu hỏi về mức lương hơn nhóm người lớn tuổi; khi đó, xác suất thiếu dữ liệu phụ thuộc vào biến “độ tuổi” đã được quan sát. Trong cơ chế MAR, dữ liệu vẫn có thể được xử lý hiệu quả thông qua các phương pháp nội suy (imputation) hoặc mô hình hóa dựa trên các biến liên quan đã quan sát được.

2.2.1.2 Các phương pháp Imputation

❖ *Rule-based imputation*

Gán khuyết dựa trên quy tắc (Rule-based imputation) là phương pháp xử lý dữ liệu thiếu bằng cách thay thế giá trị khuyết thông qua các quy tắc logic được xây dựng từ mối quan hệ giữa các thuộc tính trong tập dữ liệu. Phương pháp này thường hoạt động theo cơ chế “IF-THEN”, trong đó hệ thống kiểm tra điều kiện của dữ liệu và tự động gán giá trị phù hợp khi phát hiện dữ liệu thiếu hoặc bất thường. Rule-based imputation thường được áp dụng kết hợp với quy trình phát hiện lỗi dữ liệu nhằm tự động hóa quá trình làm sạch và đảm bảo tính nhất quán của tập dữ liệu.

❖ *Contextual AI imputation*

Gán khuyết AI dựa trên ngữ cảnh (Contextual AI imputation) là một hướng tiếp cận hiện đại sử dụng khả năng suy luận ngữ nghĩa và tri thức tổng quát của các mô hình ngôn ngữ lớn (Large Language Models - LLMs) để xử lý dữ liệu bị thiếu, thay vì chỉ dựa trên các phương pháp thống kê truyền thống. Phương pháp này khai thác thông tin ngữ cảnh từ các thuộc tính liên quan, chẳng hạn như tiêu đề, mô tả văn bản hoặc các trường dữ liệu đã quan sát được, nhằm suy luận và điền giá trị phù hợp cho các thuộc tính còn thiếu. Nhờ khả năng hiểu ngôn ngữ tự nhiên và nhận diện mối quan hệ ngữ nghĩa giữa các thuộc tính, Contextual AI imputation đặc biệt hiệu quả đối với dữ liệu phi cấu trúc hoặc dữ liệu bảng có chứa nhiều trường mô tả văn bản.

❖ *Mean/Median imputation*

Gán khuyết bằng số trung vị (Median imputation) là phương pháp thay thế các giá trị bị thiếu bằng giá trị trung vị của thuộc tính sau khi dữ liệu được sắp xếp theo thứ tự tăng dần. Đây là một kỹ thuật gán khuyết đơn phổ biến và thường được sử dụng thay cho trung bình trong các tập dữ liệu có phân phối lệch hoặc chứa nhiều giá trị ngoại lai. Do trung vị ít bị ảnh hưởng bởi các giá trị cực đoan, phương pháp này đặc biệt phù hợp với các biến liên tục như giá nhà, thu nhập hoặc diện tích bất động sản. Median imputation giúp duy trì tính ổn định của phân phối dữ liệu và hạn chế sai lệch so với phương pháp gán khuyết bằng trung bình.

❖ *Constant imputation*

Gán khuyết bằng giá trị hằng số (Constant imputation) là phương pháp thay thế tất cả các giá trị bị thiếu trong một thuộc tính bằng một giá trị cố định được xác định trước. Đây là một dạng kỹ thuật gán khuyết đơn (single imputation) có cách triển khai đơn giản và được sử dụng phổ biến trong giai đoạn tiền xử lý dữ liệu. Đối với dữ liệu số, giá trị thay thế thường là 0 hoặc một giá trị mặc định phù hợp; trong khi với dữ liệu dạng văn bản hoặc phân loại, hệ thống có thể sử dụng các nhãn như “Unknown”, “Missing” hoặc “Chưa rõ”. Phương pháp này giúp duy trì kích thước tập dữ liệu và đảm bảo mô hình xử lý được các trường hợp thiếu dữ liệu, tuy nhiên có thể làm thay đổi phân phối dữ liệu nếu được áp dụng không phù hợp.

2.2.2 Mã hóa biến phân loại

2.2.2.1 One-Hot Encoding

One-hot Encoding là phương pháp chuyển đổi các biến phân loại thành định dạng phù hợp làm đầu vào cho các mô hình học máy để cải thiện khả năng dự đoán. Phương pháp này tạo ra các cột nhị phân mới cho từng hạng mục khác nhau của một biến. Mỗi cột tương ứng với một hạng mục cụ thể, trong đó giá trị 1 biểu thị sự xuất hiện của hạng mục đó, còn giá trị 0 cho biết hạng mục không xuất hiện.

Color		Color	Red	Green	Blue
Red	→	Red	1	0	0
Green		Green	0	1	0
Blue		Blue	0	0	1

Hình B.2.1: Ví dụ về One-hot Encoding (Nguồn: Datacamp)

2.2.2.2 Target Encoding

Target Encoding là phương pháp mã hóa biến phân loại bằng cách thay thế mỗi hạng mục bằng giá trị thống kê của biến mục tiêu tương ứng, phổ biến nhất là giá trị trung bình của biến mục tiêu trong từng nhóm (Micci-Barreca, 2001).

Đối với bài toán hồi quy, giả sử một biến phân loại c có n_c quan sát với giá trị trung bình mục tiêu là $\bar{y}_c$, giá trị mã hóa được xác định như sau:

$$TE_c = \frac{n_c * \bar{y}_c + \alpha * \overline{y_{global}}}{n_c + \alpha}$$

Trong đó:

- $\bar{y}_c$: giá trị trung bình của biến mục tiêu trong nhóm c
- $\overline{y_{global}}$: giá trị trung bình toàn bộ tập dữ liệu
- n_c : số lượng quan sát thuộc nhóm c
- α : hệ số smoothing giúp giảm hiện tượng overfitting

Cơ chế smoothing giúp cân bằng giữa giá trị trung bình của từng nhóm và giá trị trung bình toàn cục. Với các nhóm có ít quan sát, giá trị mã hóa sẽ gần với trung bình toàn cục hơn nhằm hạn chế nhiễu.

So với One-hot Encoding, Target Encoding đặc biệt hiệu quả đối với các biến có số lượng hạng mục lớn như tên dự án, phòng hoặc chủ đầu tư. Phương pháp này giúp giảm mạnh số chiều dữ liệu và thường cải thiện hiệu suất dự báo đối với các mô hình boosting như LightGBM, XGBoost và CatBoost. Tuy nhiên, nếu được áp dụng trực tiếp trên toàn bộ tập huấn luyện, Target Encoding có thể gây ra hiện tượng target leakage do thông tin của biến mục tiêu bị rò rỉ vào quá trình huấn luyện.

2.2.3 Xây dựng đặc trưng

Sau khi thu thập và làm sạch dữ liệu thô, bước tiếp theo là xây dựng các đặc trưng (feature engineering) nhằm gia tăng khả năng biểu diễn thông tin của dữ liệu đầu vào, từ đó cải thiện hiệu suất của mô hình học máy. Nghiên cứu này áp dụng hai kỹ thuật chính: tạo đặc trưng tương tác (feature interaction) và biến đổi đặc trưng (feature transformation).

2.2.3.1 Đặc trưng tương tác (Feature Interaction)

Đặc trưng tương tác là kỹ thuật xây dựng các biến mới bằng cách kết hợp hai hoặc nhiều đặc trưng gốc thông qua các phép toán số học, nhằm nắm bắt mối quan hệ phi tuyến giữa các biến mà các mô hình học máy đơn thuần khó có thể tự học được từ từng đặc trưng riêng lẻ (Truong và cộng sự, 2020). Trong bài toán định giá bất động sản, các biến đơn lẻ như diện tích hay vị trí thường không phản ánh đầy đủ giá trị tài sản nếu xét độc lập, trong khi sự kết hợp giữa chúng lại mang ý nghĩa kinh tế rõ rệt hơn.

Một dạng đặc trưng tương tác phổ biến trong nghiên cứu định giá là tích của hai biến liên tục (multiplicative interaction). Ví dụ điển hình là tích giữa diện tích và số tầng, phản ánh tổng không gian sử dụng có thể khai thác được của một bất động sản. Một ví dụ khác là tích giữa diện tích và biến vị trí (được mã hóa số), giúp mô hình nhận diện rằng cùng một diện tích nhưng ở khu vực trung tâm sẽ có giá trị khác hẳn so với khu vực ngoại thành - điều mà từng biến đơn lẻ không thể biểu diễn được.

Ngoài ra, đặc trưng tương tác dạng tỷ lệ (ratio interaction) cũng được áp dụng rộng rãi. Hajiyianni và Stylianou (2024) nhấn mạnh rằng việc chuẩn hóa giá theo đơn vị diện tích (giá/m²) là bước tiền xử lý quyết định nhằm loại bỏ nhiễu quy mô và triệt tiêu các giá trị ngoại lai, đồng thời tạo ra một đặc trưng tương tác có khả năng so sánh trực tiếp giữa các bất động sản thuộc nhiều phân khúc khác nhau. Tương tự, tỷ lệ giữa số phòng ngủ và diện tích phản ánh mật độ công năng sử dụng - một chỉ số gián tiếp về hiệu quả bố trí không gian của căn hộ.

Trong nghiên cứu này, kỹ thuật feature interaction được áp dụng nhằm tạo thêm các biến phản ánh mối quan hệ giữa quy mô, vị trí và công năng sử dụng của bất động sản, từ đó cung cấp cho mô hình học máy những biểu diễn dữ liệu phong phú hơn so với tập đặc trưng gốc.

2.2.3.2 Biến đổi đặc trưng (Feature Transformation)

Biến đổi đặc trưng là quá trình áp dụng các hàm toán học lên các biến gốc nhằm điều chỉnh phân phối, thu hẹp khoảng biến thiên hoặc làm nổi bật mối quan hệ giữa đặc trưng và biến mục tiêu, từ đó cải thiện khả năng học của mô hình (Géron, 2022).

Biến đổi logarithm là kỹ thuật được sử dụng phổ biến nhất trong bài toán định giá bất động sản. Giá nhà và diện tích thường có phân phối lệch phải (right-skewed) với một số giá trị cực lớn kéo dài đuôi phân phối, gây ảnh hưởng tiêu cực đến quá trình tối

ưu hóa hàm mất mát. Việc áp dụng biến đổi $\log(1 + x)$ giúp nén khoảng giá trị, đưa phân phối về dạng gần chuẩn hơn và giảm thiểu tác động của các giá trị ngoại lai. Hajiyianni và Stylianou (2024) khẳng định rằng biến đổi logarithm trên biến giá là bước cần thiết để ổn định phương sai và cải thiện độ chính xác của mô hình hồi quy trong bài toán định giá nhà ở.

Biến đổi khoảng cách (distance transformation) là dạng biến đổi đặc thù trong bài toán bất động sản, trong đó tọa độ địa lý thô (latitude, longitude) được chuyển đổi thành khoảng cách Euclidean hoặc Haversine từ bất động sản đến các điểm tham chiếu quan trọng như trung tâm thành phố, ga metro, trường học hay bệnh viện. Hoang và cộng sự (2024) đã chứng minh rằng các biến khoảng cách dạng này mang khả năng biểu diễn không gian cao hơn so với tọa độ thô, vì chúng phản ánh trực tiếp chi phí tiếp cận và lợi thế vị trí của bất động sản. Rojas (2024) cũng xác nhận tác động đáng kể của khoảng cách đến ga tàu lên giá nhà trong nghiên cứu về hạ tầng giao thông tại Malmö, Thụy Điển.

Trong nghiên cứu này, biến đổi logarithm được áp dụng lên biến giá và diện tích nhằm xử lý hiện tượng lệch phân phối, trong khi biến đổi khoảng cách được sử dụng để chuyển hóa tọa độ địa lý thành các biến phản ánh khả năng tiếp cận tiện ích và hạ tầng - nhóm yếu tố được xác định là có ảnh hưởng đáng kể đến mặt bằng giá bất động sản tại TP.HCM.

2.3 Kỹ thuật kết hợp mô hình

2.3.1 Khái niệm và nguyên lý

Ensemble learning là phương pháp kết hợp nhiều mô hình học máy nhằm tạo ra một mô hình dự báo có độ chính xác và khả năng tổng quát hóa tốt hơn so với từng mô hình đơn lẻ. Theo Dietterich (2000), hiệu quả của ensemble learning đến từ việc kết hợp các mô hình có sai số khác nhau để giảm variance, giảm bias hoặc tăng khả năng khái quát hóa của hệ thống dự báo. Ý tưởng cốt lõi của phương pháp này dựa trên nguyên lý “trí tuệ tập thể”, trong đó nhiều mô hình độc lập khi được kết hợp hợp lý có thể cho kết quả ổn định hơn so với một mô hình riêng lẻ.

Trong thực tế, mỗi thuật toán học máy thường học các pattern khác nhau từ dữ liệu. Một số mô hình mạnh về quan hệ phi tuyến, trong khi các mô hình khác có khả

năng chống overfitting hoặc tổng quát hóa tốt hơn. Vì vậy, việc kết hợp nhiều mô hình có tính đa dạng (diversity) thường giúp cải thiện hiệu suất dự báo đáng kể.

Ensemble learning hiện được ứng dụng rộng rãi trong các bài toán dự báo thực tế và các cuộc thi dữ liệu như Kaggle, đặc biệt với dữ liệu dạng bảng (tabular data).

2.3.2 Các phương pháp ensemble phổ biến

❖ *Bagging*

Bagging (Bootstrap Aggregating) được giới thiệu bởi Breiman (1996), là phương pháp huấn luyện nhiều mô hình độc lập trên các tập dữ liệu bootstrap được lấy mẫu ngẫu nhiên có hoàn lại từ tập huấn luyện ban đầu. Kết quả cuối cùng được tổng hợp bằng trung bình (đối với hồi quy) hoặc voting (đối với phân loại).

Bagging giúp giảm phương sai (variance) của mô hình và hạn chế overfitting. Random Forest là ví dụ điển hình của phương pháp bagging.

❖ *Boosting*

Boosting là phương pháp huấn luyện tuần tự nhiều mô hình yếu (weak learners), trong đó mỗi mô hình mới tập trung học các mẫu mà các mô hình trước dự báo chưa tốt. Friedman (2001) cho rằng boosting hoạt động bằng cách tối ưu dần hàm mất mát thông qua việc cộng tuần tự các weak learners.

Khác với bagging, boosting chủ yếu giúp giảm bias và thường đạt hiệu suất rất cao trên dữ liệu có cấu trúc bảng. Các thuật toán nổi bật thuộc nhóm này bao gồm XGBoost, LightGBM và CatBoost.

❖ *Stacking*

Stacking được đề xuất bởi Wolpert (1992), là phương pháp ensemble nhiều tầng, trong đó các mô hình cơ sở (base models) được huấn luyện ở tầng đầu tiên, sau đó dự báo của các mô hình này được sử dụng làm đầu vào cho một mô hình thứ hai gọi là meta-learner.

Meta-learner sẽ học cách kết hợp dự báo từ các base models để tạo ra kết quả cuối cùng. Phương pháp này cho phép khai thác ưu điểm của nhiều mô hình khác nhau nhưng có nguy cơ overfitting nếu không sử dụng kỹ thuật cross-validation prediction phù hợp.

❖ *Weighted Averaging*

Weighted averaging là phương pháp ensemble đơn giản nhưng hiệu quả, trong đó dự báo cuối cùng được tính bằng trung bình có trọng số của nhiều mô hình:

$$\hat{y} = \sum_{i=1}^n \frac{w_i}{\hat{y}_i}$$

Trong đó, w_i là trọng số của mô hình thứ i , thỏa mãn: $\sum_{i=1}^n w_i = 1, w_i \geq 0$

Phương pháp này có ưu điểm là dễ triển khai, ít nguy cơ overfitting hơn stacking và thường mang lại cải thiện hiệu suất nếu các mô hình thành phần có sai số khác nhau.

2.4 Chỉ số đánh giá

Để đánh giá toàn diện hiệu suất dự báo của mô hình, nghiên cứu sử dụng năm chỉ số gồm MAE, MedAE, RMSE, R^2 và MdAPE. Các chỉ số này phản ánh cả mức sai số tuyệt đối, sai số tương đối cũng như khả năng giải thích biến thiên của dữ liệu.

2.4.1 MAE

MAE (Mean Absolute Error) là sai số tuyệt đối trung bình giữa giá trị dự đoán và giá trị thực tế, được tính trên không gian giá trị thực (real-space) với đơn vị triệu đồng trên một mét vuông (triệu VNĐ/m²). Công thức xác định của MAE như sau:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Về mặt đo lường, MAE phản ánh độ lệch tuyệt đối trung bình giữa dự báo của mô hình và giá trị thực. Do được biểu diễn cùng đơn vị với biến mục tiêu, chỉ số này có tính trực quan trong thực tiễn ứng dụng, đặc biệt phù hợp với các bài toán định giá tài sản. Một ưu điểm quan trọng của MAE là khả năng chịu đựng các giá trị ngoại lai (outlier) tốt hơn so với các chỉ số dựa trên bình phương sai số, bởi lẽ mọi sai số đều được xử lý tuyến tính trong quá trình tính tổng.

2.4.2 MedAE

MedAE (Median Absolute Error) là trung vị của dãy các sai số tuyệt đối giữa giá trị dự báo và giá trị thực tế. Khác với MAE sử dụng giá trị trung bình, MedAE xác định giá trị ở vị trí trung tâm của phân bố sai số sau khi sắp xếp theo thứ tự tăng dần:

$$MedAE = median(|y_1 - \hat{y}_1|, |y_2 - \hat{y}_2|, \dots, |y_n - \hat{y}_n|)$$

Trong thực nghiệm, MedAE cung cấp một ước lượng về mức sai số điển hình của mô hình, không bị ảnh hưởng bởi các quan sát có sai số cực lớn ở phần đuôi phân bố. Tính chất bền vững (robustness) này làm cho MedAE trở thành thước đo bổ sung quan trọng cho MAE, đặc biệt trong các bối cảnh dữ liệu có phương sai thay đổi hoặc tồn tại

các giá trị dị thường. Khi MedAE nhỏ hơn đáng kể so với MAE, có thể kết luận rằng phân phối của sai số có đuôi phải dài, tức là tồn tại một bộ phận không lớn các quan sát có mức sai số rất cao.

2.4.3 RMSE

RMSE (Root Mean Squared Error) là căn bậc hai của trung bình bình phương các sai số giữa giá trị dự báo và giá trị thực tế. Công thức xác định của RMSE như sau:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

RMSE được chọn để đánh giá mức độ nghiêm trọng của các dự báo kém chính xác. Trong bối cảnh định giá bất động sản, một sai số cực lớn (ví dụ dự báo căn hộ 500 triệu/m² thành 200 triệu/m²) có thể gây ra những quyết định đầu tư sai lầm nghiêm trọng. RMSE giúp phát hiện và phản ánh đúng mức độ của những sai số lớn này. Kết hợp giữa MAE và RMSE, nếu RMSE lớn hơn MAE đáng kể, đó là dấu hiệu cho thấy mô hình có một số dự báo sai rất lớn (outlier trong sai số).

2.4.4 R^2

R^2 (Coefficient of Determination), hay còn gọi là hệ số xác định, đo lường tỷ lệ phương sai của biến phụ thuộc được giải thích bởi mô hình hồi quy. Công thức tính:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Giá trị R^2 càng gần 1 cho thấy mô hình càng phù hợp với dữ liệu, trong khi R^2 gần 0 cho thấy mô hình không tốt hơn việc dự đoán bằng giá trị trung bình. Trong nghiên cứu này, R^2 được tính trên real-space cho đánh giá tổng thể và trên log-space cho phân tích theo phân khúc nhằm hạn chế ảnh hưởng khuếch đại sai số ở các phân khúc giá cao.

2.4.5 MdAPE

MdAPE (Median Absolute Percentage Error) là trung vị của sai số phần trăm tuyệt đối giữa giá trị dự đoán và thực tế.

$$MdAPE = median\left(\frac{|y_1 - \hat{y}_1|}{|y_1|} * 100\%\right)$$

Nghiên cứu lựa chọn chỉ số này vì đây là chỉ số cho phép đánh giá sai số theo góc nhìn tương đối, không phụ thuộc đơn vị tiền tệ, đồng thời phù hợp để so sánh hiệu suất mô hình giữa các phân khúc giá khác nhau. Điều này rất quan trọng, như trong trường hợp một sai số 20 triệu/ m^2 là rất lớn đối với căn hộ giá 50 triệu/ m^2 (40% sai số), nhưng lại rất nhỏ đối với căn hộ giá 500 triệu/ m^2 (chỉ 4% sai số).

2.5 Kỹ thuật giải thích mô hình

Để giải thích kết quả dự báo, nghiên cứu này sử dụng phương pháp SHAP (SHapley Additive exPlanations) do Lundberg và Lee đề xuất năm 2017 dựa trên nền tảng lý thuyết trò chơi hợp tác, cụ thể là khái niệm giá trị Shapley (Shapley value) từ công trình của nhà kinh tế học Lloyd Shapley (1953). Đây là một kỹ thuật giải thích mô hình cho phép phân tích cả ở cấp độ toàn cục (đặc trưng nào quan trọng nhất) và cấp độ cục bộ (tại sao một quan sát cụ thể lại có dự báo như vậy).

❖ *Nền tảng lý thuyết trò chơi*

Trong lý thuyết trò chơi, xét một tình huống có N người chơi cùng tham gia một trò chơi và nhận được tổng phần thưởng là $v(N)$. Câu hỏi đặt ra là: làm thế nào để phân chia phần thưởng một cách công bằng dựa trên đóng góp thực tế của mỗi người? Giá trị Shapley giải quyết bài toán này bằng cách xem xét mọi thứ tự có thể có của các người chơi khi họ lần lượt gia nhập nhóm, tính đóng góp biên (marginal contribution) của mỗi người ở mỗi thứ tự, sau đó lấy trung bình có trọng số.

Công thức toán học của giá trị Shapley cho người chơi i như sau:

$$\phi_i = \sum_{S \subseteq \substack{N \\ i \notin S}} \frac{|S|! * (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Trong đó:

- N là tập hợp tất cả người chơi
- S là một tập con của N không chứa i
- $v(S \cup \{i\}) - v(S)$ là đóng góp biên của người chơi i khi gia nhập nhóm S
- $|S|! * (|N| - |S| - 1)!$ là trọng số, thể hiện số cách sắp xếp thứ tự tương ứng

❖ *Ứng dụng SHAP trong giải thích dự báo*

Lundberg và Lee (2017) đã đưa giá trị Shapley vào lĩnh vực học máy bằng cách định nghĩa lại các thành phần như sau:

- "Người chơi" là các đặc trưng đầu vào (features)
- "Trò chơi" là bài toán dự báo cho một quan sát cụ thể
- "Phần thưởng" là chênh lệch giữa dự báo của mô hình cho quan sát đó và giá trị dự báo trung bình trên toàn bộ tập dữ liệu

Khi đó, giá trị SHAP của một đặc trưng chính là đóng góp trung bình có trọng số của đặc trưng đó vào sự chênh lệch nói trên. Ví dụ, nếu mô hình dự báo giá trung bình của toàn bộ dữ liệu là 100 triệu đồng/m², và một căn hộ cụ thể có dự báo là 150 triệu đồng/m² (chênh lệch +50 triệu), SHAP sẽ phân bổ +50 triệu này thành đóng góp của từng đặc trưng, chẳng hạn: diện tích đóng góp +30 triệu (diện tích nhỏ thường có giá/m² cao hơn), vị trí đóng góp +25 triệu, khoảng cách đến trung tâm đóng góp -5 triệu (do xa trung tâm). Tổng các đóng góp này luôn bằng đúng chênh lệch dự báo so với giá trung bình.

❖ *Ba tính chất quan trọng của SHAP*

SHAP được đánh giá cao vì đảm bảo ba tính chất lý thuyết nền tảng mà nhiều phương pháp giải thích khác không có được

(1) Tính nhất quán (Consistency): Nếu một mô hình thay đổi sao cho đóng góp của một đặc trưng tăng lên (hoặc không giảm) trong mọi điều kiện, thì giá trị SHAP của đặc trưng đó cũng tăng (hoặc không giảm) tương ứng. Tính chất này đảm bảo rằng việc so sánh tầm quan trọng của các đặc trưng giữa các mô hình khác nhau hoặc giữa các phiên bản huấn luyện khác nhau vẫn có ý nghĩa thống kê.

(2) Tính cộng gộp (Additivity): Tổng các giá trị SHAP của tất cả các đặc trưng trong một quan sát bằng đúng chênh lệch giữa dự báo của mô hình cho quan sát đó và giá trị dự báo trung bình trên toàn bộ tập dữ liệu. Quan hệ này được biểu diễn qua công thức:

$$f(x) = E[f(X)] + \sum_{i=1}^M \phi_i$$

Trong đó $f(x)$ là dự báo cho quan sát x , $E[f(X)]$ là dự báo trung bình trên toàn bộ dữ liệu, và ϕ_i là giá trị SHAP của đặc trưng thứ i . Tính chất này làm cho kết quả giải thích trở nên trực quan, minh bạch và có thể kiểm chứng một cách định lượng.

(3) Tính không có tác nhân giả (Dummy property): Nếu một đặc trưng hoàn toàn không ảnh hưởng đến dự báo của mô hình (ví dụ một cột chứa giá trị ngẫu nhiên không

mang thông tin), giá trị SHAP của đặc trưng đó sẽ bằng 0. Tính chất này đảm bảo các đặc trưng nhiễu không làm sai lệch kết quả phân tích tầm quan trọng.

❖ *TreeExplainer: Thuật toán SHAP chuyên biệt cho mô hình cây*

SHAP có nhiều biến thể thuật toán tùy thuộc vào kiến trúc mô hình cần giải thích. Phiên bản tổng quát nhất là KernelSHAP, có thể áp dụng cho bất kỳ loại mô hình nào (model-agnostic), nhưng có độ phức tạp tính toán $O(2^M)$ với M là số đặc trưng - tăng theo lũy thừa và sẽ khó khả thi nếu số lượng đặc trưng lớn.

Để khắc phục hạn chế đó, Lundberg và cộng sự (2018) đã phát triển TreeExplainer - một thuật toán SHAP chuyên biệt cho các mô hình dựa trên cây quyết định, bao gồm Random Forest, LightGBM, XGBoost và CatBoost. TreeExplainer khai thác cấu trúc phân nhánh đệ quy của cây để đạt độ phức tạp $O(TLD^2)$, trong đó T là số cây, L là số lá trung bình trên mỗi cây, và D là độ sâu tối đa của cây. Với các mô hình GBDT thực tế, độ phức tạp này cho phép tính toán giá trị SHAP trên toàn bộ tập dữ liệu hàng chục nghìn quan sát trong thời gian chấp nhận được. Đặc biệt, TreeExplainer tính toán giá trị SHAP chính xác (exact) thay vì xấp xỉ như KernelSHAP, nhờ đó đảm bảo kết quả giải thích đáng tin cậy hơn.

CHƯƠNG 3: THU THẬP DỮ LIỆU

3.1 Nguồn dữ liệu

Dữ liệu bất động sản được thu thập từ các nền tảng trực tuyến phổ biến tại Việt Nam, nơi tập trung lượng lớn tin đăng mua bán và cho thuê căn hộ, nhà đất. Nghiên cứu sử dụng ba nguồn dữ liệu chính: batdongsan.com.vn, homedy.com và nhadatcanban.com. Dữ liệu được thu thập ở hai cấp độ khác nhau tùy theo đặc thù của từng nguồn:


- Dữ liệu cấp dự án: Chỉ được thu thập từ batdongsan.com.vn.
- Dữ liệu cấp tin đăng: Được thu thập từ cả ba nguồn batdongsan.com.vn, homedy.com, nhadatcanban.com.

3.2 Quy trình thu thập dữ liệu

3.2.1 Thu thập dữ liệu cấp dự án

Dữ liệu cấp dự án bất động sản là nền tảng quan trọng cho các mô hình phân tích và dự báo giá trị bất động sản tại TP.HCM. Tuy nhiên, hiện chưa có cơ sở dữ liệu mở nào cung cấp thông tin đầy đủ và có cấu trúc về các dự án bất động sản tại Việt Nam. Do đó, nhóm tiến hành xây dựng pipeline thu thập dữ liệu tự động từ cổng thông tin batdongsan.com.vn.

Quy trình tổng thể được thiết kế theo hai giai đoạn chính: (1) Thu thập dữ liệu thô bằng kỹ thuật web crawling, và (2) Kiểm định tính chính xác, làm sạch và bổ sung dữ liệu khuyết. Hai giai đoạn này phối hợp với nhau nhằm tạo ra bộ dữ liệu có tính chính xác cao nhất có thể.



Hình B.3.1. Tổng quan quy trình thu thập và xử lý dữ liệu cấp dự án

3.2.1.1 Cấu hình

Trang web batdongsan.com.vn sử dụng JavaScript để render nội dung động, do đó không thể thu thập dữ liệu bằng các thư viện HTTP thuần túy như requests. Selenium được lựa chọn để điều khiển một phiên Chrome thực tế, kết nối qua giao thức debugger:

```
chrome_options.add_experimental_option("debuggerAddress",
                                         "127.0.0.1:9222")

driver = webdriver.Chrome(options=chrome_options)
```

Phương pháp này cho phép kết nối vào một phiên Chrome đang chạy sẵn (thay vì khởi tạo phiên mới), giúp duy trì phiên đăng nhập và các cookie cần thiết, đồng thời giảm thiểu khả năng bị phát hiện là bot. Ngoài ra, để giảm nguy cơ bị chặn IP, hệ thống áp dụng các cơ chế:

- Delay ngẫu nhiên giữa các lần truy cập trang danh sách: 3-5 giây
- Delay ngẫu nhiên giữa các lần crawl chi tiết dự án: 1.5-3 giây
- Cuộn trang (scroll) để kích hoạt lazy-loading nội dung trước khi trích xuất
- Timeout tối đa 15 giây cho việc chờ phần tử xuất hiện (WebDriverWait)

3.2.1.2 Quy trình thu thập dữ liệu thô

❖ *Bước 1: Thu thập danh sách dự án (crawl_all_pages)*

Đây là bước đầu tiên trong pipeline, có nhiệm vụ duyệt qua toàn bộ các trang danh sách và thu thập URL cùng thông tin sơ bộ của từng dự án từ URL mục tiêu:

```
https://batdongsan.com.vn/du-an-bat-dong-san-tp-hcm?sts=2,1
```

Trong đó, tham số ?sts=2,1 cho phép lọc các dự án theo trạng thái đang mở bán và sắp mở bán.

a. *Cơ chế phân trang*

URL các trang danh sách được xây dựng theo quy tắc:

Trang 1:	<code>https://batdongsan.com.vn/du-an-bat-dong-san-tp-hcm?sts=2,1</code>
Trang N:	<code>https://batdongsan.com.vn/du-an-bat-dong-san-tp-hcm/pN?sts=2,1</code>

Vòng lặp phân trang tiếp tục cho đến khi một trong hai điều kiện dừng được thỏa mãn: (i) không còn dự án mới nào xuất hiện so với các trang trước, hoặc (ii) đạt đến giới hạn trang tối đa (nếu có cấu hình).

b. *Trích xuất thông tin từ thẻ card*

Mỗi dự án trên trang danh sách được đại diện bởi một thẻ HTML có class `.re__prj-card-full`. Hệ thống trích xuất 4 trường thông tin sơ bộ từ mỗi thẻ:

- URL chi tiết dự án (thuộc tính href của thẻ `<a>`)
- Tên dự án (selector: `.re__prj-card-title`)

- Trạng thái dự án (selector: `.re__prj-tag-info label`)
- Địa chỉ thô (selector: `.re__prj-card-location`)

c. Cơ chế chống trùng lặp

Một tập hợp `seen_urls` được duy trì để theo dõi các URL đã thu thập. Chỉ những dự án có URL chưa xuất hiện mới được thêm vào danh sách kết quả, đảm bảo không có dự án nào bị đếm hai lần khi trang phân trang có sự chồng lấp.

❖ Bước 2: Crawl chi tiết từng dự án (*crawl_project_detail*)

Sau khi có danh sách URL, chương trình duyệt tuần tự từng dự án và thu thập toàn bộ thông tin chi tiết. Quá trình xử lý HTML sử dụng BeautifulSoup để phân tích cú pháp, kết hợp với các regular expression để trích xuất giá trị số.

a. Thông tin định danh và phân loại

Các trường thông tin cơ bản được trích xuất bao gồm:

- Tên dự án (`.re__project-name`)
- Địa chỉ (`.re__project-address`)
- Loại hình dự án (`.re__prj-cat span`)
- Tình trạng pháp lý (`.re__prj-tag-info label`)
- Chủ đầu tư (`.re__prj-investor a`)
- Mô tả tổng quan (`.js__prj-detail-content`)

b. Trích xuất tọa độ địa lý

Tọa độ GPS (kinh độ, vĩ độ) được lấy từ thẻ `div` chứa Google Maps với id `#data-album-google-map`. Thuộc tính `data-src` của thẻ này chứa URL nhúng bản đồ, trong đó tọa độ được mã hóa theo định dạng `q=lat,lng`. Hệ thống sử dụng regular expression để trích xuất:

```
match = re.search(r'q=(-\d.]+), (-\d.]+)', src)
```

c. Thông số dự án

Hệ thống nhận diện các thông số dựa trên class của icon đi kèm trong phần `.re__project-info-details`, thay vì dựa vào nhãn văn bản (tránh vấn đề Unicode và biến thể từ ngữ):

- Icon house → Tổng số căn hộ (`total_apartment`)
- Icon building → Diện tích đất (`land_area_ha`)

Đối với các mục thông tin trong hộp .re__project-box-item, hệ thống so khớp nhãn văn bản (label) với các từ khóa tiếng Việt để xác định trường tương ứng:

Bảng B.3.1: Ánh xạ nhãn HTML sang trường dữ liệu

Từ khóa nhãn (label)	Trường dữ liệu	Kiểu dữ liệu
diện tích	land_area_ha	float (ha)
số căn hộ	total_apartment	int
số tòa / quy mô	num_towers	int
mật độ xây dựng	construction_density	float (%)
khởi công	launch_year	int (năm)
bàn giao / hoàn thành	handover_year	int (năm)
pháp lý / sở hữu	ownership	string

d. Hàm chuyển đổi đơn vị diện tích

Diện tích đất trên trang web có thể được biểu thị bằng đơn vị hecta (ha) hoặc mét vuông (m²). Hàm parse_land_area() chuẩn hóa toàn bộ về đơn vị hecta trước khi lưu trữ:

Nếu có chuỗi 'ha' → giữ nguyên giá trị số
Nếu có chuỗi 'm ² ' hoặc 'm2' → chia cho 10.000
Trường hợp khác → lấy giá trị số nguyên

e. Mã hóa tiện ích dự án

Danh sách tiện ích được trích xuất từ phần .re__prj-facilities ul li, sau đó chuẩn hóa về chữ thường và kiểm tra sự xuất hiện của các từ khóa nhận dạng. Kết quả được mã hóa dưới dạng biến nhị phân (0/1):

Bảng B.3.2: Các biến nhị phân tiện ích và từ khóa nhận dạng

Biến	Từ khóa nhận dạng	Ý nghĩa
has_mall	trung tâm thương mại, siêu thị	Có TTTM/Siêu thị
has_school	trường	Có trường học nội khu

has_hospital	bệnh viện, trạm y tế	Có cơ sở y tế
has_park	công viên	Có công viên nội khu
has_pool	hồ bơi	Có hồ bơi
has_parkinglot	bãi đỗ, bãi giữ	Có bãi đỗ xe

❖ *Bước 3: Lưu dữ liệu thô*

Mỗi dự án sau khi crawl được lưu trữ dưới dạng một bản ghi với 40 trường thông tin:

Bảng B.3.3: Schema bộ dữ liệu cấp dự án

Nhóm trường	Các trường dữ liệu	Ghi chú
Định danh	project_id, source_url, crawled_date	ID tự sinh, URL nguồn, thời điểm crawl
Phân loại	project_name, project_type, project_status, brand	Tên, loại hình, trạng thái, chủ đầu tư
Địa chỉ	address_raw, longitude, latitude, city, district, ward, street	Địa chỉ thô và tọa độ GPS
Quy mô	land_area_ha, num_towers, total_apartment, construction_density	Các chỉ số kỹ thuật dự án
Khoảng cách	dist_cbd_km, dist_metro_km, dist_river_lake_km, dist_highway_km, dist_airport_km, dist_market, dist_school, dist_park, dist_hospital	Các trường về khoảng cách được bổ sung ở giai đoạn sau

Tiện ích	has_mall, has_school, has_hospital, has_park, has_pool, has_parkinglot	Biến nhị phân (0/1)
Thời gian	launch_year, handover_year, ownership, description, note	Năm khởi công, bàn giao, pháp lý

Kết quả được tổ chức thành hai thư mục riêng biệt:

- Thư mục /url: Lưu file CSV chứa danh sách URL và thông tin sơ bộ (urls_YYYYMMDD_HHMMSS.csv), cùng với danh sách URL crawl thất bại (failed_urls_YYYYMMDD_HHMMSS.csv).
- Thư mục /data: Lưu file CSV chứa dữ liệu chi tiết đầy đủ (projects_hcm_YYYYMMDD_HHMMSS.csv). File được xuất với encoding UTF-8 BOM (utf-8-sig).

3.2.1.3 Kiểm định và hoàn thiện bộ dữ liệu

Dữ liệu thô sau khi crawl sẽ trải qua quy trình kiểm định và điền khuyết thủ công trước khi được sử dụng ở bước tiếp theo. Giai đoạn này bao gồm:

- Kiểm tra tính đầy đủ: Rà soát đánh giá tỷ lệ điền đầy dữ liệu (fill rate) của từng trường. Các trường như *latitude*, *longitude*, *land_area_ha*, *total_apartment* được kiểm tra và xử lý bổ sung.
- Kiểm tra tính hợp lệ: Thực hiện lọc và kiểm tra các ràng buộc miền giá trị: tọa độ phải nằm trong phạm vi địa lý TP.HCM (vĩ độ 10.4 - 11.0°N, kinh độ 106.3 - 107.1°E); các thông số cũng sẽ được kiểm tra và so sánh với các trang thông tin chính thức của dự án
- Bổ sung dữ liệu khoảng cách: Đối với các biến số không gian, nghiên cứu tiến hành xác định và điền thủ công các trường khoảng cách dựa trên nền tảng bản đồ thực tế. Từ vị trí GPS đã được làm sạch của từng dự án, người xử lý sẽ đo đạc trực quan để xác định cự ly chính xác đến các trục hạ tầng cốt lõi cũng như các tiện ích dân sinh xung quanh. Việc tính toán thủ công này giúp khắc phục hoàn toàn hiện tượng nhiễu định vị hoặc sai lệch địa chỉ thường gặp ở các công cụ tự động, mang lại độ chính xác tuyệt đối cho nhóm biến khoảng cách.

3.2.2 Thu thập dữ liệu cấp tin đăng

Dữ liệu cấp tin đăng phản ánh thông tin giao dịch thực tế trên thị trường thứ cấp, bao gồm giá niêm yết, diện tích, số phòng ngủ, tình trạng pháp lý và các đặc trưng vật lý của từng căn. Đây là lớp dữ liệu quan trọng nhất trong bộ dataset, cung cấp biến mục tiêu (giá) và hàng loạt biến giải thích cho mô hình định giá.

Hệ thống được thiết kế để thu thập đồng thời từ nhiều nền tảng bất động sản, đảm bảo độ phủ tốt và khả năng đối chiếu giữa các nguồn. Toàn bộ logic chung như quản lý phiên HTTP, phân trang, xử lý lỗi, làm sạch và chuẩn hóa đều được tập trung hóa thành một framework dùng chung, trong khi logic đặc thù theo từng nền tảng sẽ được xử lý riêng ở lớp crawler tương ứng.

3.2.2.1 Kiến trúc và cơ chế kỹ thuật chung của hệ thống thu thập

Hệ thống được tổ chức theo kiến trúc phân tầng rõ ràng:

Bảng B.3.4: Kiến trúc của hệ thống thu thập dữ liệu cấp tin đăng

Tầng	File	Nhiệm vụ
Tiện ích dùng chung	common_utils.py	Parse giá/diện tích, chuẩn hóa văn bản, canonical key, xuất CSV
Framework	multisource_helpers.py	HTTP session, vòng lặp phân trang, resume, build dataset sạch
Crawler theo nguồn	collect_*.py	Kế thừa framework, tùy biến logic parse HTML riêng của từng nền tảng
Điều phối chạy	run_collectors.py	Đọc config YAML, gọi từng crawler với tham số phù hợp

Thiết kế này cho phép thêm một nguồn dữ liệu mới chỉ bằng cách viết một file collect_*.py kế thừa từ GenericRequestsCrawler và implement hai phương thức bắt buộc, mà không cần sửa bất kỳ logic nào ở tầng bên dưới.

Để duy trì hiệu năng kết nối và tối ưu hóa tài nguyên mạng, hệ thống sử dụng requests.Session dùng chung cho toàn bộ phiên crawl, tận dụng cơ chế HTTP keep-alive để giảm overhead kết nối. Session này được cấu hình với tính năng tự động thử

lại thông qua urllib3.Retry với các tham số nghiêm ngặt: tối đa 3 lần thử lại, hệ số backoff 1.0 giây, áp dụng riêng cho các mã lỗi 429 (rate limit) và nhóm 5xx (lỗi server), đồng thời tuân thủ header Retry-After khi server gửi về. Bên cạnh đó, các HTTP header cũng được thiết lập chi tiết để giả lập trình duyệt thông thường, bao gồm User-Agent của Chrome, cấu hình Accept-Language ưu tiên tiếng Việt, và cài đặt Cache-Control: no-cache. Nhằm phòng tránh các cơ chế chặn tự động từ phía server, một khoảng delay ngẫu nhiên được áp dụng tại hai điểm trong pipeline: giữa các trang danh sách (mặc định 1.0-2.2 giây) và giữa các trang chi tiết (mặc định 0.8-1.8 giây). Việc ngẫu nhiên hóa thời gian chờ thay vì sử dụng delay cố định giúp xóa bỏ các pattern request đều đặn, giảm thiểu tối đa khả năng bị nhận diện là bot.

Về cơ chế vận hành, file run_collectors.py đóng vai trò là điểm khởi chạy cho toàn bộ pipeline thu thập dữ liệu. Thay vì cố định các tham số bên trong mã nguồn, mọi cấu hình vận hành được đọc tập trung từ file YAML bên ngoài, cho phép linh hoạt thay đổi các tham số như ngày snapshot, số trang tối đa, thời gian delay, hoặc thành phố cần crawl mà không cần can thiệp vào logic code. Hệ thống điều phối này còn hỗ trợ cơ chế --only-sources để chạy có chọn lọc một tập con các nguồn (ví dụ: chỉ chạy lại nguồn bị lỗi mà không ảnh hưởng đến các nguồn đã hoàn thành) và tham số --override-snapshot-date giúp gán nhãn ngày snapshot tùy ý khi cần chạy bổ sung dữ liệu cho một ngày cụ thể trong quá khứ.

3.2.2.2 Luồng xử lý

Mỗi crawler, bất kể thuộc nền tảng nào, đều thực thi một pipeline cố định gồm ba giai đoạn nối tiếp nhau thông qua phương thức run():

Bảng B.3.5: Ba giai đoạn xử lý trong pipeline thu thập dữ liệu cấp tin đăng

	Giai đoạn	Phương thức	Đầu ra
1	Thu thập URL	crawl_list_pages()	{prefix}_urls_raw.csv
2	Crawl chi tiết	crawl_detail_pages()	{prefix}_details_raw.csv
3	Chuẩn hóa	build_clean_dataset()	{prefix}_details_clean.csv

❖ *Giai đoạn 1: Thu thập URL (crawl_list_pages)*

Crawler bắt đầu từ một hoặc nhiều URL, duyệt tuần tự qua các trang phân trang và thu thập URL của từng tin đăng. Framework hỗ trợ hai chế độ đầu vào:

- Một base URL đơn lẻ truyền qua tham số `--base-url`.
- Danh sách nhiều base URL thông qua `--base-url-file` (file CSV/TXT) hoặc `--base-urls` (chuỗi phân cách bằng dấu phẩy). Khi dùng chế độ này, crawler lần lượt duyệt từng URL độc lập, tích lũy kết quả vào một file `urls_raw` duy nhất và dedup theo `listing_url` trong suốt quá trình.

Điều kiện dừng của vòng lặp phân trang bao gồm: đạt giới hạn `max_pages`, không còn link trang tiếp theo, hoặc hai trang liên tiếp không phát sinh URL mới (cơ chế stagnant detection, biến đếm tăng khi trang trả về 0 URL mới và reset về 0 khi có URL mới). Cơ chế này đặc biệt quan trọng để xử lý các trang cuối danh sách có nội dung trùng lặp.

URL trang tiếp theo được xác định theo thứ tự ưu tiên: (1) nếu có `page_url_template` trong cấu hình, dùng template để xây dựng URL trang kế; (2) nếu không, gọi `parse_list_page()` của lớp con và lấy `next_url` trả về..

❖ *Giai đoạn 2: Crawl chi tiết (crawl_detail_pages)*

Với danh sách URL thu được ở giai đoạn 1, crawler lần lượt fetch từng trang chi tiết và gọi `parse_detail_page()` - phương thức được lớp con override - để trích xuất dữ liệu thô. Kết quả được tích lũy trong bộ nhớ và ghi ra file CSV định kỳ sau mỗi `save_every` bản ghi (mặc định 20), phòng trường hợp tiến trình bị gián đoạn.

Cơ chế resume được kích hoạt bằng cờ `--resume`: khi chạy lại, crawler đọc file `details_raw` hiện có, tái lập tập `seen_urls`, và bỏ qua các URL đã xử lý. Cơ chế này cho phép tiếp tục phiên crawl từ chỗ đang dở mà không mất dữ liệu đã thu thập.

Mọi lỗi HTTP hoặc lỗi parse tại từng URL chi tiết đều được ghi vào file `errors.csv` kèm timestamp, stage (list/detail), URL và thông điệp lỗi đầy đủ, mà không làm dừng toàn bộ tiến trình. Đây là điểm khác biệt quan trọng so với việc để ngoại lệ lan truyền - một URL lỗi không ảnh hưởng đến các URL còn lại.

❖ *Giai đoạn 3: Chuẩn hóa dữ liệu (build_clean_dataset)*

Dữ liệu thô thu được ở giai đoạn 2 chứa các giá trị chuỗi chưa xử lý (price_raw, area_raw, v.v.) và có thể thiếu nhiều trường. Giai đoạn này thực hiện loạt biến đổi để đưa dữ liệu về schema chuẩn:

- Giá: parse_price_to_vnd() nhận diện đơn vị tỷ/triệu/ngàn VNĐ và quy đổi về đơn vị đồng nguyên.
- Diện tích: parse_area_m2() xử lý cả định dạng số đơn ("75m²") lẫn định dạng kích thước ("5x15 m"), trả về bộ ba (area_m2, width_m, length_m).
- Giá/m²: Ưu tiên lấy từ trường price_per_m2_raw nếu có; nếu không, tính bằng price_total_vnd / area_m2.
- Ngày tháng: safe_to_datetime() thử nhiều định dạng (dd-mm-yyyy, yyyy-mm-dd, v.v.) và chuẩn hóa về ISO 8601.
- Số nguyên: bedrooms, bathrooms, floors, image_count được ép kiểu qua parse_int_value().
- Canonical key: Chuỗi fingerprint dạng title | project | area | price dùng để phát hiện bản ghi trùng lặp giữa các nguồn trong bước hợp nhất dataset.

Kết quả cuối cùng được lọc trùng theo source_listing_id (giữ bản ghi đầu tiên) và xuất ra file details_clean.csv theo schema thống nhất.

3.2.2.3 Nền tảng Homedy

Điểm khác biệt trong quy trình thu thập dữ liệu từ Homedy xuất phát từ việc nghiên cứu thống nhất lấy danh mục dự án từ nền tảng batdongsan.com.vn (đã thu thập ở mục 3.2.1) làm bộ khung chuẩn, toàn bộ dữ liệu tin đăng từ các nguồn khác đều phải quy dẫn về bộ khung này. Đối với homedy, nghiên cứu thực hiện một bước tiền xử lý chuyên biệt bằng script crawl_homedy.py nhằm quét qua danh sách dự án đang mở bán của nền tảng này để trích xuất các thông tin sơ bộ bao gồm tên dự án, chủ đầu tư, trạng thái và URL trang gốc, sau đó đóng gói vào dataclass ProjectListing để xuất ra file CSV. File này ngay sau đó được so khớp với bộ dữ liệu chuẩn projects_hcm.csv dựa trên trường project_name. Cơ chế lọc trước này đảm bảo hệ thống thu thập tin đăng chỉ tập trung chính xác vào đúng tập dự án quan tâm đã được định danh, giúp tối ưu hóa tài nguyên mạng và tránh thu thập các dữ liệu rác không liên quan bên ngoài phạm vi nghiên cứu.

Danh sách URL sau khi lọc được lưu trữ tập trung tại file `homedy_for_sale_urls.csv`. Khi khởi chạy, bộ điều phối `run_collectors.py` sẽ nạp tệp cấu hình YAML để truyền tham số đường dẫn thông qua biến `--base-url-file`. Tại đây, hàm `load_url_list` nằm trong framework dùng chung `multisource_helpers.py` sẽ chịu trách nhiệm đọc file, trích xuất cột URL, tự động loại bỏ các liên kết trùng lặp nhưng vẫn giữ nguyên thứ tự gốc trước khi chuyển cho crawler xử lý tuần tự như quy trình chung.

3.2.2.4 Nền tảng Nhadatcanban

Nhadatcanban là nền tảng bất động sản có cấu trúc tương đối đơn giản với nội dung được render tĩnh (server-side rendering), cho phép thu thập dữ liệu bằng các thư viện HTTP thuần túy như `requests`. Điều này giúp tiết kiệm tài nguyên và tăng tốc độ crawl đáng kể so với các nền tảng sử dụng JavaScript rendering như nền tảng `batdongsan`.

Tuy nhiên, nền tảng này có một hạn chế quan trọng: tính năng lọc theo dự án không đáng tin cậy. Khi sử dụng tham số tìm kiếm theo từ khóa dự án (ví dụ `https://nhadatcanban.com.vn/nha-dat-tai-ho-chi-minh-co-tu-khoa-vinhomes-grandpark/page-3`), kết quả trả về không chỉ bao gồm bài đăng của dự án mong muốn mà còn lẫn bài đăng từ các dự án khác (Vinhomes Central Park, Vinhomes Ba Son) và cả tin cho thuê. Điều này làm cho việc crawl trực tiếp theo từ khóa dự án trở nên không khả thi.

Do đó, nghiên cứu áp dụng chiến lược crawl toàn bộ thị trường + gán nhãn ngược thay vì crawl theo từng dự án cụ thể.

Điểm khác biệt trong quy trình thu thập dữ liệu từ Nhadatcanban xuất phát từ việc nghiên cứu thống nhất lấy danh mục dự án từ nền tảng `batdongsan.com.vn` (đã thu thập ở mục 3.2.1) làm bộ khung chuẩn. Toàn bộ dữ liệu tin đăng từ Nhadatcanban đều phải quy dẫn về bộ khung này thông qua bước gán nhãn ngược (reverse mapping).

Thay vì lọc trước danh sách URL dự án như Homedy, nghiên cứu thực hiện:

- Crawl toàn bộ tin đăng căn hộ bán tại TP.HCM (không sử dụng bộ lọc từ khóa dự án)
- Sau khi thu thập, áp dụng script `filter_project.py` để gán `project_name` cho từng bài đăng dựa trên danh sách 156 dự án chuẩn

- Cơ chế gán nhãn ngược sau crawl này đảm bảo không bỏ sót bài đăng nào do bộ lọc của nền tảng hoạt động không chính xác, đồng thời vẫn chỉ giữ lại đúng tập dữ án quan tâm đã được định danh từ batdongsan.

Đối với Nhadatcanban, nhóm thực hiện một bước xử lý chuyên biệt bằng script `filter_project.py` nhằm quét qua toàn bộ dữ liệu tin đăng đã thu thập để trích xuất và gán `project_name` dựa trên thuật toán hybrid matching ba tầng:

- Tầng 1: Strong Keywords (Ưu tiên cao nhất)

Xây dựng danh sách từ khóa đặc trưng cho từng dự án dựa trên quan sát thực tế từ tiêu đề tin đăng:

```
strong_keywords = {
    "vinhomes grand": "Vinhomes Grand Park",
    "the global city": "The Global City",
    "de capella": "De Capella Thủ Thiêm",
    "eastmark": "Chung cu MT Eastmark City",
    # ... 50+ từ khóa khác
}
```

Nếu từ khóa xuất hiện trong tiêu đề (title), bài đăng được gán ngay với độ tin cậy 100%.

- Tầng 2: Exact Match

Duyệt qua danh sách 156 tên dự án chuẩn, kiểm tra tên dự án có xuất hiện chính xác trong tiêu đề hoặc mô tả không.

- Tầng 3: Fuzzy Match (Fallback)

Áp dụng fuzzy matching trên tiêu đề sau khi chuẩn hóa (bỏ dấu, viết thường) với ngưỡng tương tự được điều chỉnh qua thực nghiệm:

Bảng B.3.6: Kết quả từng ngưỡng trùng lặp khi áp dụng fuzzy matching

Lần thử	Ngưỡng	Kết quả
1	70%	Sai quá nhiều (gán nhầm dự án)
2	85%	Vẫn còn sai

3	90%	Tỷ lệ sai thấp nhất
---	-----	---------------------

Kết quả: Với 3.792 bài đăng từ Nhadatcanban, thuật toán gán thành công project_name cho 818 bài (tỷ lệ 21,6%). Các bài không gán được chủ yếu là nhà đất riêng lẻ hoặc dự án không nằm trong danh sách 156 dự án mục tiêu.

Sau khi hoàn tất crawl và gán nhãn, dữ liệu được xuất ra các file bao gồm: file _urls_raw.csv chứa danh sách URL đã thu thập, file _details_clean.csv chứa dữ liệu đã làm sạch, file nhadatcanban_with_project.csv là dữ liệu đã gán project_name (818 dòng), cùng với các file phụ trợ như unassigned_rows_hybrid.csv (các bài không gán được) và fuzzy_matched_report.csv (báo cáo các bài match bằng fuzzy kèm độ tin cậy). Toàn bộ các trường được chuẩn hóa thông qua build_clean_dataset của lớp cha, bao gồm chuyển đổi giá sang VND, chuyển đổi diện tích sang m², che số điện thoại và tính các trường phái sinh.

3.2.2.5 Nền tảng batdongsan

Điểm khác biệt căn bản của nền tảng batdongsan.com.vn so với hai nguồn còn lại nằm ở cơ chế render nội dung. Toàn bộ danh sách tin đăng và trang chi tiết đều được xây dựng trên nền JavaScript động, khiến các thư viện HTTP thuần túy như requests không thể thu được nội dung thực sự sau khi trang đã tải xong. Do đó, crawler tương ứng - collect_batdongsan.py - được triển khai dựa trên SeleniumBase với chế độ undetected-chrome (uc=True), cho phép điều khiển một phiên Chrome thực tế và tự động vượt qua các lớp kiểm tra bot phổ biến (Cloudflare, TLS fingerprinting). Thay vì khởi tạo phiên mới cho từng dự án, driver được khởi động một lần duy nhất và tái sử dụng xuyên suốt toàn bộ phiên crawl, giúp tiết kiệm thời gian khởi động và duy trì trạng thái session ổn định.

Về chiến lược thu thập, do nghiên cứu đã có sẵn danh sách 156 dự án mục tiêu từ bước thu thập dữ liệu cấp dự án, crawler không crawl theo URL danh mục chung mà vận hành theo chế độ crawl theo danh sách dự án. Với mỗi tên dự án trong file projects.csv, hệ thống tự động sinh slug URL theo quy tắc chuẩn hóa: chuyển về chữ thường, loại bỏ dấu tiếng Việt và thay thế khoảng trắng bằng dấu gạch nối, sau đó ghép với tiền tố cố định để tạo thành URL danh sách tương ứng:

```
https://batdongsan.com.vn/nha-dat-ban-{slug}
```

Ví dụ, dự án "Vinhomes Grand Park" được chuyển thành slug vinhomes-grand-park và trở đến URL <https://batdongsan.com.vn/nha-dat-ban-vinhomes-grand-park>. Một số dự án có tên đặc biệt hoặc ký tự không chuẩn (như "Sola - Đảo Ánh Dương") được xử lý riêng thông qua bảng `special_cases` trong hàm `create_slug()` nhằm đảm bảo slug khớp chính xác với URL thực tế trên nền tảng.

Về trích xuất dữ liệu trên trang danh sách, hệ thống sử dụng trực tiếp Selenium để truy vấn DOM thay vì phân tích HTML tĩnh qua BeautifulSoup. Các card tin đăng được xác định qua selector `#product-lists-web .re__card-full`, trong đó crawler tự động lọc bỏ các card có class `promoted` (tin quảng cáo được đẩy lên đầu) và các card chứa thẻ `.re__native-sponsored-ad` để chỉ giữ lại tin đăng hữu cơ. Phân trang được xử lý bằng cách kiểm tra trạng thái của nút điều hướng `a.re__pagination-next`, nếu nút này không mang class `disabled`, URL trang tiếp theo được trích xuất từ thuộc tính `href` và đưa vào vòng lặp tiếp theo.

Trên trang chi tiết, dữ liệu được trích xuất thông qua các selector CSS đặc thù của nền tảng. Thông số kỹ thuật của từng căn (giá, diện tích, số phòng ngủ, hướng nhà, pháp lý, nội thất) được lấy từ khối `.re__pr-specs-content-item` bằng cách so khớp nhãn văn bản với từ khóa tiếng Việt. Khác với homedy và nhadatcanban, nơi giá được thu về dạng chuỗi thô (`price_raw`) rồi parse ở giai đoạn chuẩn hóa, crawler batdongsan thực hiện parse giá trực tiếp tại thời điểm thu thập, chuyển đổi về đơn vị VND ngay trong `parse_detail_page()` và lưu vào trường `price_total_vnd`. Điều này phản ánh thực tế rằng cấu trúc HTML của batdongsan tách bạch rõ ràng giá trị số và đơn vị trong hai thẻ riêng biệt, thuận tiện cho việc parse tức thời hơn so với hai nền tảng còn lại.

Ngoài ra, để tránh tạo áp lực lên server và giảm nguy cơ bị chặn IP trong phiên dài, một khoảng delay ngẫu nhiên từ 30 đến 60 giây được áp dụng giữa hai dự án liên tiếp, bổ sung cho delay giữa các trang và các request chi tiết đã được cấu hình ở tầng framework chung.

3.2.3 Gộp dữ liệu

Sau khi hoàn tất thu thập dữ liệu từ các nguồn khác nhau, bước cuối cùng của quy trình là tích hợp các tập dữ liệu thành một bộ dữ liệu thống nhất để phục vụ phân tích. Quá trình này được thực hiện tuần tự thông qua các bước xử lý dữ liệu thành phần, gộp các tin đăng lại với nhau và kết nối với thông tin dự án tương ứng.

Trước tiên, dữ liệu từ từng nguồn riêng lẻ được xử lý cục bộ để đảm bảo tính đồng bộ về mặt cấu trúc và tên gọi:

- Đối với dữ liệu từ nhadatcanban: tiến hành lọc bỏ các dòng có trường `project_name` bị khuyết thiếu (null) để chỉ giữ lại những bài đăng có liên kết với dự án cụ thể.
- Đối với dữ liệu từ homedy: do tên dự án giữa các nguồn chưa đồng nhất, một bảng ánh xạ (mapping) được xây dựng dựa trên file `bds_with_homedy_url.xlsx` để chuyển đổi trường `homedy_project_name` về tên dự án đúng với tên trên trang batdongsan, các trường hợp không khớp được giữ nguyên tên gốc để tránh mất dữ liệu.
- Bên cạnh đó, các cột mô tả ở cả hai nguồn trên cũng được đổi tên từ `description_text` thành `description` nhằm đồng bộ với cấu trúc trường thông tin chung.

Tiếp theo, ba nguồn dữ liệu tin đăng bao gồm dữ liệu từ trang batdongsan, dữ liệu homedy sau khi map tên dự án, và dữ liệu nhadatcanban sau khi lọc được nối thành một file. Quá trình gộp này chỉ giữ lại các cột chung tồn tại trong cả ba bảng dữ liệu dựa trên khung cấu trúc của bảng batdongsan, giúp đảm bảo tính đồng nhất. Kết quả thu được là file `listing_final.csv` chứa toàn bộ tin đăng bất động sản đã được đồng bộ về mặt cấu trúc cột.

Cuối cùng, bảng tin đăng tổng hợp được nối với dữ liệu dự án tại TP.HCM (`projects_hcm.csv`):

- Trước khi thực hiện phép nối, các cột thông tin dự án cũ (nếu có) trong bảng tin đăng được loại bỏ để tránh trùng lặp thông tin.
- Đồng thời, trường mô tả được đổi tên thành `listing_description` ở bảng tin đăng và `project_description` ở bảng dự án để tránh xung đột tên cột khi thực hiện merge.
- Phép nối được thực hiện dựa trên khóa chung là `project_name`. Qua đó, các thông tin chi tiết của dự án như mã dự án, loại hình, chủ đầu tư, tọa độ, quy mô, hệ thống tiện ích và khoảng cách đến các tiện ích công cộng được ghép vào từng tin đăng tương ứng.

- Sau khi nối, các bản ghi có trường `project_id` bị null, được loại bỏ hoàn toàn để đảm bảo chất lượng dữ liệu.

Dữ liệu cuối cùng được xuất ra file `data_final_raw.csv`, đóng vai trò là đầu vào cho các bước tiền xử lý, xử lý dữ liệu khuyết thiếu và xây dựng mô hình ở các phần tiếp theo.

3.3 Kết quả thu thập

Sau khi hoàn tất toàn bộ quy trình thu thập và tích hợp dữ liệu, bộ dữ liệu thô tổng hợp (`data_final_raw.csv`) bao gồm 6.444 tin đăng trải rộng trên 100 dự án bất động sản tại TP.HCM, được thu thập từ ba nền tảng trong khoảng thời gian từ cuối tháng 4 đến giữa tháng 5 năm 2026. Các tin đăng được ghi nhận từ thời điểm đăng sớm nhất vào tháng 8 năm 2023, với phần lớn tập trung vào năm 2026 (66,7%), cho thấy bộ dữ liệu phản ánh chủ yếu tình trạng thị trường hiện tại. Con số 100 dự án có tin đăng thực tế thấp hơn so với tổng số 156 dự án trong danh sách mục tiêu ban đầu thu thập được từ `batdongsan.com.vn`, phản ánh thực tế một phần các dự án không còn tin đăng đang hoạt động tại thời điểm crawl hoặc không được niêm yết trên cả ba nền tảng.

Bảng B.3.7: Phân bố số tin đăng theo từng nguồn

Nguồn	Số lượng bản ghi	%
batdongsan	4.279	66,4%
homedy	1.347	20,9%
nhadatcanban	818	12,7%

Sự chênh lệch này phản ánh thực tế thị trường: `batdongsan` là nền tảng có lưu lượng tin đăng lớn nhất tại Việt Nam, trong khi `homedy` và `nhadatcanban` đóng vai trò bổ sung để tăng độ phủ trên cùng tập dự án mục tiêu.

Bộ dữ liệu `data_final_raw.csv` cuối cùng gồm 54 cột thuộc tính, bao phủ đầy đủ bốn nhóm thông tin chính: đặc trưng giao dịch (giá, diện tích, số phòng ngủ, hướng nhà, pháp lý, nội thất), thông tin dự án (chủ đầu tư, quy mô, tiện ích nội khu), tọa độ địa lý và khoảng cách đến 8 loại tiện ích công cộng, cùng thông tin liên hệ người đăng. Các trường cốt lõi phục vụ mô hình như `price_total_vnd` (94,6% non-null), `area_m2`

(99,97%), bedrooms (86,0%) và legal_status (86,2%) đạt tỷ lệ non-null ở mức chấp nhận được. Một số trường có tỷ lệ khuyết thiếu cao hơn như direction (52,9%) và furniture_status (70,5%), các dữ liệu null này sẽ được xử lý bổ sung thông qua quy trình AI Fill ở các bước tiền xử lý tiếp theo.

CHƯƠNG 4: KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU

4.1 Quy trình xử lý dữ liệu

Dưới đây là quy trình xử lý dữ liệu tổng quát được thực hiện tuần tự qua các bước nhằm đảm bảo dữ liệu sạch, nhất quán và sẵn sàng cho phân tích.

Bước 1: Kiểm tra và chuẩn hóa cấu trúc dữ liệu. Dữ liệu thô sau khi nạp vào hệ thống sẽ được đánh giá và thống kê ban đầu. Sau đó chuẩn hóa định dạng văn bản (loại bỏ placeholder) và chuyển đổi kiểu dữ liệu (số nguyên, số thực, datetime) cho đồng bộ.

Bước 2: Xử lý trùng lặp và ngoại lệ ban đầu. Loại bỏ các tin đăng trùng `source_listing_url` và `source_listing_id`. Áp dụng ngưỡng thực tế để lọc các giá trị phi lý (số phòng 1 - 20, diện tích 5 - 10.000 m^2 , giá 10 triệu - 10 nghìn tỷ). Đồng thời tính bù giá và loại bỏ tin đăng cho thuê.

Bước 3: Chuẩn hóa danh mục bằng AI Fill. Sử dụng quy tắc (rule-based) kết hợp mô hình Llama-3.3-70b-versatile thông qua Groq API để điền và chuẩn hóa các biến hướng nhà, pháp lý, nội thất, đạt độ chính xác 98 - 99% và loại bỏ hoàn toàn giá trị thiếu.

Bước 4: Khám phá dữ liệu (EDA). Tiến hành phân tích thống kê mô tả toàn diện, đánh giá phân phối của các biến để nắm bắt đặc trưng cơ bản của từng thuộc tính. Xây dựng ma trận tương quan Pearson để lượng hóa mối quan hệ tuyến tính giữa các đặc trưng với biến mục tiêu. Thống kê tỷ lệ dữ liệu thiếu và phát hiện ngoại lệ bằng hai phương pháp IQR và Z-score.

Bước 5: Lọc ngoại lệ nâng cao. Tiến hành loại bỏ các sai lệch dữ liệu qua ba tầng kiểm soát. Thứ tự ưu tiên xóa lần lượt là outlier cả hai phía (both), outlier chỉ trong nội bộ dự án (project_only), outlier toàn cục còn lại (global_only).

Bước 6: Imputation dữ liệu thiếu theo nhóm. Xây dựng chiến lược điền giá trị khuyết thiếu riêng cho từng nhóm thuộc tính dựa trên bản chất dữ liệu.

Bước 7: Xây dựng đặc trưng và mã hóa (Feature Engineering & Encoding). Tạo ra các đặc trưng mới nhằm gia tăng khả năng học của mô hình gồm đặc trưng thời gian, quy mô tương đối, điểm tiện ích, khả năng tiếp cận và các đặc trưng tương tác. Áp dụng log-transform cho các biến lệch. Sử dụng K-Fold Target Encoding (k=5, smoothing) cho `project_name`, `ward`, `investor`, kết hợp One-hot Encoding cho các biến phân loại ít giá trị.

4.2 Tiền xử lý dữ liệu

4.2.1 Kiểm tra cấu trúc dữ liệu

Sau quá trình thu thập dữ liệu từ các nền tảng bất động sản trực tuyến, tập dữ liệu thô được nạp vào hệ thống để tiến hành đánh giá tổng quan ban đầu. Giai đoạn này tập trung kiểm tra kích thước vật lý của dữ liệu thông qua số lượng dòng và số lượng cột thực tế, đồng thời thống kê tổng số lượng giá trị khuyết thiếu (NaN) xuất hiện trong toàn bộ ma trận dữ liệu. Sau khi thống kê, bộ dữ liệu cho ra kết quả gồm 6444 dòng và 54 cột. Tổng số lượng NaN là 19898.

Việc khảo sát cấu trúc dữ liệu ban đầu đóng vai trò quan trọng trong việc xác định mức độ đầy đủ, tính nhất quán và chất lượng tổng thể của dữ liệu thu thập được. Kết quả của bước này là cơ sở để thiết lập các tham số xử lý cố định, đồng thời định hướng cho các quy trình làm sạch và chuẩn hóa dữ liệu chuyên sâu ở các giai đoạn tiếp theo.

4.2.2 Chuẩn hóa định dạng dữ liệu

Dữ liệu bất động sản thu thập từ các nền tảng trực tuyến (homedy, nhadatcanban, batdongsan.com) thường không đồng nhất do quy cách nhập liệu khác nhau. Do đó, quy trình chuẩn hóa định dạng được xử lý thực hiện nghiêm ngặt qua hai giai đoạn:

- **Làm sạch văn bản và xử lý ký tự giữ chỗ (Placeholder):** Sử dụng danh sách các chuỗi rác, hệ thống quét qua toàn bộ các cột dữ liệu dạng chuỗi (object). Các giá trị mang tính chất ký tự giữ chỗ hoặc không mang thông tin thực tế (như “n/a”, “none”, “null”, “-”, “--”, “không”,...) được loại bỏ khoảng trắng thừa ở hai đầu, chuyển về dạng ký tự thường và quy đổi đồng bộ về giá trị khuyết thiếu chuẩn (np.nan).
- **Chuẩn hóa trường thời gian (Datetime):** Hàm process_datetime sử dụng các mask để chuẩn hóa và phân tích cấu trúc ngày tháng riêng biệt theo đặc thù từng website nguồn (homedy theo chuẩn YYYY-MM-DD, nhadatcanban theo cấu trúc Tháng/Ngày/Năm, và batdongsan.com cùng các nguồn khác được xử lý dưới dạng chuỗi hỗn hợp với tham số dayfirst=True). Toàn bộ các thuộc tính mốc thời gian gồm posted_at, expired_at và snapshot_date sau đó được ép kiểu đồng bộ về cấu trúc thời gian chuẩn datetime64[ns].

4.2.3 Chuyển đổi kiểu dữ liệu

Để phục vụ cho các thuật toán học máy và phân tích thống kê, các thuộc tính cần được đưa về đúng phân nhóm kiểu dữ liệu số học được lưu trữ trong máy tính. Quy trình chuyển đổi được chia thành ba nhóm thuộc tính chính:

- **Nhóm dữ liệu số nguyên:** Áp dụng cho các thuộc tính mang tính chất đếm được bao gồm số phòng ngủ (bedrooms), số phòng tắm (bathrooms), mã định danh tin đăng gốc (source_listing_id), số tòa nhà (num_towers), tổng số căn hộ (total_apartment), năm khởi công (launch_year), và năm bàn giao (handover_year). Các cột này được xử lý thông qua hàm `pd.to_numeric()`, các giá trị lỗi định dạng được ép về dạng NaN, và toàn bộ trường dữ liệu được cấu trúc sang kiểu Int64 (kiểu số nguyên mở rộng có hỗ trợ giá trị khuyết thiếu của thư viện Pandas) nhằm bảo toàn cấu trúc ma trận bảng dữ liệu.
- **Nhóm dữ liệu số thực:** Áp dụng cho các thuộc tính đo lường liên tục bao gồm diện tích không gian (area_m2), tổng giá trị giao dịch (price_total_vnd), đơn giá trên một mét vuông (price_per_m2_vnd), diện tích đất quy đổi héc-ta (land_area_ha), mật độ xây dựng (construction_density), cùng toàn bộ 11 thuộc tính đo đặc khoảng cách địa lý tuyến tính đến các thực thể tiện ích công cộng (các biến mang tiền tố `dist_`). Khối dữ liệu này được ép kiểu đồng bộ về dạng số thực float64 để tối ưu hóa độ chính xác cho các phép tính toán học.

4.2.4 Xử lý dữ liệu trùng lặp

Hiện tượng một bất động sản được cập nhật thông tin nhiều lần hoặc xuất hiện trùng lặp giữa các nền tảng được giải quyết bằng hàm `remove_duplicates` qua hai cấp độ loại bỏ:

- **Trùng lặp tuyệt đối (Exact):** Loại bỏ các dòng dữ liệu có tất cả các thuộc tính hoàn toàn giống nhau, chỉ giữ lại bản ghi đầu tiên được tìm thấy.
- **Trùng lặp theo nghiệp vụ (Business Logic):** Hệ thống sắp xếp dữ liệu giảm dần theo ngày thu thập (snapshot_date), sau đó tiến hành xóa các bản ghi trùng nhau dựa trên cặp khóa: mã tin gốc (source_listing_id) và tên nguồn (source_name). Cơ chế này đảm bảo chỉ giữ lại tin đăng có thông tin mới nhất, cập nhật nhất; các tin đăng cũ hơn sẽ bị loại bỏ trước khi đánh chỉ số (Index) lại toàn bộ tập dữ liệu.

4.2.5 Xử lý dữ liệu ngoại lai

Hệ thống triển khai một chuỗi các hàm lọc liên tiếp nhằm gạt bỏ các thông tin nhiễu hoặc sai lệch ra khỏi tập dữ liệu bất động sản:

- **Xử lý nhóm dữ liệu nhị phân:** Hàm `handle_missing` thực hiện quét qua toàn bộ các thuộc tính kiểm tra sự hiện diện của tiện ích (bắt đầu bằng tiền tố `has_`). Các ô trống khuyết thiếu của nhóm này được điền mặc định bằng 0 và ép cứng về kiểu số nguyên `int` nhằm biểu diễn hai trạng thái duy nhất: 1 - Có tiện ích và 0 - Không có tiện ích.
- **Điền khuyết thiếu văn bản:** Cũng trong hàm `handle_missing`, các cột văn bản tự do (`title`, `listing_description`, `address`) nếu gặp giá trị khuyết thiếu sẽ được thay thế bằng một chuỗi rỗng `""` để đảm bảo tính liên tục và tránh gây lỗi cho các tác vụ xử lý chuỗi văn bản ở giai đoạn sau.
- **Xử lý giá trị ngoại lệ:** Hàm `remove_outliers` sử dụng các bộ lọc biên thực tế thị trường để đưa các giá trị phi lý về dạng khuyết thiếu (`NaN`), cụ thể: số phòng ngủ và phòng tắm thuộc đoạn $[1, 20]$; diện tích thuộc đoạn $[5, 10000] m^2$; tổng giá trị giao dịch nằm trong khoảng từ 10 triệu đến 10 nghìn tỷ VNĐ
- **Đồng bộ và tính toán giá:** Hàm `process_prices` tự động tính toán bù trừ toán học giữa các trường giá: nếu khuyết tổng giá thì lấy diện tích nhân với đơn giá/ m^2 , và ngược lại. Những dòng dữ liệu trống cả hai trường giá này sau đó sẽ bị loại bỏ hoàn toàn.
- **Sàng lọc tin đăng cho thuê:** Vì mục tiêu của nghiên cứu là phân tích bất động sản để bán, hàm `remove_rental_listing` kết hợp kỹ thuật quét từ khóa chứa chuỗi “cho thuê”, “cho thue” trong tiêu đề, đồng thời áp dụng ngưỡng lọc giá thấp dưới 900 triệu VNĐ (`RENTAL_THRESHOLD`) để nhận diện và loại bỏ hoàn toàn các tin đăng thuê nhà.

4.2.6 Chuẩn hóa danh mục bằng quy tắc kết hợp Trí tuệ nhân tạo (AI Fill)

Đối với ba thuộc tính phân loại có tính đặc thù cao gồm Hướng nhà (`direction`), Tình trạng pháp lý (`legal_status`) và Tình trạng nội thất (`furniture_status`), dữ liệu ban đầu tồn tại tỷ lệ nhiễu tự do và giá trị khuyết thiếu ở mức lớn do nguồn thu thập được tổng hợp từ nhiều bài đăng không chuẩn hóa. Trước khi xử lý, tỷ lệ giá trị thiếu (`NaN`) của ba thuộc tính `legal_status`, `furniture_status` và `direction` lần lượt đạt 17.5%, 29.5%

và 46.8%. Để nâng cao chất lượng dữ liệu và tối đa hóa khả năng lấp đầy thông tin, hệ thống triển khai quy trình chuẩn hóa gồm ba giai đoạn độc lập nhưng liên kết chặt chẽ với nhau.

❖ *Giai đoạn 1 - Chuẩn hóa bằng tập luật cố định (Rule-based Normalization):*

Hệ thống trước tiên áp dụng cơ chế ánh xạ dựa trên tập luật cố định thông qua các hàm `normalize_direction`, `normalize_legal` và `normalize_furniture` nhằm chuyển đổi dữ liệu văn bản tự do về các nhãn chuẩn hóa theo quy ước thị trường. Cụ thể, thuộc tính hướng nhà được quy đổi về 9 nhóm hướng chuẩn như Đông, Tây Nam, Tây Bắc, Đông Nam; tình trạng pháp lý được phân loại thành các nhóm như Sổ hồng/Sổ đỏ, Hợp đồng mua bán; trong khi tình trạng nội thất được chuẩn hóa thành các mức Đầy đủ, Cơ bản và Không nội thất. Những trường hợp không thể nhận diện bằng luật hoặc bị thiếu dữ liệu sẽ tạm thời được gán nhãn “Chưa rõ” để phục vụ xử lý ở bước tiếp theo. Kết quả sau giai đoạn đầu cho thấy phương pháp Rule-based đã xử lý thành công 82,8% số giá trị thiếu của thuộc tính pháp lý, 77,1% của thuộc tính nội thất và 41% đối với thuộc tính hướng nhà.

❖ *Giai đoạn 2 - Suy luận ngữ nghĩa sâu bằng AI kết hợp bộ lọc xác thực (AI Normalization & Validation):*

Đối với các bản ghi vẫn mang nhãn “Chưa rõ” sau bước Rule-based, hệ thống tiếp tục áp dụng mô hình ngôn ngữ lớn để suy luận ngữ nghĩa sâu từ nội dung văn bản. Cụ thể, hệ thống khởi tạo mặt nạ lọc (`need_ai_mask`) nhằm tách toàn bộ các dòng dữ liệu chưa xác định và tiến hành xử lý theo từng lô nhỏ (`batch size = 10`). Dữ liệu sau đó được gửi tới mô hình Llama-3.3-70b-versatile thông qua Groq API với khoảng nghỉ 2 giây giữa các lần gọi nhằm đảm bảo ổn định hệ thống và tránh vượt ngưỡng tải.

Trong quá trình xử lý, hệ thống chỉ trích xuất phần thông tin quan trọng từ Tiêu đề (title) và Mô tả chi tiết (description) để tối ưu chi phí suy luận và tăng hiệu quả nhận diện ngữ cảnh. Mô hình AI đóng vai trò đọc hiểu nội dung văn bản tự do và trả về kết quả dưới định dạng JSON chuẩn hóa. Để hạn chế hiện tượng sinh nhãn sai hoặc “hallucination” từ mô hình ngôn ngữ, toàn bộ kết quả đầu ra tiếp tục được kiểm tra thông qua ba hàm xác thực `validate_direction`, `validate_legal` và `validate_furniture`. Những giá trị không thuộc tập nhãn hợp lệ (`VALID_`) sẽ bị loại bỏ và tự động thay thế bằng giá trị phòng vệ mặc định “Chưa rõ”.

Kết quả thực nghiệm cho thấy mô hình AI đã xác định được tổng cộng 12428 giá trị còn thiếu, trong đó chỉ có 130 trường hợp không khớp với tập nhãn xác thực. Điều này cho thấy độ chính xác của mô hình đạt mức rất cao, ước tính khoảng 98 - 99%, đồng thời loại bỏ hoàn toàn tình trạng giá trị null còn sót lại trong ba thuộc tính mục tiêu.

❖ *Giai đoạn 3 - Kiểm tra phân phối nhãn và kiểm soát chất lượng đầu ra:*

Sau khi hoàn tất quá trình tích hợp kết quả từ mô hình AI, hệ thống tiến hành bước hậu kiểm nhằm đánh giá chất lượng chuẩn hóa đầu ra. Cụ thể, hệ thống thống kê và trực quan hóa phân phối nhãn (value counts) của các thuộc tính `direction_norm`, `legal_status_norm` và `furniture_status_norm`. Bước kiểm tra này giúp nhóm nghiên cứu phát hiện các dấu hiệu bất thường trong phân phối dữ liệu, đánh giá tính hợp lý của quá trình gán nhãn và đảm bảo không còn tồn tại giá trị khuyết thiếu trước khi xuất bản bộ dữ liệu cuối cùng phục vụ cho các bước phân tích và xây dựng mô hình học máy.

4.3 Khám phá dữ liệu

4.3.1 Thống kê mô tả dữ liệu

Tập dữ liệu gồm 5983 quan sát và 55 cột với đầy đủ thông tin về giá, diện tích, vị trí địa lý, tiện ích và đặc điểm dự án. Phần này phân tích các chỉ số thống kê cơ bản của dữ liệu như trung bình, trung vị, giá trị lớn nhất, nhỏ nhất và độ lệch chuẩn nhằm có cái nhìn tổng quan về tập dữ liệu.

	count	unique	top	freq
source_name	5983	3	batdongsan	4085
snapshot_date	5983	5	2026-04-26	2665
listing_url	5983	5983	https://nhadatcanban.com.vn/victoria-village-6...	1
project_name	5983	83	Vinhomes Grand Park	1719
listing_type	5983	5	vip-normal	3873
title	5983	5860	2PN Căn hộ cao cấp Elysian LK Vành Đai 3 giá m...	3
listing_description	5983	5855	Mua bán căn hộ Vinhomes Grand Park Quận 9 - Ho...	8
legal_status	5983	3	Sổ hồng/Sổ đỏ	2776
furniture_status	5983	4	Đầy đủ	2770
direction	5983	9	Chưa rõ	2713
contact_name	5983	1621	Thoa Võ	146
contact_phone_masked	4916	1245	094***611	146
posted_at	5983	737	2026-04-24	370
expired_at	5167	632	2026-09-05	352
project_id	5983	83	DA_20260423_204253_695	1719
project_type	5983	7	Căn hộ chung cư	2944
project_status	5983	2	Đang mở bán	5932
investor	5983	61	Vinhomes	1890
address	5983	80	Đường Nguyễn Xiển, Phường Long Bình, Hồ Chí Minh	1719
city	5983	1	Hồ Chí Minh	5983
ward	5983	49	Phường Long Bình	1769
street	5983	67	Đường Nguyễn Xiển	1724
ownership	5773	20	Sổ hồng lâu dài	2143
project_description	5983	83	Vinhomes Grand Park là đại đô thị hiện đại, th...	1719
source_url	5983	83	https://batdongsan.com.vn/du-an-khu-phuc-hop-q...	1719
note	100	11	Dự án dính nhiều nghi vấn lừa đảo vì mặc dù đã...	48

Hình B.4.1: Thống kê số lượng và mức độ đa dạng của các thuộc tính trong bộ dữ liệu

	count	mean	std	min	25%	median	75%	max
price_total_vnd	5983.0	11.15	23.87	0.00	3.15	4.59	8.50	428.00
area_m2	5983.0	90.94	72.66	23.20	60.00	73.00	95.00	2400.00
price_per_m2_vnd	5983.0	97.99	101.76	0.06	50.00	63.51	89.57	1169.23
bedrooms	5983.0	2.20	0.90	1.00	2.00	2.00	3.00	20.00
bathrooms	5983.0	1.98	0.89	1.00	2.00	2.00	2.00	20.00
land_area_ha	5982.0	90.03	117.40	0.09	2.80	14.50	271.00	350.00
num_towers	4789.0	28.98	31.61	1.00	4.00	7.00	71.00	71.00
total_apartment	5719.0	15301.72	18973.80	20.00	1046.00	4000.00	44000.00	44000.00
construction_density	5650.0	29.22	8.80	14.00	23.00	28.00	31.00	90.00
dist_cbd_km	5983.0	14.75	7.02	2.10	9.50	13.40	23.00	35.31
dist_metro_km	5983.0	8.34	3.97	0.00	5.40	9.10	11.00	35.31
dist_river_lake_km	5983.0	1.22	1.34	0.00	0.40	1.10	1.30	30.00
dist_highway_km	5983.0	6.28	4.48	0.20	2.50	6.70	7.00	24.86
dist_airport_km	5983.0	16.79	6.47	3.12	10.00	16.00	24.00	32.08
dist_market	5983.0	0.97	1.05	0.00	0.28	0.80	1.00	8.42
dist_school	5983.0	0.99	0.91	0.00	0.27	1.00	1.30	4.90
dist_park	5983.0	0.85	0.69	0.00	0.24	0.65	1.50	3.50
dist_hospital	5983.0	3.15	1.75	0.20	2.20	2.90	3.80	12.00
has_mall	5983.0	0.81	0.39	0.00	1.00	1.00	1.00	1.00
has_school	5983.0	0.64	0.48	0.00	0.00	1.00	1.00	1.00
has_hospital	5983.0	0.40	0.49	0.00	0.00	0.00	1.00	1.00
has_park	5983.0	0.85	0.36	0.00	1.00	1.00	1.00	1.00
has_pool	5983.0	0.89	0.31	0.00	1.00	1.00	1.00	1.00
has_parkinglot	5983.0	0.92	0.27	0.00	1.00	1.00	1.00	1.00
launch_year	5869.0	2018.71	3.29	2001.00	2018.00	2019.00	2021.00	2026.00
handover_year	5895.0	2021.47	2.99	2010.00	2020.00	2021.00	2024.00	2027.00

Hình B.4.2: Thống kê mô tả các biến định lượng

*Giá tổng và giá/m² đã quy đổi về đơn vị tỷ đồng và triệu đồng/m² để dễ đọc.

- Biến mục tiêu - Giá trên mỗi mét vuông (price_per_m2_vnd)

Giá trên mét vuông dao động từ khoảng 60 nghìn đến 1,17 tỷ đồng/m² với trung bình ~97,99 triệu đồng/m² và trung vị ~63,51 triệu đồng/m² cho thấy

price_per_m2_vnd có phạm vi dao động rộng, bao phủ phần lớn giao dịch phổ biến trên thị trường. Tuy nhiên có thể thấy biến mục tiêu đang có một số giá trị lỗi giá từ phía tin đăng hoặc đây là giá trị cực đoan thấp hoặc cao cần lưu ý.

- Giá bất động sản (price_total_vnd)

Biến price_total_vnd phản ánh mức giá giao dịch trung bình đạt khoảng 11,15 tỷ đồng, tuy nhiên trung vị chỉ ở mức 4,59 tỷ đồng - sự chênh lệch lớn này cho thấy phân phối giá bị lệch phải đáng kể, tức là một số ít căn có giá rất cao (tối đa ~428 tỷ đồng) đã kéo giá trung bình lên cao. Mức giá thấp nhất ghi nhận khoảng 2,9 triệu đồng, đây có thể là dữ liệu bất thường cần xem xét thêm. Độ lệch chuẩn (~23,87 tỷ) rất lớn so với trung vị, phản ánh biên độ giá dao động rộng trên thị trường.

- Diện tích (area_m2)

Diện tích (area_m2) trung bình là 90,94 m², trung vị là 73 m². Phân phối cũng lệch phải với giá trị tối đa lên tới 2400 m² - có thể là penthouse hoặc biệt thự lớn. Phần lớn bất động sản nằm trong khoảng từ 60 đến 95 m² (IQR), tương ứng với phân khúc bất động sản từ 2 - 3 phòng ngủ phổ biến.

- Số phòng ngủ và phòng tắm

Số phòng ngủ (bedrooms) trung bình là 2,2 phòng, trung vị là 2, tập trung chủ yếu vào loại căn 2 - 3 phòng ngủ. Số phòng tắm (bathrooms) có phân phối tương tự với trung bình 1,98 và trung vị là 2. Giá trị tối đa 20 phòng ở cả hai biến là ngoại lệ do nó thuộc về biệt thự lớn.

- Đặc điểm dự án

Diện tích khu đất (land_area_ha) có mức trung bình 90 ha nhưng trung vị chỉ 14,5 ha cho thấy sự đa dạng lớn về quy mô dự án - từ căn hộ chung cư đến các đại đô thị như Vinhomes Grand Park. Số tòa tháp (num_towers, có 4789 quan sát hợp lệ) trung bình là 28,9 tòa, tổng số căn hộ (total_apartment) trung bình đạt ~15302 căn với tối đa 44000 căn. Mật độ xây dựng (construction_density) trung bình là 29,2% nằm trong khung quy định phổ biến cho chung cư tại Việt Nam.

- Thời gian ra mắt và bàn giao

Năm ra mắt (launch_year) tập trung chủ yếu từ 2018 - 2021 (Q1 - Q3), với trung vị năm 2019. Năm bàn giao (handover_year) có trung vị 2021 và kéo dài đến 2027,

phản ánh chu kỳ xây dựng và giao nhà thực tế của các dự án căn hộ tại TP.HCM trong giai đoạn này.

- Khoảng cách đến các tiện ích

Các biến khoảng cách phản ánh khả năng tiếp cận hạ tầng và tiện ích xung quanh của từng căn. Khoảng cách đến trung tâm (dist_cbd_km) trung bình là 14,75 km, trung vị 13,4 km, cho thấy phần lớn dự án nằm ở vùng ven nội thành. Khoảng cách đến tuyến metro (dist_metro_km) có trung vị 9,1 km, trong khi khoảng cách đến sông/hồ (dist_river_lake_km) tương đối gần với trung vị chỉ 1,1 km. Các tiện ích lân cận như chợ, trường học, công viên và bệnh viện đều có khoảng cách trung vị dưới 3 km, trong đó bệnh viện xa nhất với trung vị 2,9 km.

- Biến nhị phân tiện ích


Các biến has_* cho thấy tỷ lệ phổ biến của từng tiện ích trong tập dữ liệu. Bãi đỗ xe (has_parkinglot) và hồ bơi (has_pool) là hai tiện ích phổ biến nhất với tỷ lệ lần lượt là 92,3% và 89,2%. Trung tâm thương mại (has_mall, 80,8%) và công viên (has_park, 84,7%) cũng rất phổ biến, trong khi bệnh viện nội khu (has_hospital) chỉ xuất hiện ở 40% số dự án - tiện ích khó triển khai và đặc thù hơn.

- Dữ liệu phân loại


Về nguồn dữ liệu, 3 nguồn được thu thập với batdongsan.com.vn chiếm đa số (4085/5983 quan sát). Tập dữ liệu bao gồm 83 dự án tại TP.HCM, trong đó Vinhomes Grand Park chiếm tỷ lệ cao nhất với 1719 listing (~28,7%). Loại hình chủ yếu là căn hộ chung cư (2944 listing) và 99,2% dự án đang ở trạng thái mở bán. Tình trạng pháp lý phổ biến nhất là Sổ hồng/Sổ đỏ (2776 listing) còn nội thất chủ yếu theo dạng đầy đủ (2770 listing).

4.3.2 Phân tích phân phối dữ liệu

- Nhóm biến giá




Hình B.4.3: Biểu đồ phân phối giá trước và sau khi biến đổi log



Hình B.4.4: Biểu đồ phân phối giá/m² trước và sau khi biến đổi log

Nhóm biến giá có mức độ lệch phải rất cao ngay cả sau khi áp dụng log-transform. Cụ thể, `price_total_vnd` đạt skewness = 7,79 và `price_per_m2_vnd` đạt skewness = 3,48 cho thấy sự tồn tại của các giá trị cực đoan ở đuôi phải - chủ yếu đến từ biệt thự, penthouse hoặc lỗi tin đăng. So sánh giữa hai biến, `price_per_m2_vnd` sau khi áp dụng phép biến đổi log1p có hệ số skewness giảm xuống -0,04, tức phân phối đã trở nên đối xứng và xấp xỉ chuẩn, do đó phù hợp hơn để sử dụng làm biến mục tiêu trong mô hình hồi quy.

- Nhóm biến đặc điểm dự án




Hình B.4.5: Biểu đồ phân phối của các biến thông số căn hộ và dự án

Các biến số về quy mô cũng thể hiện xu hướng lệch phải mạnh. Diện tích căn hộ (area_m2) có skewness = 8,46 do một số dự án đất nền, biệt thự diện tích rất lớn (đến $2400 m^2$) trong khi phần lớn căn hộ phổ biến chỉ 60 - 95 m^2 . Tương tự, land_area_ha (diện tích khu đất) lệch phải 8,04 bởi sự hiện diện của các đại đô thị như Vinhomes bên cạnh những dự án nhỏ lẻ. Số phòng ngủ (bedrooms) và phòng tắm (bathrooms) lần lượt có skewness = 3,05 và 4,10 - cho thấy các giá trị ngoại lệ lên đến 20 phòng làm lệch phân phối, dù phần lớn chỉ có 2 - 3 phòng.

Đáng chú ý, construction_density (mật độ xây dựng) đạt skewness = 2,14, tức lệch phải vừa phải, phản ánh hầu hết dự án tuân thủ mật độ quanh 30%, nhưng có một số ít dự án mật độ cao hơn. Trong khi đó, num_towers (số tòa tháp) và total_apartment (tổng căn hộ) lần lượt có skewness = 0,56 và 0,82 - gần đối xứng, cho thấy phân phối của hai thuộc tính này tương đối cân đối quanh giá trị trung bình


- Nhóm biến thời gian



Hình B.4.6: Biểu đồ phân phối của các biến thời gian

Nhóm biến thời gian (launch_year, handover_year) có đặc điểm lệch trái, ngược với phần lớn các biến số trong tập dữ liệu. Biến launch_year có skewness = -1,95 với đỉnh tập trung vào giai đoạn 2018 - 2019, phản ánh làn sóng ra mắt dự án căn hộ mạnh mẽ tại TP.HCM trong giai đoạn này. Biến handover_year có phân phối trải rộng hơn (skew = -0,90) kéo dài đến năm 2027 do nhiều dự án vẫn đang trong quá trình xây dựng.


- Nhóm biến khoảng cách



Hình B.4.7: Biểu đồ phân phối của các biến khoảng cách

Các biến khoảng cách đa phần đều có phân phối lệch phải (skewness dương nhưng thường < 2). Phần lớn quan sát tập trung ở vùng khoảng cách nhỏ - ví dụ khoảng cách đến sông/hồ có trung vị 1,1 km, đến chợ, trường, công viên, bệnh viện đều dưới 3 km - phản ánh các dự án được bố trí trong khu vực có tiện ích tương đối đầy đủ. Khoảng cách đến metro (dist_metro_km) có phạm vi trải rộng hơn do mạng lưới metro TP.HCM còn hạn chế, nhiều dự án nằm cách xa tuyến metro (trung vị 9,1 km), tạo thành đuôi phải khá dài. Mức độ lệch của nhóm biến khoảng cách thấp hơn nhiều so với biến giá và diện tích, do đó không nhất thiết phải biến đổi log có thể chỉ cần chuẩn hóa (standardization) trước khi đưa vào mô hình.


- Nhóm biến tiện ích nhị phân



Hình B.4.8: Phân bố 2 lớp giữa các biến nhị phân tiện ích nội khu

Nhóm biến tiện ích nhị phân (has_*) phản ánh mức độ phổ biến của từng tiện ích. Bãi đỗ xe, hồ bơi và công viên là các tiện ích có tỷ lệ hiện diện cao nhất gần như trở thành tiêu chuẩn bắt buộc của các dự án bất động sản hiện đại. Ngược lại, bệnh viện nội khu (has_hospital) có tỷ lệ thấp nhất (~40%), thể hiện mức độ mất cân bằng lớn nhất trong nhóm - cần lưu ý khi sử dụng biến này trong mô hình.

- Nhóm biến phân loại




Hình B.4.9: Phân bố tần suất các giá trị của các biến phân loại

Từ biểu đồ có thể thấy, nguồn tin từ batdongsan.com.vn chiếm ưu thế tuyệt đối, các nguồn còn lại chỉ chiếm phần nhỏ. Trong bộ dữ liệu hiện tại có 7 loại hình dự án, riêng căn hộ chung cư chiếm gần một nửa (2944 listing, ~ 49,2%), các loại hình khác phân bố thưa hơn. Các biến legal_status và furniture_status lần lượt chiếm phần lớn bởi sổ hồng/sổ đỏ và nội thất đầy đủ. Sự mất cân bằng này cần được xử lý khi mã hóa và xây dựng mô hình (gộp nhóm hiếm, one-hot có kiểm soát) để tránh sai lệch do các dự án lớn chi phối.

4.3.3 Phân tích tương quan dữ liệu

Sau khi khảo sát phân phối từng biến, bước tiếp theo là đánh giá mối quan hệ tuyến tính giữa các thuộc tính với biến mục tiêu price_per_m2_vnd (giá trên mét vuông) nhằm xác định các yếu tố ảnh hưởng mạnh nhất, hỗ trợ lựa chọn đặc trưng cho mô hình.



Hình B.4.10: Ma trận tương quan của các thuộc tính số với biến mục tiêu


Dựa trên ma trận tương quan Pearson, các kết quả đáng chú ý như sau:

- Nhóm tương quan mạnh nhất ($|r| > 0,5$):
 - + dist_metro_km có tương quan âm mạnh nhất với giá/m² ($r = -0,518$), nghĩa là càng gần metro, giá trên mét vuông càng cao - hợp lý do tiện ích giao thông công cộng.
 - + price_total_vnd tương quan dương rất cao ($r = 0,766$) với giá/m² nhưng đây là hệ quả tất yếu vì $\text{price_total_vnd} = \text{price_per_m2_vnd} \times \text{area_m2}$. Do đó, biến này sẽ bị loại khi xây dựng mô hình để tránh đa cộng tuyến.
- Nhóm tương quan trung bình ($0,3 < |r| < 0,5$):
 - + dist_airport_km ($r = -0,359$) và dist_cbd_km ($r = -0,345$): khoảng cách đến sân bay và trung tâm càng xa thì giá/m² càng giảm, phù hợp với quy luật thị trường.

- + dist_school ($r = +0,322$) - bất ngờ khi tương quan dương: càng xa trường học, giá/ m^2 càng cao? Có thể do các dự án cao cấp nằm xa khu vực đông đúc trường học, hoặc do nhiều dữ liệu cần kiểm tra lại.
- + area_m2 ($r = +0,303$): diện tích càng lớn thì giá/ m^2 càng cao - trái với suy luận thông thường (thường căn nhỏ mới có giá/ m^2 cao). Điều này gợi ý trong tập dữ liệu, các căn có diện tích lớn (penthouse, biệt thự) thuộc phân khúc cao cấp, kéo giá/ m^2 lên.
- Nhóm tương quan yếu - trung bình ($0,15 < |r| < 0,3$):
 - + bathrooms ($r = 0,231$), bedrooms ($r = 0,209$) tương quan dương nhẹ với giá/ m^2 .
 - + construction_density (0,161) - mật độ xây dựng cao hơn đi kèm giá/ m^2 cao hơn.
 - + Các khoảng cách tiện ích: dist_market ($r = 0,153$), dist_park ($r = -0,153$), dist_hospital ($r = -0,254$), dist_river_lake_km ($r = -0,198$) có mức độ ảnh hưởng từ nhẹ đến trung bình, trong đó gần bệnh viện và gần sông/hồ làm tăng giá.
- Nhóm tương quan rất yếu ($|r| < 0,15$):
 - + Các biến nhị phân tiện ích (has_pool, has_parkinglot, has_school, has_park, has_mall, has_hospital) có hệ số từ -0,22 đến 0,06, ảnh hưởng không đáng kể.
 - + Quy mô dự án (num_towers, total_apartment, land_area_ha) tương quan âm rất nhẹ ($\approx -0,14$ đến $-0,18$).
 - + Năm bàn giao, năm ra mắt, tọa độ địa lý hầu như không tương quan ($|r| < 0,04$).

4.3.4 Phân tích dữ liệu thiếu

Tỷ lệ dữ liệu thiếu được thống kê cho từng thuộc tính nhằm đánh giá mức độ ảnh hưởng đến các bước tiền xử lý và xây dựng mô hình. Kết quả được trình bày trong Bảng



Hình B.4.11: Thống kê missing value theo feature

- Biến số tòa (num_towers)

Đây là biến có tỷ lệ thiếu cao nhất (20%), có thể do một số dự án không công bố thông tin này và các loại hình khác như shophouse, biệt thự liền kề vốn dĩ không có toa. Vì biến này có hệ số bất đối xứng thấp (skewness = 0,56, phân phối tương đối đối xứng) phương án xử lý phù hợp là imputation bằng giá trị trung vị.

- Biến thời gian hết hạn tin đăng (expired_at)

Biến này đang thiếu 13,6% do các tin đăng từ trang homedy không hiển thị thời gian hết hạn của tin. Biến expired_at chỉ có ý nghĩa quản lý dữ liệu, không phải đặc trưng dự đoán giá, do đó có thể loại bỏ khỏi tập mà không ảnh hưởng đến chất lượng mô hình.

- Biến liên quan đến dự án

Biến construction_density (5,6%) và total_apartment (4,4%) thiếu ở mức trung bình thấp, các biến ownership (3,5%), launch_year (1,9%), handover_year (1,5%) thiếu không đáng kể, có thể xử lý bằng imputation trung vị.

- Các biến còn lại không có ý nghĩa trong tập dữ liệu như note và contact_phone_masked sẽ bị xóa khỏi tập.

4.3.5 Phân tích ngoại lệ

Để đánh giá mức độ ảnh hưởng của các giá trị bất thường, nhóm áp dụng đồng thời hai phương pháp: IQR (khoảng tứ phân vị) phù hợp với dữ liệu không chuẩn, và Z-score (ngưỡng 3) giả định phân phối chuẩn. Kết quả được trình bày tại Bảng và Bảng

Bảng B.4.1: Thống kê outlier theo phương pháp IQR

Biến	Q1	Q3	IQR	N outlier	%
price_total_vnd	3,15 tỷ	8,5 tỷ	5,35 tỷ	920	15,4
price_per_m2_vnd	50 triệu	89,567 triệu	39,567 triệu	892	14,9
area_m2	60	95	35	497	8,2
bedrooms	2,0	3,0	1,0	122	2,0
bathrooms	2,0	2,0	0	1888	31,6

Bảng B.4.2: Thống kê outlier theo phương pháp Z-score


Biến	Mean	Std	Z thresh	N outlier	%
price_total_vnd	11,15 tỷ	23,868 tỷ	3	81	1,4
price_per_m2_vnd	97,99 triệu	101,76 triệu	3	162	2,7
area_m2	90,9	72,7	3	148	2,5
bedrooms	2.2	0,9	3	122	2,0
bathrooms	2,0	0,9	3	157	2,6

Phương pháp IQR phát hiện tỷ lệ outlier rất cao (15 - 30%) ở các biến giá, diện tích và bathrooms, phản ánh đúng đặc điểm phân phối lệch phải mạnh (skewness từ 3,48 đến 8,46). Ngược lại, Z-score chỉ ra rất ít outlier (dưới 3%) do giả định phân phối chuẩn không được thỏa mãn. Điều này cho thấy Z-score không phù hợp để phát hiện outlier trên dữ liệu giá bất động sản - vốn có đuôi rất dài về phía giá cao.

Trường hợp bathrooms có $IQR = 0$ ($Q1 = Q3 = 2$) dẫn đến gần 32% outlier theo IQR, nhưng thực tế các giá trị như 3, 4,...20 phòng tắm là hoàn toàn có thật (penthouse, biệt thự).

4.3.6 Phân tích phân bố dữ liệu mục tiêu

Biến mục tiêu trong bài toán là `price_per_m2_vnd` (giá trên mét vuông). Việc đánh giá phân bố của nó đóng vai trò then chốt, ảnh hưởng trực tiếp đến hiệu suất của các mô hình dự báo.



Hình B.4.12: Phân bố diện tích theo giá trên mỗi mét vuông và tổng giá trị căn hộ

Phân tích từ biểu đồ phân tán có thể thấy:

Scatter plot $\text{Giá}/\text{m}^2$ với Diện tích cho thấy một số điểm có diện tích rất nhỏ ($< 40 \text{ m}^2$) nhưng $\text{giá}/\text{m}^2$ cực cao (thường là studio cao cấp). Ngược lại, một số điểm diện tích lớn ($> 200 \text{ m}^2$) lại có $\text{giá}/\text{m}^2$ thấp (biệt thự vùng ven).

Scatter plot Tổng giá với Diện tích thể hiện xu hướng tuyến tính nhưng xuất hiện những điểm nằm xa so với xu hướng chính, thường là các căn có giá tổng rất cao (có thể do sai sót hoặc do vị trí đặc biệt).

Nếu giữ nguyên dữ liệu gốc, các mô hình tuyến tính sẽ bị ảnh hưởng nặng bởi những giá trị cực trị, dẫn đến hệ số hồi quy không ổn định và sai số dự báo lớn trên phân khúc phổ biến. Các mô hình dạng cây (Random Forest, XGBoost) ít nhạy hơn nhưng vẫn có thể bị ảnh hưởng khi chia tách do sự chênh lệch về thang đo.

Biến mục tiêu ban đầu bị lệch phải mạnh, cần được biến đổi log trước khi đưa vào mô hình, skewness giảm từ 3,48 xuống -0,04 (gần như đối xứng). Biểu đồ histogram sau log (đã trình bày ở mục 4.3.2) xác nhận phân bố đã trở nên cân bằng - đây là bước chuẩn bị quan trọng cho các phần xây dựng mô hình sau này.

4.4 Tiềm xử lý dữ liệu sau phân tích

Sau bước khám phá dữ liệu (EDA), một pipeline tiền xử lý nâng cao được thực thi để chuẩn bị tập dữ liệu sẵn sàng cho việc huấn luyện mô hình. Pipeline này gồm bốn giai đoạn chính: (1) lọc và làm sạch nâng cao, (2) imputation dữ liệu thiếu theo nhóm, (3) xây dựng đặc trưng mới, (4) mã hóa biến phân loại. Toàn bộ pipeline tuân thủ nguyên tắc không rò rỉ dữ liệu: mọi tham số (trung vị, thống kê nhóm) đều chỉ được ước lượng trên tập huấn luyện rồi áp dụng lên tập kiểm tra.

4.4.1 Lọc ngoại lệ nâng cao

Dựa trên kết quả EDA, nhóm áp dụng ba tầng lọc ngoại lệ nhằm loại bỏ các giá trị sai lệch rõ ràng và các trường hợp vi phạm logic thực tế, đồng thời giữ lại các bất động sản cao cấp hợp lý.

Tầng 1, các bản ghi có `price_per_m2_vnd` dưới 1 triệu VNĐ/ m^2 được xem là lỗi nhập liệu (ví dụ thiếu số 0) và bị loại bỏ hoàn toàn. Ngoài ra, các căn thấp hơn phân vị 1% (dưới ~22,9 triệu/ m^2) sẽ được xóa, các căn cao hơn phân vị 99% (giá/ m^2 cực cao) được giữ lại vì phản ánh đúng bất động sản cao cấp.

Tầng 2, dựa trên phân phối thực tế và đặc điểm thị trường, nhóm áp dụng ngưỡng cho khoảng giá và diện tích như sau:

- + `price_per_m2_vnd2` sẽ được giữ lại trong khoảng giá đã xử lý từ tầng 1 đến 1,2 tỷ VNĐ/ m^2 , các căn có giá dưới 5 triệu bị loại nhưng những căn trên 1,2 tỷ vẫn được giữ vì đó là bất động sản cao cấp thực tế (penthouse, biệt thự siêu sang).
- + `area_m2` giữ từ 15 m^2 đến 2000 m^2 , các căn dưới 15 m^2 (quá nhỏ cho chung cư) hoặc trên 2000 m^2 (vượt quá quy mô thông thường) sẽ bị loại.
- + Logic diện tích - phòng ngủ: Những căn có `area_m2` dưới 50 m^2 nhưng số phòng ngủ từ 3 trở lên sẽ bị loại vì vi phạm bố trí không gian thực tế.

Tầng 3, thay vì loại bỏ toàn bộ outlier, nhóm phân loại mức độ bất thường và ưu tiên xóa theo thứ tự:

- + Outlier cả hai phía (both): Các bản ghi vừa là outlier global (Z-score > 3) vừa là outlier trong cùng dự án. Đây là những trường hợp bất thường rõ nhất, được xóa trước.

- + Outlier chỉ trong dự án (project_only): Các căn có giá lệch quá xa so với trung bình cùng dự án nhưng vẫn nằm trong phân bố chung của toàn thị trường. Xóa nếu còn hạn mức.
- + Outlier toàn cục còn lại (global_only): Xóa sau cùng nếu vẫn chưa đạt giới hạn 5%.

Kết quả sau tầng lọc này số quan sát giảm xuống còn 5659 dòng với tỷ lệ xóa khoảng 5%. Cách tiếp cận này đảm bảo loại bỏ các nhiễu thực sự mà không làm mất đi các giao dịch đặc thù có giá trị cao - vốn rất quan trọng trong bài toán dự báo giá bất động sản.

4.4.2 Phân chia tập huấn luyện và tập kiểm tra

Tập dữ liệu được chia theo tỷ lệ 80/20 (huấn luyện/kiểm tra) sử dụng phân tầng theo phân khúc giá. Cụ thể, biến phân tầng được tạo bằng cách chia price_per_m2_vnd thành 4 nhóm: dưới 50 triệu, 50 - 100 triệu, 100 - 200 triệu và trên 200 triệu VNĐ/m². Chiến lược này đảm bảo phân phối phân khúc trong tập kiểm tra phản ánh đúng tập huấn luyện, tránh tình trạng tập kiểm tra bị lệch về một phân khúc giá cụ thể và làm sai lệch kết quả đánh giá mô hình.

Biến mục tiêu được biến đổi logarithm trước khi huấn luyện: $\log_price_m2 = \log_{1p}(price_per_m2_vnd/10^6)$. Phép biến đổi này giúp đưa phân phối lệch phải mạnh của giá bất động sản về gần phân phối chuẩn hơn, cải thiện độ ổn định của gradient trong quá trình tối ưu hóa mô hình.

4.4.3 Xử lý dữ liệu thiếu theo nhóm

Chiến lược imputation được thiết kế theo mô hình fit/apply tách biệt, đảm bảo không rò rỉ thông tin từ tập kiểm tra sang tập huấn luyện. Dưới đây là chi tiết cách xử lý cho từng nhóm thuộc tính, dựa trên phân tích đặc điểm dữ liệu và kết quả từ mục 4.3.4 và được trình bày trong Bảng 4.2.

Bảng B.4.3: Chiến lược xử lý dữ liệu thiếu theo nhóm

Nhóm thuộc tính	Chiến lược điền	Thứ tự ưu tiên
num_towers	Tạo flag is_null_towers trước khi fill; loại	Project → Global (riêng loại hình đặc biệt gán 0)

	không có tháp — 0; còn lại median theo dự án — median toàn cục	
Đặc điểm dự án (total_apartment, construction_density, land_area_ha)	Trung vị theo project_name — trung vị toàn cục	Project → Global
Thời gian (launch_year, handover_year)	Trung vị theo project_name — trung vị theo project_type — trung vị toàn cục	Project → Type → Global
Ownership	Gán nhãn "Khac" trực tiếp	Fallback cố định
Expired_at	Ở bước kiểm tra cuối cùng, expried_at sẽ được tự động fill bằng mode	

Một điểm đáng chú ý là biến `is_null_towers` được tạo ra trước khi imputation `num_towers`. Phân tích cho thấy khoảng 20% bản ghi có giá trị `num_towers` bị thiếu. Sự thiếu hụt này không hoàn toàn ngẫu nhiên (MNAR): phần lớn các trường hợp thiếu thuộc về các loại hình bất động sản không có cấu trúc tháp như biệt thự liền kề, shophouse và nhà mặt phố. Một số ít còn lại có thể do thiếu thông tin từ nguồn thu thập (MAR). Bằng cách tạo cờ nhị phân `is_null_towers` trước khi điền giá trị, mô hình có thể học được tín hiệu ẩn từ việc thiếu dữ liệu. Cụ thể, đối với các loại hình không có tháp, `num_towers` được thiết lập bằng 0; các trường hợp còn lại được impute theo thứ tự ưu tiên `project → type → global`.

4.4.4 Xây dựng đặc trưng mới (Feature Engineering)

Sau bước làm sạch dữ liệu và xử lý missing values, nghiên cứu tiếp tục thực hiện feature engineering nhằm tạo thêm các đặc trưng có khả năng phản ánh tốt hơn hành vi định giá của thị trường bất động sản. Các feature mới được xây dựng hoàn toàn từ thông tin đầu vào, không sử dụng target nhằm tránh data leakage.

Đầu tiên, nhóm feature liên quan đến thời gian đăng tin được tạo từ biến `posted_at`. Cụ thể, mô hình sinh thêm các biến `posted_month`, `posted_year` và `posted_quarter` nhằm phản ánh yếu tố mùa vụ và xu hướng thị trường theo thời gian. Đồng thời, biến `listing_age_days` được tính bằng khoảng cách giữa thời điểm snapshot dữ liệu và ngày đăng tin, thể hiện độ mới của listing trên thị trường. Các giá trị âm được clip về 0 để tránh sai lệch dữ liệu thời gian.

Bên cạnh đó, nghiên cứu xây dựng các feature liên quan đến vòng đời dự án. Biến `project_age_years` biểu diễn số năm kể từ thời điểm dự án khởi công đến thời điểm đăng bán. Trong khi đó, `years_to_handover` phản ánh khoảng thời gian từ lúc đăng bài tới thời điểm bàn giao căn hộ và được giới hạn trong khoảng $[-5, 10]$ để giảm ảnh hưởng của outlier. Ngoài ra, biến `build_duration` được tính bằng hiệu giữa `handover_year` và `launch_year`, đóng vai trò như một proxy cho quy mô và mức độ phức tạp của dự án. Các dự án có thời gian xây dựng dài thường thuộc nhóm quy mô lớn hoặc cao cấp hơn.

Ngoài ra, nghiên cứu xây dựng nhóm feature phản ánh quy mô tương đối của căn hộ trong cùng dự án. Trước hết, biến `proj_median_area` được tính bằng diện tích trung vị của tất cả các căn hộ thuộc cùng một dự án (`project_name`). Trong trường hợp dự án chưa xuất hiện trong tập huấn luyện, giá trị này được thay thế bằng diện tích trung vị toàn bộ tập dữ liệu nhằm đảm bảo tính nhất quán giữa tập huấn luyện và tập dự báo.

Từ đó, biến `area_ratio_in_proj` được xây dựng bằng tỷ lệ giữa diện tích căn hộ và diện tích trung vị của dự án. Feature này cho biết căn hộ có diện tích lớn hay nhỏ so với loại hình phổ biến trong cùng dự án. Giá trị lớn hơn 1 thể hiện căn hộ có quy mô lớn hơn mức trung vị của dự án, trong khi giá trị nhỏ hơn 1 cho thấy căn hộ thuộc nhóm diện tích nhỏ hơn mặt bằng chung. So với việc chỉ sử dụng diện tích tuyệt đối, biến này cung cấp thêm ngữ cảnh về vị trí tương đối của căn hộ trong cơ cấu sản phẩm của từng dự án, từ đó giúp mô hình nhận diện tốt hơn các căn hộ có khả năng được định giá cao hoặc thấp hơn mức thông thường.

Đối với nhóm đặc trưng không gian sống, mô hình tạo biến `room_total` bằng tổng số phòng ngủ và phòng tắm. Tiếp theo, `bed_bath_ratio` phản ánh tỷ lệ giữa số phòng ngủ và số phòng tắm nhằm mô tả cấu trúc căn hộ. Feature `area_per_room` được xây dựng bằng cách lấy diện tích căn hộ chia cho tổng số phòng cộng thêm 1, giúp mô hình nhận biết mức độ rộng rãi tương đối của không gian sinh hoạt.

Nghiên cứu cũng xây dựng feature tổng hợp tiện ích (`amenity_score`) bằng cách cộng các biến nhị phân như `has_mall`, `has_school`, `has_hospital`, `has_park`, `has_pool` và `has_parkinglot`. Feature này đại diện cho mức độ đầy đủ tiện ích nội khu và ngoại khu của dự án.

Đối với các biến khoảng cách, nghiên cứu tạo thêm các feature tổng hợp nhằm mô tả khả năng tiếp cận của căn hộ. Biến `location_tier` phân nhóm vị trí dựa trên khoảng cách tới CBD thành nhiều cấp độ từ 1 đến 5, trong đó vị trí gần trung tâm hơn sẽ có tier cao hơn. Các biến `dist_avg` và `dist_min` lần lượt biểu diễn khoảng cách trung bình và khoảng cách nhỏ nhất tới các tiện ích quan trọng như CBD, metro, sông hồ, cao tốc, sân bay, chợ, công viên và bệnh viện. Từ đó, biến `accessibility` được tính theo công thức nghịch đảo của `dist_avg`, phản ánh mức độ thuận tiện trong di chuyển và tiếp cận hạ tầng đô thị.

Ngoài các feature đơn lẻ, nghiên cứu còn xây dựng nhiều interaction features nhằm giúp mô hình học tốt hơn các mối quan hệ phi tuyến giữa các đặc trưng. Cụ thể:

Bảng B.4.4: Các biến tương tác được tạo từ các biến trước target encoding

Tên đặc trưng	Công thức	Mục đích
<code>area_x_dist_cbd</code>	<code>area_m2 * dist_cbd_km</code>	Tương tác diện tích và vị trí. Ví dụ căn hộ diện tích lớn nhưng nằm gần CBD thường có giá premium rất cao so với căn nhỏ ở cùng khu vực.
<code>area_x_bedrooms</code>	<code>area_m2 * bedrooms</code>	Tương tác diện tích và số phòng ngủ. Ví dụ căn hộ nhiều phòng ngủ nhưng diện tích nhỏ thường có mật

		độ sử dụng cao và giá/m ² thấp hơn căn rộng cùng số phòng.
cbd_x_amenity	$(1 / (\text{dist_cbd_km} + 0.5)) * \text{amenity_score}$	Tương tác vị trí và tiện ích. Ví dụ dự án gần trung tâm và có nhiều tiện ích thường có mức tăng giá mạnh hơn so với chỉ có một yếu tố riêng lẻ.
tier_x_amenity	$\text{location_tier} * \text{amenity_score}$	Tương tác phân khúc vị trí và tiện ích. Ví dụ khu vực tier cao kết hợp nhiều tiện ích nội khu thường thuộc phân khúc cao cấp và có giá bán cao hơn đáng kể.
tier_x_area	$\text{location_tier} * \text{area_m2}$	Tương tác phân khúc vị trí và diện tích. Ví dụ căn hộ có diện tích lớn và nằm ở khu vực tier cao thường có giá premium cao hơn đáng kể.

4.4.5 Log Transformation

Một số biến có phân phối lệch phải mạnh được áp dụng phép biến đổi logarit bằng hàm `log1p()` nhằm giảm độ lệch phân phối (skewness), hạn chế ảnh hưởng của các giá trị ngoại lệ và giúp mô hình học ổn định hơn. Các biến được xử lý bao gồm `area_m2`, `bedrooms`, `bathrooms`, `dist_river_lake_km`, `dist_market`, `construction_density`, `dist_highway_km` và `area_ratio_in_proj`. Đối với biến `area_ratio_in_proj`, phép biến đổi logarit tạo ra feature mới `log_area_ratio`, phản ánh quy mô tương đối của căn hộ so với diện tích trung vị của dự án trong khi vẫn kiểm soát được ảnh hưởng của các giá trị quá lớn. Sau biến đổi, các feature mới được lưu dưới dạng `log_*` và được sử dụng trong quá trình huấn luyện mô hình.

4.4.6 K-Fold Target Encoding

Target Encoding được áp dụng cho các biến có số lượng giá trị lớn gồm `project_name`, `ward` và `investor`. Thay vì chuyển đổi thành nhiều cột nhị phân như One-hot Encoding, phương pháp này biểu diễn mỗi nhóm bằng giá trị trung bình của biến mục tiêu tương ứng.

Để hạn chế hiện tượng target leakage, nghiên cứu sử dụng kỹ thuật K-Fold Target Encoding với $K=5$ folds. Trong mỗi fold, giá trị encoding của tập validation được tính từ $K-1$ folds còn lại thay vì sử dụng toàn bộ tập train. Sau đó, encoding cuối cùng cho tập test được tính dựa trên toàn bộ dữ liệu train.

Nhằm giảm hiện tượng overfitting đối với các nhóm có số lượng mẫu nhỏ, nghiên cứu áp dụng kỹ thuật smoothing trong quá trình Target Encoding. Ý tưởng này thường được sử dụng trong các thư viện mã hóa biến phân loại như `category_encoders.TargetEncoder`, trong đó giá trị encoding của mỗi nhóm được tính bằng cách kết hợp giá trị trung bình của riêng nhóm đó với giá trị trung bình toàn bộ dữ liệu (global mean). Ý nghĩa của smoothing là giúp các nhóm có ít quan sát không bị ảnh hưởng quá mạnh bởi các giá trị ngoại lệ. Ví dụ, nếu một phường chỉ có vài mẫu nhưng giá bất động sản trung bình rất cao, việc sử dụng trực tiếp mean của phường đó có thể làm mô hình học sai lệch. Khi áp dụng smoothing, giá trị encoding sẽ được kéo gần hơn về mức trung bình toàn cục, từ đó giúp mô hình ổn định và tổng quát hóa tốt hơn trên dữ liệu mới.

Sau khi Target Encoding, nghiên cứu tiếp tục xây dựng thêm các đặc trưng tương tác (Interaction Features) như `ward_te_x_area`, `ward_te_x_dist_cbd`, `ward_te_x_amenity`, `ward_te_x_log_area_ratio` và `proj_te_x_log_area_ratio` nhằm giúp mô hình học tốt hơn ảnh hưởng kết hợp giữa vị trí, dự án và diện tích căn hộ.

Bảng B.4.5: Các biến tương tác được tạo từ các biến sau target encoding

Tên đặc trưng	Công thức	Mục đích
<code>ward_te_x_area</code>	$\text{ward_te} * \text{log_area_m2}$	Tương tác mức giá khu vực và diện tích. Ví dụ căn hộ diện tích lớn nằm trong phường có mức giá

Tên đặc trưng	Công thức	Mục đích
		trung bình cao thường có giá/m ² cao hơn mặt bằng chung.
ward_te_x_dist_cbd	ward_te * dist_cbd_km	Tương tác mức giá khu vực và khoảng cách CBD. Ví dụ cùng khoảng cách đến trung tâm nhưng các phường vốn có mức giá cao vẫn duy trì giá bất động sản cao hơn.
ward_te_x_amenity	ward_te * amenity_score	Tương tác mức giá khu vực và tiện ích. Ví dụ khu vực cao cấp kết hợp nhiều tiện ích như mall, park, hospital thường tạo ra mức premium lớn hơn.
ward_te_x_log_area_ratio	ward_te * log_area_ratio	Tương tác mức giá khu vực và tỷ lệ diện tích. Ví dụ căn hộ có diện tích lớn bất thường trong khu vực đắt đỏ có thể là penthouse hoặc căn premium nên giá tăng mạnh.
proj_te_x_log_area_ratio	project_name_te * log_area_ratio	Tương tác dự án và tỷ lệ diện tích. Ví dụ căn hộ lớn hơn đáng kể so với diện tích phổ biến của dự án thường thuộc loại căn đặc biệt và có giá cao hơn.

4.4.7 One-hot Encoding

One-hot Encoding được áp dụng cho các biến phân loại có số lượng giá trị không quá lớn gồm: project_type, legal_status, furniture_status, direction, ownership và listing_type.

Đối với mỗi biến, các giá trị thiếu được thay bằng "Unknown", sau đó xây dựng vocabulary từ tập train và tạo các cột nhị phân tương ứng cho từng nhóm giá trị. Nhóm đầu tiên được loại bỏ nhằm tránh hiện tượng đa cộng tuyến. Toàn bộ vocabulary từ tập train tiếp tục được áp dụng thống nhất cho tập test để đảm bảo đồng nhất cấu trúc dữ liệu đầu vào giữa hai tập dữ liệu.

4.5 Kết quả xử lý

Sau khi hoàn tất toàn bộ quá trình tiền xử lý, tập dữ liệu cuối cùng có cấu trúc như sau:

- Số lượng quan sát: 5.659 dòng (giảm từ 5.983 dòng ban đầu, tương ứng tỷ lệ giảm khoảng 5,4%).
- Số lượng cột: 76 cột (bao gồm các biến gốc đã được làm sạch, các biến flag, các đặc trưng mới được xây dựng và các biến đã qua mã hóa).
- Chỉ mục (index): Được đánh lại từ 0 đến 5.595, liên tục, không có giá trị thiếu.

Tập dữ liệu này sẵn sàng để đưa vào huấn luyện các mô hình dự báo giá bất động sản (hồi quy tuyến tính, Random Forest, XGBoost, v.v.) với kỳ vọng đạt độ chính xác cao nhờ các bước xử lý chuyên sâu.

CHƯƠNG 5: XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH

5.1 Xây dựng mô hình

5.1.1 Lựa chọn lớp mô hình

Bài toán dự báo giá bất động sản trên mét vuông được định nghĩa là bài toán hồi quy có giám sát (supervised regression). Biến mục tiêu là $\log_{10}(\text{price_per_m2_vnd} / 10^6)$ nhằm đưa phân phối lệch phải mạnh của giá về dạng gần chuẩn hơn, cải thiện độ ổn định của quá trình tối ưu hóa.

Ba lớp mô hình Gradient Boosting được lựa chọn làm nền tảng của nghiên cứu là LightGBM (Microsoft, 2017), XGBoost (Chen & Guestrin, 2016) và CatBoost (Yandex, 2018). Ba mô hình này đều thuộc họ cây quyết định tăng cường gradient (Gradient Boosted Decision Trees), song khác nhau về thuật toán xây cây, cách xử lý dữ liệu và cơ chế regularization, tạo ra sự đa dạng cần thiết cho kỹ thuật ensemble.

LightGBM sử dụng chiến lược xây cây leaf-wise (best-first) thay vì level-wise, cho phép mỗi lần lặp ưu tiên mở rộng lá có mức giảm loss lớn nhất. Cách tiếp cận này thường cho kết quả tốt hơn trên cùng số lá nhưng dễ overfit hơn khi dữ liệu nhỏ, đòi hỏi kiểm soát num_leaves và min_child_samples cẩn thận.

XGBoost xây cây theo chiến lược level-wise (depth-first) với histogram approximation (tree_method="hist"), cân bằng giữa tốc độ và khả năng tổng quát hóa. Bộ regularization L1/L2 tường minh giúp kiểm soát độ phức tạp mô hình hiệu quả.

CatBoost sử dụng cây đối xứng (symmetric trees), có nghĩa là tất cả lá ở cùng độ sâu chia sẻ điều kiện tách giống nhau. Cấu trúc này tạo ra mô hình có tốc độ dự báo nhanh hơn và ít overfit hơn trên tập dữ liệu nhỏ. Ngoài ra, CatBoost triển khai ordered boosting - dùng hoán vị ngẫu nhiên để tính thống kê target, giảm target leakage trong quá trình huấn luyện.

Lý do không sử dụng Random Forest là vì các mô hình GBDT được chứng minh liên tục vượt trội trên dữ liệu bảng có kích thước vừa và nhỏ, đặc biệt khi kết hợp với feature engineering và target encoding như trong pipeline này. Random Forest có thể được bổ sung làm baseline trong nghiên cứu mở rộng.

5.1.2 Chiến lược đánh giá: K-Fold Cross Validation

Toàn bộ ba mô hình được đánh giá bằng chiến lược 5-Fold Cross Validation (KFold, shuffle=True, random_state=42) trên tập huấn luyện. Chiến lược này được

chọn thay vì hold-out validation đơn giản vì hai lý do. Thứ nhất, với khoảng 5000 bản ghi trong tập huấn luyện, mỗi fold train sử dụng khoảng 4000 mẫu và fold validation khoảng 1000 mẫu, đủ để cho ước lượng tổng quát hóa ổn định. Thứ hai, quá trình KFold cho phép mỗi mẫu dữ liệu lần lượt đóng vai trò validation đúng một lần, từ đó thu được các dự báo trên phần dữ liệu chưa được mô hình nhìn thấy trong quá trình huấn luyện. Các dự báo này được sử dụng để đánh giá hiệu suất mô hình và tính trọng số cho ensemble mà không cần tách riêng một validation set độc lập.

Trong mỗi fold, mô hình được huấn luyện với early stopping (patience = 150 vòng) trên validation fold tương ứng. Số cây tối ưu (best_iteration) được ghi lại sau mỗi fold. Sau khi hoàn thành 5 folds, mô hình cuối cùng được retrain trên toàn bộ tập huấn luyện với số cây bằng giá trị trung vị của 5 best_iteration, early stopping sẽ không sử dụng ở bước này để tận dụng tối đa dữ liệu có sẵn.

5.1.3 Thiết lập siêu tham số

Siêu tham số của ba mô hình được lựa chọn dựa trên đặc điểm của dataset (~5000 dòng) và điều chỉnh qua nhiều lần thử nghiệm để giảm overfit nhưng vẫn giữ được độ chính xác dự báo. Các tham số như độ sâu cây, số lá, regularization và subsampling được thiết kế theo hướng hạn chế mô hình học quá chi tiết trên tập huấn luyện. Bảng 5.1 tổng hợp toàn bộ siêu tham số được sử dụng cho LightGBM, XGBoost và CatBoost.

Bảng B.5.1: Siêu tham số của ba mô hình LightGBM, XGBoost và CatBoost

Tham số	LightGBM	XGBoost	CatBoost
Hàm mục tiêu	regression_l1 (MAE)	reg:absoluteerror	MAE
Learning rate	0.03	0.03	0.03
Độ sâu cây/Số lá	num_leaves = 127	max_depth = 7	depth = 7
Số cây tối đa	3000 (early stop)	3000 (early stop)	2000 (early stop)
Early stopping	150 rounds	150 rounds	150 rounds
Subsampling	bagging_fraction = 0.80 bagging_freq = 5	subsample = 0.80	-
Feature sampling	feature_fraction =	colsample_bytree =	-

	0.75	0.75	
L1 regularization	reg_alpha = 0.30	reg_alpha = 0.30	l2_leaf_reg = 5
L2 regularization	reg_lambda = 0.50	reg_lambda = 1.0	-
Min samples per leaf	min_child_samples = 15	min_child_weight = 10	-
Thuật toán xây cây	leaf-wise (best-first)	hist (histogram)	Symmetric trees

Cả ba mô hình đều dùng hàm mục tiêu MAE (L1) thay vì MSE (L2) để giảm ảnh hưởng của ngoại lệ giá. Learning rate 0.03 được chọn để cân bằng tốc độ hội tụ và khả năng tổng quát hóa.

Quyết định thiết kế quan trọng nhất là giảm num_leaves của LightGBM từ 256 xuống 127. Với mỗi fold huấn luyện chỉ có khoảng 4000 mẫu, num_leaves=256 cho phép cây phân nhánh quá mức, dẫn đến overfit cao. Ngưỡng 127 là giá trị hợp lý cho kích thước dataset này, được xác nhận qua việc gap $|CV R^2 - Test R^2|$ thu hẹp đáng kể so với phiên bản trước.

Đối với XGBoost, min_child_weight được tăng từ 5 lên 10, tức là mỗi lá phải chứa tổng Hessian tối thiểu bằng 10, tương đương với yêu cầu ít nhất ~10 mẫu có trọng số đáng kể mỗi lá, giúp chống overfit trên dataset nhỏ.

5.2 Tối ưu mô hình

5.2.1 Các cải tiến từ phiên bản v1 sang v2

Mô hình trong nghiên cứu này là phiên bản v2, được phát triển qua một quá trình cải thiện có hệ thống từ phiên bản trước (v1). Mỗi thay đổi được thực hiện dựa trên phân tích cụ thể về nguyên nhân lỗi, không phải thử sai ngẫu nhiên. Bảng 5.2 tổng hợp bảy cải tiến chính.

Bảng B.5.2: Các cải tiến từ phiên bản v1 sang v2

FIX	Nội dung thay đổi	Tác động kỳ vọng	Ghi chú
FIX 1	Loại dist_school khỏi dist_avg và feature set	Giảm nhiễu và tăng tính ổn định của mô hình	dist_school có Pearson correlation dương nhưng Spearman gần bằng 0, cho

			thấy tương quan giả do outlier
FIX 2	Bổ sung đặc trưng build_duration = handover_year - launch_year	Giúp mô hình học thêm thông tin về quy mô và tiến độ dự án	Dự án lớn hoặc phức tạp thường có thời gian xây dựng dài hơn
FIX 3	Tạo thêm interaction features như area_x_dist_cbd, area_x_bedrooms, cbd_x_amenity, ...	Hỗ trợ mô hình học tốt hơn các quan hệ phi tuyến	Dataset chỉ khoảng 5000 mẫu nên việc tạo interaction thủ công giúp mô hình ổn định hơn
FIX 4	Giảm num_leaves của LightGBM từ 256 xuống 127	Hạn chế overfitting và cải thiện khả năng tổng quát hóa	Mỗi fold chỉ có khoảng 4000 mẫu train nên cây quá lớn dễ học nhiều
FIX 5	Bổ sung CatBoost vào ensemble	Tăng diversity giữa các mô hình trong ensemble	CatBoost sử dụng symmetric trees và cơ chế học khác với LightGBM/XGBoost

5.2.2 Chiến lược early stopping và xác định số cây tối ưu

Early stopping với patience 150 vòng được áp dụng nhất quán cho cả ba mô hình trong giai đoạn CV. Khi một fold kết thúc, best_iteration được ghi lại. Sau khi hoàn thành tất cả 5 folds, giá trị trung vị của các best_iteration được dùng làm số cây cố định khi retrain trên toàn bộ tập huấn luyện.

Lý do dùng trung vị thay vì trung bình là để tránh ảnh hưởng của các fold có số cây bất thường (fold với validation set dễ hoặc khó hơn mức bình thường). Phương pháp này đảm bảo mô hình cuối cùng có số cây ổn định và tránh underfitting (quá ít cây) cũng như overfitting (quá nhiều cây).

5.2.3 Ensemble weighted theo kết quả cross-validation

Sau khi huấn luyện ba mô hình riêng lẻ, phương pháp weighted ensemble được áp dụng để kết hợp dự báo. Trọng số của từng mô hình được tính tự động dựa trên R^2 cross-validation của chính mô hình đó, theo công thức:

$$\hat{y}_{ens} = w_{lgb} * \hat{y}_{lgb} + w_{xgb} * \hat{y}_{xgb} + w_{cat} * \hat{y}_{cat}$$

Trong đó:

- $\hat{y}_{lgb}, \hat{y}_{xgb}, \hat{y}_{cat}$: dự đoán của LightGBM, XGBoost và CatBoost
- $w_{lgb}, w_{xgb}, w_{cat}$: trọng số của từng mô hình

Trọng số được tính dựa trên R^2 cross-validation: $w_i = \frac{R_i^2}{\sum_j R_j^2}$

Trong đó:

- R_i^2 : giá trị R^2 cross-validation của mô hình thứ i
- $\sum_j R_j^2$: tổng R^2 cross-validation của tất cả mô hình trong ensemble

Mô hình có R^2 cross-validation cao hơn sẽ được gán trọng số lớn hơn trong ensemble. Cách làm này giúp tận dụng điểm mạnh của từng mô hình đồng thời giảm variance và cải thiện khả năng tổng quát hóa trên tập test.

Sự đa dạng của ba mô hình đảm bảo rằng các lỗi của từng mô hình phần nào là độc lập, tạo nên hiệu ứng hiệu chỉnh lẫn nhau (error cancellation) trong ensemble.

5.3 Đánh giá mô hình

5.3.1 Kết quả Cross-Validation

Bảng 5.3 trình bày kết quả cross-validation của ba mô hình trên tập huấn luyện (80% dữ liệu). Cross-validation predictions được tổng hợp từ 5 folds, mỗi mẫu trong tập huấn luyện được dự báo đúng một lần bởi một mô hình không nhìn thấy mẫu đó trong quá trình học. Đây là ước lượng đáng tin cậy về hiệu suất tổng quát hóa.

Bảng B.5.3: Kết quả cross-validation trên tập huấn luyện và trọng số ensemble

Chỉ số	LightGBM	XGBoost	CatBoost
MAE (triệu/ m^2)	10.888 triệu/ m^2	11.001 triệu/ m^2	10.823 triệu/ m^2
R^2 (real-space)	0.8877	0.8849	0.8912

MdAPE (%)	6.43%	6.60%	6.66%
Số cây tối ưu (median)	1208	2502	1988
Trọng số ensemble	0.333	0.332	0.335

Kết quả trong Bảng 5.3 cho thấy ba mô hình đều đạt hiệu suất dự báo cao và khá ổn định trên tập huấn luyện thông qua đánh giá cross-validation. Trong đó, CatBoost đạt kết quả tốt nhất với MAE thấp nhất (10.823 triệu/ m^2) và R^2 cao nhất (0.8912), cho thấy khả năng học tốt các quan hệ phi tuyến trong dữ liệu bất động sản. LightGBM và XGBoost cũng cho kết quả tương đương với chênh lệch không lớn, phản ánh tính nhất quán giữa các mô hình boosting. Do hiệu suất của ba mô hình khá tương đồng nên trọng số ensemble được phân bổ gần như đồng đều (xấp xỉ 0.33 cho mỗi mô hình). Tổng ba trọng số bằng 1.0 nhằm đảm bảo dự báo cuối cùng là trung bình có trọng số của toàn bộ hệ mô hình, đồng thời tận dụng được điểm mạnh của từng thuật toán để cải thiện khả năng tổng quát hóa.

5.3.2 Kết quả trên tập kiểm tra (Test Set)

Tập kiểm tra (20% dữ liệu, 1132 bản ghi) không được sử dụng trong bất kỳ bước nào của quá trình huấn luyện hay feature engineering. Đây là đánh giá unbiased về hiệu suất mô hình trên dữ liệu chưa từng thấy. Kết quả được trình bày trong Bảng 5.4.

Bảng B.5.4: Kết quả đánh giá trên tập kiểm tra (test set)

Chỉ số	LightGBM	XGBoost	CatBoost	Ensemble
MAE (triệu/ m^2)	10.6040	10.4220	10.6570	10.3200
MedAE (triệu/ m^2)	4.0110	3.9930	3.9160	3.8000
RMSE (triệu/ m^2)	23.9800	23.9710	23.4010	23.0450
R^2	0.8936	0.8936	0.8986	0.9017
MdAPE (%)	6.0720	5.9720	5.9150	5.9040

Nhìn chung, mô hình Ensemble đạt kết quả tốt nhất trên hầu hết các chỉ số đánh giá, với MAE thấp nhất, R^2 cao nhất và MdAPE nhỏ nhất. Điều này cho thấy việc kết hợp LightGBM, XGBoost và CatBoost giúp tận dụng ưu điểm của từng mô hình riêng lẻ, từ đó cải thiện khả năng tổng quát hóa và tăng độ chính xác dự báo trên dữ liệu chưa từng thấy.

5.3.3 Kiểm tra overfit: Cross-Validation vs Test

Một trong những rủi ro chính khi xây dựng mô hình trên dataset nhỏ là overfit - mô hình học thuộc lòng tập huấn luyện nhưng không tổng quát hóa được. Bảng 5.5 so sánh R^2 cross-validation và R^2 Test để phát hiện overfit.

Bảng B.5.5: So sánh R^2 cross-validation (CV) và R^2 Test để kiểm tra overfit

Mô hình	R^2 CV	R^2 Test	Gap CV – Test	Đánh giá
LightGBM	0.8877	0.8936	0.0058	[< 0.02 ổn]
XGBoost	0.8849	0.8936	0.0087	[< 0.02 ổn]
Ensemble	0.8940	0.9017	0.0077	[< 0.02 ổn]

Kết quả trong Bảng 5.5 cho thấy cả ba mô hình đều có độ chênh lệch giữa R^2 cross-validation và R^2 Test rất nhỏ (đều < 0.01), thấp hơn đáng kể so với ngưỡng 0.02 thường được xem là dấu hiệu ổn định. Điều này chỉ ra rằng các mô hình không bị overfit đáng kể và có khả năng tổng quát hóa tốt trên dữ liệu chưa được nhìn thấy. Đặc biệt, mô hình Ensemble đạt R^2 Test cao nhất (0.9017), đồng thời vẫn duy trì gap nhỏ (0.0077), chứng tỏ việc kết hợp nhiều mô hình giúp cải thiện hiệu suất dự báo mà không làm tăng nguy cơ overfit.

5.3.4 Phân tích hiệu suất theo phân khúc giá

Thị trường bất động sản TP.HCM có phân phối giá lệch phải đáng kể, phần lớn giao dịch tập trung ở phân khúc 50 - 200 triệu VNĐ/ m^2 trong khi một số ít bất động sản cao cấp có giá trên 400 triệu/ m^2 . Do đó, hiệu suất tổng thể không phản ánh đầy đủ chất lượng mô hình ở từng phân khúc. Bảng 5.6 trình bày breakdown theo 5 phân khúc giá.

Bảng B.5.6: Hiệu suất Ensemble theo phân khúc giá trên tập kiểm tra

Phân khúc (triệu/ m^2)	n	MAE (tr/ m^2)	MdAPE (%)	R^2 log- space	R^2 real- space
< 50	290	4.641	6.77%	-0.163(log)	-0.501(real)
50 - 100	625	5.969	4.89%	0.283(log)	-0.256(real)
100 - 200	123	22.673	8.37%	-0.565(log)	-0.382(real)
200 - 400	90	36.867	10.15%	0.046(log)	0.315(real)

Thông qua số liệu, có thể thấy hiệu suất mô hình Ensemble thay đổi đáng kể giữa các phân khúc giá bất động sản. Mô hình hoạt động tốt nhất ở phân khúc 50 - 100 triệu VNĐ/ m^2 với MdAPE thấp nhất (4.89%) và R^2 log-space dương, cho thấy khả năng dự báo ổn định tại nhóm có số lượng mẫu lớn nhất. Bên cạnh đó, phân khúc 200 - 400 triệu VNĐ/ m^2 cũng đạt R^2 dương ở cả log-space và real-space, cho thấy mô hình vẫn có khả năng nắm bắt xu hướng giá ở nhóm bất động sản cao cấp dù số lượng mẫu không lớn. Ngược lại, các phân khúc dưới 50 triệu/ m^2 và 100 - 200 triệu/ m^2 có R^2 âm, phản ánh độ phân tán giá cao và sự khó khăn trong việc mô hình hóa chính xác từng bất động sản cụ thể. Ngoài ra, MAE tăng mạnh ở các phân khúc giá cao do sai số tuyệt đối có xu hướng tăng theo mức giá tài sản. Kết quả này chỉ ra rằng mô hình phù hợp hơn với các phân khúc có dữ liệu tương đối ổn định và đủ lớn, trong khi các nhóm ít mẫu hoặc biến động mạnh vẫn là thách thức đối với bài toán dự báo giá bất động sản.

5.3.5 Phân tích phần dư và căn cứ báo sai nhiều nhất

Để đánh giá sâu hơn hành vi của mô hình, nghiên cứu tiến hành phân tích phần dư (residual analysis) trên tập kiểm tra bằng cách tính sai số tuyệt đối giữa giá thực tế và giá dự báo của từng bất động sản. Kết quả cho thấy phần lớn các trường hợp dự báo sai lớn tập trung ở các phân khúc trung - cao cấp, đặc biệt là nhóm 100 - 200 triệu VNĐ/ m^2 và 200 - 400 triệu VNĐ/ m^2 . Cụ thể, số lượng căn có sai số tuyệt đối lớn hơn 50 triệu VNĐ/ m^2 lần lượt là 14 và 22 căn ở hai phân khúc này.

Các bất động sản có sai số cao chủ yếu thuộc các dự án lớn như Grand Marina Saigon, Empire City Thủ Thiêm, The Opera Residence và Vinhomes Golden River Ba

Son. Đây đều là các dự án cao cấp hoặc siêu cao cấp tại TP.HCM với cơ cấu sản phẩm rất đa dạng, bao gồm từ căn hộ tiêu chuẩn đến các loại hình premium, duplex hoặc penthouse có mức giá chênh lệch rất lớn ngay trong cùng một dự án. Ví dụ, một căn tại The Opera Residence có giá thực tế khoảng 54 triệu VNĐ/ m^2 nhưng được dự báo tới hơn 361 triệu VNĐ/ m^2 , tạo ra sai số hơn 306 triệu VNĐ/ m^2 . Điều này cho thấy mô hình gặp khó khăn khi các đặc điểm đầu vào hiện tại chưa thể mô tả đầy đủ sự khác biệt về vị trí tầng, view sông, nội thất, loại căn hoặc tiện ích riêng của từng sản phẩm cao cấp.

Ngoài ra, kết quả cũng phản ánh đặc trưng của thị trường bất động sản TP.HCM: cùng một khu vực hoặc cùng tên dự án có thể tồn tại nhiều phân khúc giá hoàn toàn khác nhau. Do dữ liệu huấn luyện chưa bao quát đầy đủ các yếu tố vi mô quyết định giá trị bất động sản cao cấp, mô hình dù đạt hiệu suất tổng thể cao vẫn xuất hiện các phần dư lớn ở nhóm tài sản có tính dị biệt cao và phân phối giá không đồng nhất.


5.4 Feature Importance

Để giải thích hành vi của mô hình ensemble và xác định các đặc trưng ảnh hưởng mạnh nhất đến dự báo giá bất động sản, nghiên cứu sử dụng SHAP (SHapley Additive exPlanations). SHAP là một phương pháp explainable AI dựa trên lý thuyết trò chơi, cho phép lượng hóa mức độ đóng góp của từng feature vào output của mô hình.

Trong nghiên cứu này, SHAP được áp dụng cho mô hình ensemble gồm LightGBM, XGBoost và CatBoost nhằm xác định mức độ quan trọng của các biến đầu vào, phân tích chiều tác động của từng feature và hiểu rõ hơn cách mô hình học các mối quan hệ phi tuyến trong dữ liệu bất động sản.

Kết quả được trình bày thông qua hai biểu đồ Global Feature Importance dựa trên $\text{mean}(|\text{SHAP value}|)$ và SHAP Summary Beeswarm Plot.

5.4.1 Global Feature Importance



Hình B.5.1: Global Feature Importance dựa trên $\text{mean}(|\text{SHAP value}|)$

Biểu đồ Global Feature Importance thể hiện mức độ ảnh hưởng trung bình của từng feature đến output mô hình thông qua giá trị $[\text{mean}(|\text{SHAP}|)]$. Giá trị này phản ánh độ lớn tác động trung bình của feature mà không xét chiều tác động dương hay âm.

Kết quả cho thấy `project_name_te` là feature quan trọng nhất trong toàn bộ mô hình ensemble, vượt trội đáng kể so với các biến còn lại. Điều này cho thấy tên dự án đóng vai trò rất lớn trong việc quyết định giá bất động sản. Biến này được xây dựng bằng Target Encoding trên trường `project_name`, cho phép mô hình học được mức giá

trung bình của từng dự án từ dữ liệu huấn luyện. Kết quả phản ánh thực tế thị trường khi các dự án cao cấp hoặc có thương hiệu mạnh thường có mức giá premium cao hơn đáng kể.


Feature quan trọng thứ hai là `listing_age_days`, đại diện cho số ngày tin đăng tồn tại trên hệ thống. Điều này cho thấy yếu tố thời gian đăng tin có ảnh hưởng lớn đến khả năng định giá. Các căn hộ được đăng lâu thường phản ánh mức giá chưa hấp dẫn hoặc khó giao dịch hơn so với các listing mới.

Các feature tiếp theo như `ward_te_x_area`, `posted_year`, `ward_te`, `area_x_dist_cbd`, `investor_te` cũng có mức độ ảnh hưởng đáng kể đến mô hình. Đáng chú ý, phần lớn các feature quan trọng nhất đều là Target Encoding features hoặc interaction features được feature engineering tạo ra. Điều này cho thấy mô hình không chỉ dựa trên các thuộc tính cơ bản như diện tích hay số phòng ngủ, mà còn học mạnh các quan hệ phi tuyến giữa vị trí, quy mô căn hộ, thương hiệu dự án và đặc điểm thị trường khu vực.

Ngoài ra, các biến khoảng cách như `dist_metro_km`, `dist_airport_km`, `log_dist_highway_km` có mức độ ảnh hưởng thấp hơn đáng kể. Điều này cho thấy trong dataset hiện tại, yếu tố phân khúc dự án và khu vực có vai trò quan trọng hơn so với các yếu tố accessibility đơn lẻ.

5.4.2 SHAP Summary Interpretation

SHAP Summary Beeswarm Plot cung cấp cái nhìn chi tiết hơn về cách từng feature ảnh hưởng đến output mô hình. Trong biểu đồ, trục ngang biểu diễn giá trị SHAP, giá trị dương làm tăng giá dự đoán, giá trị âm làm giảm giá dự đoán, màu đỏ biểu thị feature value cao còn màu xanh biểu thị feature value thấp.



Hình B.5.2: SHAP Summary Beeswarm Plot

Kết quả cho thấy `project_name_te` không chỉ là feature quan trọng nhất mà còn có phạm vi tác động rất lớn đến mô hình. Các dự án có giá trị encoding cao thường tạo ra SHAP value dương mạnh, qua đó làm tăng đáng kể giá dự báo. Điều này phản ánh khả năng mô hình nhận diện được “project premium” giữa các phân khúc bất động sản khác nhau.

Đối với `listing_age_days`, các listing tồn tại lâu trên hệ thống thường có SHAP value âm, tức làm giảm giá dự báo. Ngược lại, các tin đăng mới có xu hướng tác động dương lên mô hình. Kết quả này phù hợp với thực tế thị trường khi các sản phẩm có tính thanh khoản cao thường được giao dịch nhanh hơn.

Feature `ward_te_x_area` thể hiện interaction giữa mức giá khu vực và diện tích căn hộ. SHAP cho thấy các căn hộ lớn nằm trong các khu vực có mức giá cao thường tạo tác động dương đáng kể lên giá dự đoán. Điều này phản ánh premium kép giữa vị trí và quy mô căn hộ.

Biến `ward_te` cho thấy sự khác biệt rõ rệt giữa các khu vực địa lý. Những phường có encoding cao thường làm tăng mạnh giá trị dự báo, phản ánh ảnh hưởng của vị trí, hạ tầng, mức độ phát triển và chất lượng khu dân cư.

Feature `area_x_dist_cbd` giúp mô hình học được hiệu ứng giữa diện tích và khoảng cách tới trung tâm thành phố. Các giá trị cao của feature này thường tạo tác động âm, cho thấy các căn hộ lớn nhưng nằm xa CBD thường có giá/m² thấp hơn.

Ngoài ra, `investor_te` cũng có tác động đáng kể đến mô hình. Các chủ đầu tư uy tín tạo ra SHAP value dương lớn hơn, cho thấy mô hình đã học được “brand premium” của chủ đầu tư trên thị trường bất động sản.

Một số engineered features khác như `tier_x_area`, `proj_te_x_log_area_ratio`, `area_per_room` cũng thể hiện vai trò quan trọng trong việc giúp mô hình nắm bắt các nonlinear relationships trong dữ liệu. Các feature này cho phép mô hình phân biệt tốt hơn giữa căn hộ phổ thông, căn hộ cao cấp, penthouse hoặc các sản phẩm có thiết kế đặc biệt.


Tổng thể, kết quả SHAP cho thấy mô hình ensemble không chỉ học các đặc trưng vật lý cơ bản mà còn học rất mạnh các yếu tố ngữ cảnh thị trường thông qua vị trí, thương hiệu dự án, thương hiệu chủ đầu tư và các interaction features. Điều này góp phần cải thiện đáng kể khả năng dự báo giá và tăng tính giải thích của mô hình.

5.4.3 SHAP Dependence Plot Analysis

Để phân tích sâu hơn mối quan hệ giữa feature values và tác động của chúng lên output mô hình, nghiên cứu sử dụng SHAP Dependence Plots cho bốn feature quan trọng nhất của mô hình ensemble.

Khác với SHAP Summary Plot chỉ thể hiện mức độ ảnh hưởng tổng quát, dependence plot cho phép quan sát xu hướng tác động của từng feature, tính phi tuyến (nonlinearity), ngưỡng thay đổi (threshold effects) và interaction giữa các biến.

a. *project_name_te*



Hình B.5.3: Biểu đồ SHAP Dependence của biến *project_name_te*


Biểu đồ dependence của *project_name_te* cho thấy mối quan hệ dương rất rõ rệt giữa giá trị encoding của dự án và SHAP value. Khi *project_name_te* tăng, SHAP value cũng tăng mạnh, đồng nghĩa với việc mô hình dự báo giá cao hơn đối với các dự án có mức encoding lớn.

Đặc biệt, mối quan hệ này mang tính phi tuyến rõ rệt. Từ khoảng giá trị encoding ~4.2 trở lên, SHAP value tăng nhanh hơn đáng kể. Điều này cho thấy mô hình nhận diện được hiệu ứng “premium segmentation”, tức các dự án thuộc phân khúc cao cấp có mức tăng giá không tuyến tính.

Màu sắc trong biểu đồ đại diện cho *tier_x_area*, cho thấy interaction giữa phân hạng vị trí và diện tích căn hộ. Các điểm có *tier_x_area* cao thường tập trung ở vùng

SHAP dương lớn, cho thấy các căn hộ lớn nằm trong khu vực cao cấp tạo ra mức premium mạnh nhất.

b. listing_age_days



Hình B.5.4: Biểu đồ SHAP Dependence của biến listing_age_days


Biểu đồ dependence của listing_age_days cho thấy mối quan hệ âm khá mạnh giữa tuổi của listing và giá trị SHAP.

Các tin đăng mới (listing age thấp) thường có SHAP value dương hoặc gần 0, trong khi các listing tồn tại lâu có SHAP value âm đáng kể. Điều này phản ánh thực tế thị trường rằng các căn hộ hấp dẫn thường được giao dịch nhanh, còn các listing tồn tại lâu thường có mức giá kém cạnh tranh hoặc thanh khoản thấp hơn.

Ngoài ra, biểu đồ cũng cho thấy hiệu ứng diminishing impact. Sau khoảng 800 - 1000 ngày, SHAP value giảm chậm lại và tiến tới trạng thái ổn định. Điều này cho thấy khi listing đã tồn tại quá lâu, tác động tiêu cực bổ sung lên giá dự báo không còn tăng mạnh nữa.

Màu sắc biểu diễn ward_te_x_area, cho thấy interaction giữa giá trị khu vực và diện tích căn hộ. Tuy nhiên, interaction này không quá mạnh so với feature chính.

c. *ward_te_x_area*



Hình B.5.5: Biểu đồ SHAP Dependence của biến *ward_te_x_area*


Biểu đồ dependence của *ward_te_x_area* cho thấy đây là một engineered feature có tác động phi tuyến rất rõ rệt.

Khi giá trị feature thấp hơn khoảng 18, SHAP value chủ yếu âm hoặc gần bằng 0. Tuy nhiên, sau ngưỡng này, SHAP value tăng nhanh theo feature value. Điều này cho thấy các căn hộ lớn nằm ở khu vực có mức giá cao tạo ra premium đáng kể trong mô hình dự báo.

Màu sắc biểu diễn *total_apartment*, cho thấy interaction giữa mức độ phát triển của dự án và feature vị trí-diện tích. Các điểm có số lượng căn hộ lớn thường tập trung ở vùng SHAP dương cao hơn, cho thấy các đại dự án tại khu vực cao cấp có xu hướng được định giá cao hơn.

Biểu đồ này cũng phản ánh khả năng của mô hình ensemble trong việc học các nonlinear interactions phức tạp thay vì chỉ dựa trên các feature riêng lẻ.

d. *posted_year*



Hình B.5.6: Biểu đồ SHAP Dependence của biến posted_year

Biểu đồ dependence của posted_year cho thấy tác động của yếu tố thời gian đối với giá bất động sản.

Các năm cũ hơn (2023 - 2024) chủ yếu tạo SHAP value âm, trong khi các năm gần hiện tại (2025 - 2026) có xu hướng tạo SHAP value dương. Điều này phản ánh xu hướng tăng giá bất động sản theo thời gian trong dataset nghiên cứu.

Biểu đồ cũng cho thấy feature này hoạt động gần như theo dạng step-wise relationship thay vì liên tục hoàn toàn. Điều này hợp lý vì posted_year là biến rời rạc theo từng năm.

Màu sắc biểu diễn ward_te_x_amenity, cho thấy interaction giữa chất lượng khu vực và mức độ tiện ích. Các khu vực có nhiều tiện ích hơn thường tạo SHAP value cao hơn trong các năm gần đây, phản ánh vai trò ngày càng lớn của accessibility và urban amenities trong định giá bất động sản.


5.4.4 Phân tích các trường hợp đặc biệt bằng SHAP Waterfall Plot

Để hiểu rõ hơn cách mô hình ensemble đưa ra dự báo trong từng trường hợp cụ thể, nghiên cứu sử dụng SHAP Waterfall Plot nhằm phân tích đóng góp của từng feature vào prediction cuối cùng.

Waterfall Plot cho phép biểu diễn giá trị cơ sở của mô hình ($E[f(X)]$), mức đóng góp dương hoặc âm của từng feature và cách các feature kết hợp để tạo ra dự báo cuối cùng. Phương pháp này giúp giải thích prediction ở cấp độ từng quan sát (local interpretability), từ đó đánh giá hành vi thực tế của mô hình trong các trường hợp đặc biệt.

a. Trường hợp dự báo tốt nhất

Đối với trường hợp có sai số thấp nhất, giá thực tế và giá dự đoán đều bằng 66.9 triệu VNĐ/m². Kết quả Waterfall Plot cho thấy prediction được hình thành từ sự kết hợp của nhiều feature có tác động trái chiều nhưng tương đối cân bằng.



Hình B.5.7: SHAP Waterfall Plot cho trường hợp dự báo chính xác nhất của mô hình Ensemble

Trong trường hợp này, `project_name_te` là feature có tác động âm lớn nhất đến prediction với SHAP value khoảng (-0.11). Điều này cho thấy dự án của căn hộ này có mức encoding thấp hơn so với mặt bằng chung của các dự án cao cấp trong dataset, từ đó kéo giảm giá dự báo.

Tương tự, `ward_te_x_area` cũng tạo tác động âm đáng kể. Điều này cho thấy mặc dù căn hộ có diện tích phù hợp, nhưng combination giữa diện tích và mức giá khu vực chưa thuộc nhóm premium mạnh nhất.

Ngược lại, `listing_age_days` tạo tác động dương khoảng (+0.06). Với tuổi listing chỉ khoảng 37 ngày, mô hình xem đây là một tin đăng tương đối mới và có tính thanh khoản tốt hơn, từ đó làm tăng prediction.


Ngoài ra các biến `legal_status_Hợp đồng mua bán`, `posted_year = 2026` và `area_ratio_in_proj` cũng tạo tác động dương nhẹ lên giá dự báo. Trong khi đó, các feature như `area_per_room`, `ward_te` và 67 features khác có tác động âm nhỏ hơn và gần như đóng vai trò điều chỉnh cục bộ.

Điểm đáng chú ý là mặc dù tồn tại cả tác động dương và âm, tổng hợp các SHAP values đã giúp prediction cuối cùng gần như trùng khớp hoàn toàn với giá thực tế. Điều này cho thấy mô hình ensemble không phụ thuộc vào một feature duy nhất mà học được sự cân bằng giữa đặc điểm dự án, vị trí, tính thanh khoản và các interaction features.

Kết quả này phản ánh khả năng generalization tốt của mô hình trong các trường hợp dữ liệu “điển hình”, nơi các đặc trưng của căn hộ tương đối phù hợp với phân bố mà mô hình đã học trong quá trình huấn luyện.

b. Trường hợp dự báo tệ nhất

Đối với căn hộ có mức sai lệch lớn nhất, giá thực tế đạt 626.5 triệu VNĐ/ m^2 trong khi giá dự báo chỉ khoảng 380.1 triệu VNĐ/ m^2 , dẫn đến chênh lệch đáng kể theo hướng đánh giá thấp. Biểu đồ SHAP Waterfall cho thấy giá trị dự báo được hình thành từ nhiều yếu tố đóng góp cả chiều tăng lẫn chiều giảm, nhưng mức điều chỉnh chưa đủ mạnh để tiệm cận giá thực tế.



Hình B.5.8: SHAP Waterfall Plot cho trường hợp dự báo sai lớn nhất của mô hình Ensemble

Trong trường hợp này, project_name_te là biến có ảnh hưởng tích cực mạnh nhất, tuy nhiên vẫn không đủ để kéo dự đoán lên mức giá rất cao của căn hộ. Điều này cho thấy dự án thuộc nhóm cao cấp, nhưng encoding từ dữ liệu huấn luyện chưa phản ánh đầy đủ mức độ “premium” của tài sản trong thực tế.

Bên cạnh đó, ward_te_x_area và ward_te cũng đóng góp theo chiều dương vào prediction. Điều này phản ánh căn hộ nằm trong khu vực có mặt bằng giá tương đối cao, đồng thời hiệu ứng kết hợp giữa diện tích và mức giá khu vực cũng làm tăng định giá của mô hình. Tuy nhiên, mức tác động của các biến này vẫn khá nhỏ so với khoảng cách rất lớn giữa giá thực tế và giá dự báo.

Một số feature khác như investor_te, dist_metro_km và area_x_dist_cbd cũng góp phần nâng prediction. Khoảng cách tới metro tương đối gần cùng với đặc điểm chủ đầu tư giúp mô hình đánh giá căn hộ thuộc nhóm có vị trí và chất lượng tốt hơn trung bình.


Ngoài ra, `posted_year = 2026` và `listing_age_days` tạo tác động dương nhẹ, cho thấy mô hình xem đây là một listing mới với mức độ quan tâm thị trường còn cao.

Dù vậy, tổng hợp tất cả các SHAP values chỉ đưa prediction lên khoảng 380 triệu VNĐ/ m^2 , thấp hơn đáng kể so với mức thực tế 626.5 triệu VNĐ/ m^2 . Điều này cho thấy căn hộ có thể thuộc nhóm “outlier cao cấp”, nơi giá trị thực tế bị chi phối bởi những yếu tố khó lượng hóa hoàn toàn từ dữ liệu structured, chẳng hạn như độ hiếm của dự án, chất lượng hoàn thiện nội thất, tầm nhìn đặc biệt hoặc giá trị thương hiệu vượt xa phần lớn mẫu trong tập huấn luyện.

Kết quả này phản ánh giới hạn phổ biến của các mô hình machine learning trong bài toán định giá bất động sản: khi gặp những căn hộ nằm ngoài phân bố thông thường của dữ liệu, mô hình có xu hướng dự báo về gần vùng giá trung bình đã học được thay vì dự đoán tới các mức giá cực cao.

c. Trường hợp dự báo trung bình

Đối với trường hợp có sai số ở mức trung bình, giá thực tế của căn hộ đạt khoảng 59.3 triệu VNĐ/ m^2 , trong khi mô hình dự đoán khoảng 55.5 triệu VNĐ/ m^2 . Sai lệch chỉ khoảng 3.8 triệu VNĐ/ m^2 cho thấy Ensemble vẫn bám khá sát xu hướng giá thực tế dù tồn tại một số yếu tố làm giảm dự báo.



Hình B.5.9: SHAP Waterfall Plot cho trường hợp dự báo mức trung bình của mô hình Ensemble

Trong biểu đồ này, project_name_te tiếp tục là feature có ảnh hưởng mạnh nhất nhưng theo chiều âm, với SHAP value khoảng (-0.12). Điều này cho thấy dự án của căn hộ chưa thuộc nhóm có mức target encoding cao trong dataset, từ đó kéo giảm đáng kể giá dự báo.

Tác động âm cũng xuất hiện ở các biến ward_te_x_area, area_x_dist_cbd và direction_Đông - Bắc. Điều này cho thấy combination giữa vị trí, diện tích và khoảng cách tới khu vực trung tâm chưa đủ để mô hình đánh giá căn hộ thuộc nhóm có giá trị nổi bật. Đồng thời, hướng căn hộ cũng không phải yếu tố tạo premium mạnh trong dữ liệu huấn luyện.

Ngược lại, listing_age_days và posted_year = 2026 tạo ảnh hưởng dương nhẹ lên prediction. Tin đăng tồn tại khoảng 120 ngày cho thấy căn hộ vẫn duy trì sự hiện diện

trên thị trường, trong khi yếu tố thời gian đăng bán mới hơn giúp mô hình điều chỉnh tăng giá nhẹ theo xu hướng thị trường hiện tại.

Ngoài ra, các feature như `ward_te`, `log_area_m2` và 67 features khác chủ yếu đóng vai trò tinh chỉnh cục bộ với biên độ tác động nhỏ. Không có feature nào tạo ảnh hưởng quá vượt trội, cho thấy prediction được hình thành từ sự cộng hưởng của nhiều yếu tố mức độ vừa phải thay vì phụ thuộc vào một biến đơn lẻ.

Trường hợp này phản ánh cách mô hình hoạt động ổn định với các căn hộ thuộc phân khúc phổ biến trong dữ liệu. Khi các đặc trưng đầu vào nằm gần phân bố đã học, mô hình ensemble có khả năng duy trì sai số tương đối thấp và tạo ra prediction khá sát với giá trị thực tế.

CHƯƠNG 6: KẾT LUẬN

6.1 Kết luận chính của nghiên cứu

Nghiên cứu đã hoàn thành các mục tiêu đề ra ban đầu là xây dựng bộ dữ liệu bất động sản đa nguồn tại TP.HCM, thiết kế pipeline tiền xử lý kết hợp rule-based và LLM để chuẩn hóa dữ liệu phân loại, và phát triển mô hình ensemble dự báo giá có khả năng giải thích theo phân khúc thị trường. Kết quả cho thấy pipeline hai tầng đã giảm đáng kể tình trạng phân mảnh nhãn, điển hình là `furniture_status` từ gần 250 biến thể xuống chỉ còn một vài nhãn chuẩn hóa. Về mô hình, `weighted ensemble` từ `LightGBM`, `XGBoost` và `CatBoost` cho thấy hiệu suất được cải thiện so với từng mô hình đơn lẻ, đặc biệt trong việc tối ưu sai số trên dữ liệu có phân phối không đồng nhất.

Ở góc độ đánh giá theo phân khúc, mô hình hoạt động tốt nhất ở các phân khúc trung bình (50-100 triệu/m² và 200-400 triệu/m²), nơi dữ liệu đủ dày và phân phối ổn định, trong khi hiệu suất suy giảm ở phân khúc dưới 50 triệu/m² và 100-200 triệu/m² do dữ liệu thưa và biến động cao. Phân tích SHAP cho thấy tên dự án là đặc trưng quan trọng nhất, phản ánh hiệu ứng "thương hiệu" và phân khúc định vị; các đặc trưng tương tác như `ward_te_x_area` và `area_x_dist_cbd` chứng tỏ mô hình đã học được mối quan hệ phi tuyến giữa vị trí, diện tích và khoảng cách đến trung tâm.

Tổng thể, nghiên cứu đã bước đầu khẳng định tính khả thi của một quy trình phân tích dữ liệu bất động sản toàn diện dựa trên dữ liệu thực tế tại TP.HCM. Việc mở rộng sang các khu vực địa lý khác, bổ sung dữ liệu giao dịch thực sẽ giúp nâng cao độ tin cậy và giá trị ứng dụng của kết quả trong thực tiễn định giá và ra quyết định đầu tư.

6.2 Trả lời các câu hỏi nghiên cứu

RQ1: Mô hình nào phù hợp nhất đối với bộ dữ liệu bất động sản tại Thành phố Hồ Chí Minh trong nghiên cứu?

Trong bài toán dự báo giá bất động sản tại Thành phố Hồ Chí Minh, các mô hình dựa trên cơ chế boosting được xem là lựa chọn phù hợp nhất do khả năng xử lý tốt dữ liệu dạng bảng có cấu trúc phức tạp và quan hệ phi tuyến giữa các biến. Thay vì tập trung vào một thuật toán cụ thể, hướng tiếp cận mang tính kết hợp nhiều mô hình có đặc trưng học khác nhau được đánh giá là hợp lý hơn, bởi nó giúp giảm phụ thuộc vào một giả định đơn lẻ về dữ liệu, đồng thời cải thiện độ ổn định của kết quả dự báo trong các bối cảnh phân phối dữ liệu không đồng nhất. Điều này đặc biệt quan trọng trong bài

toán bất động sản, nơi mà sự biến động giữa các phân khúc giá và sự không đồng đều trong dữ liệu có thể làm giảm hiệu quả của một mô hình đơn.

RQ2: Những yếu tố nào có ảnh hưởng đáng kể đến giá bất động sản tại Thành phố Hồ Chí Minh?

Về các yếu tố ảnh hưởng đến giá bất động sản, có thể khái quát rằng giá trị tài sản hình thành từ sự kết hợp của nhiều nhóm yếu tố mang tính cấu trúc và bối cảnh. Trước hết, yếu tố liên quan đến dự án và chủ thể phát triển đóng vai trò như một lớp định vị giá trị, phản ánh mức độ uy tín, phân khúc và định hướng sản phẩm trên thị trường. Song song đó, yếu tố vị trí địa lý và đặc điểm khu vực là một trong những thành phần quan trọng nhất, thể hiện sự chênh lệch về hạ tầng, mức độ đô thị hóa, khả năng kết nối và giá trị không gian sống giữa các khu vực khác nhau trong thành phố. Bên cạnh đó, các đặc điểm nội tại của bất động sản như diện tích, cấu trúc và cách bố trí không gian bên trong căn hộ ảnh hưởng trực tiếp đến giá trị, nhưng thường không tồn tại mối quan hệ tuyến tính đơn giản mà phụ thuộc vào sự tương tác với bối cảnh xung quanh.

Ngoài các yếu tố tĩnh, yếu tố thời gian cũng đóng vai trò phản ánh trạng thái thị trường tại từng giai đoạn, bao gồm xu hướng tăng giảm chung của giá và mức độ sôi động của giao dịch. Đồng thời, đặc trưng về thanh khoản và mức độ hấp dẫn của tài sản trên thị trường cũng góp phần điều chỉnh giá trị quan sát được, bởi những bất động sản dễ giao dịch hoặc thu hút nhiều sự quan tâm thường có xu hướng phản ánh mức giá sát với kỳ vọng thị trường hơn. Tổng thể, giá bất động sản không được quyết định bởi một yếu tố đơn lẻ mà là kết quả của sự tương tác đa chiều giữa dự án, vị trí, đặc điểm tài sản và bối cảnh thị trường theo thời gian.


RQ3: Việc khai thác dữ liệu văn bản kết hợp với các mô hình AI/LLM hỗ trợ như thế nào trong quá trình xử lý dữ liệu khuyết và chuẩn hóa các thuộc tính?

Bối cảnh vấn đề: Trong quá trình thu thập dữ liệu bất động sản từ nhiều nền tảng khác nhau như Homedy, nhadatcanban và batdongsan, tập dữ liệu sau khi tổng hợp xuất hiện nhiều vấn đề về chất lượng dữ liệu. Các thuộc tính categorical quan trọng như direction, legal_status và furniture_status có tỷ lệ khuyết cao do nhiều tin đăng không được điền đầy đủ thông tin hoặc không thống nhất được cách biểu diễn dữ liệu giữa các nền tảng. Đặc biệt, thuộc tính hướng nhà (direction) có tỉ lệ khuyết thiếu lên đến hơn 59%, trong khi nhiều giá trị khác tồn tại dưới dạng nhiều hoặc biến thể ngôn ngữ khác

nhau như “Đông Nam”, “ĐN”, “dong nam” hoặc “Đông-Nam”. Ngoài ra, nhiều thông tin quan trọng không được điền trực tiếp vào trường thuộc tính mà xuất hiện trong tiêu đề và nội dung mô tả tin đăng dưới dạng văn bản tự do.

Ở tầng đầu tiên, hệ thống sử dụng các kỹ thuật khai thác văn bản dựa trên luật như regex normalization, keyword matching và substring matching để chuẩn hóa các giá trị có pattern rõ ràng. Các biểu diễn khác nhau như “Đông Nam”, “Đông-Nam”, “ĐN” hoặc “dong nam” được ánh xạ về cùng một nhãn chuẩn hóa là “Đông-Nam”. Tương tự, các cụm từ liên quan đến pháp lý như “sổ hồng riêng”, “SHR”, “pháp lý đầy đủ” được chuẩn hóa về nhóm “Sổ hồng/Sổ đỏ”. Cách tiếp cận này cho phép xử lý nhanh các trường hợp phổ biến với độ chính xác cao và không phát sinh chi phí inference từ mô hình AI.

Kết quả thực nghiệm cho thấy lớp rule-based có thể xử lý khoảng 41% dữ liệu thuộc tính direction, 82.8% thuộc tính legal_status và 77.1% thuộc tính furniture_status. Phần dữ liệu còn lại chủ yếu là các trường bị khuyết, mô tả không đầy đủ hoặc chứa thông tin ngữ nghĩa nằm trong tiêu đề và nội dung mô tả tin đăng. Điều này cho thấy rule-based hoạt động hiệu quả với các trường hợp có pattern cố định, tuy nhiên vẫn chưa đủ để xử lý toàn bộ dữ liệu thực tế.



Hình B.6.1: Tỷ lệ đóng góp của Rule-based và LLM trong quá trình xử lý dữ liệu


Biểu đồ trên cho thấy phần lớn dữ liệu được xử lý trực tiếp bởi lớp rule-based, trong khi LLM chỉ được sử dụng cho các trường hợp mà luật không thể nhận diện. Cách tiếp cận này giúp giảm đáng kể chi phí inference và tối ưu hiệu suất xử lý toàn pipeline.

Đối với các trường hợp mà rule-based không thể xử lý, hệ thống chuyển sang tầng thứ hai sử dụng mô hình ngôn ngữ lớn LLM (Groq/LLaMA) để suy luận ngữ nghĩa từ văn bản tự do. Thay vì chỉ dựa trên giá trị gốc của thuộc tính, mô hình được cung cấp thêm thông tin từ title và listing_description nhằm khai thác các tín hiệu ngữ cảnh ẩn trong nội dung tin đăng. Ví dụ, mặc dù trường direction có giá trị trống, tiêu đề tin đăng có thể chứa cụm “căn hộ hướng Đông Nam”, cho phép LLM suy luận và điền nhãn chuẩn hóa tương ứng. Tương tự, các mô tả như “nội thất cao cấp nhập khẩu Châu Âu” hoặc “bàn giao full đồ” được sử dụng để xác định tình trạng nội thất dù trường furniture_status ban đầu bị thiếu.

Điểm quan trọng của pipeline là mô hình LLM không được phép sinh tự do mà bị ràng buộc bởi tập nhãn hợp lệ được định nghĩa trước trong prompt. Nếu không đủ thông tin để suy luận, hệ thống sẽ trả về giá trị “Chưa rõ” thay vì tạo ra dữ liệu giả hoặc suy diễn không có căn cứ. Cơ chế này giúp giảm hiện tượng hallucination và đảm bảo độ tin cậy của dữ liệu sau xử lý.

Sau khi LLM hoàn thành bước suy luận, tầng verification tiếp tục sử dụng rule-based để kiểm tra chéo kết quả. Trong các trường hợp xảy ra xung đột giữa kết quả từ rule và output của LLM, hệ thống ưu tiên giá trị từ rule-based do đây là lớp xử lý xác định (deterministic layer) có độ tin cậy cao hơn. Cơ chế verification này giúp duy trì tính nhất quán của dữ liệu và hạn chế các lỗi suy luận từ mô hình ngôn ngữ.

Ngoài việc xử lý dữ liệu khuyết, pipeline còn cho thấy hiệu quả rõ rệt trong việc giảm phân mảnh dữ liệu categorical. Trước khi chuẩn hóa, cùng một ý nghĩa ngữ nghĩa được biểu diễn dưới rất nhiều biến thể khác nhau do sự khác biệt giữa các nền tảng crawl và cách nhập liệu của người dùng. Sau khi áp dụng pipeline hybrid, số lượng nhãn duy nhất giảm mạnh ở cả ba thuộc tính direction, legal_status và furniture_status.



Hình B.6.2: Mức độ giảm phân mảnh dữ liệu trước và sau chuẩn hóa

Biểu đồ trên cho thấy số lượng unique labels giảm đáng kể sau quá trình chuẩn hóa. Đặc biệt, thuộc tính furniture_status giảm từ gần 250 biến thể xuống chỉ còn vài nhãn chuẩn hóa chính. Kết quả này chứng minh pipeline đã xử lý hiệu quả tình trạng dữ liệu không đồng nhất và cải thiện đáng kể tính nhất quán của tập dữ liệu đầu ra.

So với việc chỉ sử dụng rule-based hoặc chỉ sử dụng LLM, pipeline kết hợp cho thấy nhiều ưu điểm hơn về hiệu quả xử lý và chi phí tính toán. Rule-based đảm nhiệm các trường hợp đơn giản với tốc độ cao và khả năng kiểm soát tốt, trong khi LLM hỗ trợ xử lý các trường hợp chứa thông tin ngữ nghĩa tự do mà phương pháp truyền thống không thể nhận diện. Nhờ đó, hệ thống có thể điền khuyết và chuẩn hóa gần như toàn bộ ba thuộc tính categorical quan trọng gồm direction, legal_status và furniture_status, trong khi vẫn duy trì được tính nhất quán và khả năng kiểm chứng của dữ liệu đầu ra.

Từ kết quả nghiên cứu, có thể kết luận rằng việc kết hợp khai thác dữ liệu văn bản với AI/LLM là hướng tiếp cận hiệu quả cho bài toán tiền xử lý dữ liệu bất động sản đa nguồn. Phương pháp này không chỉ nâng cao khả năng xử lý dữ liệu khuyết và chuẩn hóa thuộc tính mà còn góp phần cải thiện chất lượng dữ liệu đầu vào cho các bước phân tích và xây dựng mô hình downstream sau này.

RQ4: Hiệu suất của mô hình dự báo thay đổi như thế nào giữa các phân khúc giá khác nhau?

Hiệu suất dự báo của mô hình không đồng đều giữa các phân khúc giá mà có sự biến thiên rõ rệt theo đặc điểm dữ liệu từng nhóm. Nhìn chung, mô hình hoạt động tốt hơn ở các phân khúc có nhiều quan sát và phân phối giá ổn định, trong khi hiệu suất suy giảm ở những phân khúc ít dữ liệu hoặc có mức độ biến động cao. Cụ thể, ở các phân khúc trung bình - nơi tập trung phần lớn giao dịch - mô hình cho kết quả tương đối ổn định với sai số thấp và khả năng bám sát xu hướng giá tốt, do đây cũng là vùng mà mô hình có nhiều dữ liệu để học, các quan hệ giữa đặc trưng và giá ít bị nhiễu hơn.

Ngược lại, ở các phân khúc giá thấp hoặc giá rất cao, hiệu suất dự báo có xu hướng giảm rõ rệt. Với phân khúc thấp, giá trị bất động sản thường chịu ảnh hưởng mạnh bởi các yếu tố nhiễu hoặc đặc thù cục bộ, khiến quan hệ giữa đặc trưng và giá trở nên khó học và kém nhất quán. Trong khi đó, ở phân khúc cao cấp, số lượng mẫu thường ít hơn và mức độ dị biệt của từng tài sản lại rất lớn, dẫn đến việc mô hình khó nắm bắt đầy đủ các yếu tố “premium” hoặc giá trị đặc biệt của từng căn hộ. Điều này làm cho sai số tăng lên và độ giải thích của mô hình giảm tương đối so với các phân khúc phổ biến.

Tổng thể, có thể thấy mô hình phù hợp nhất với các phân khúc có dữ liệu dày và hành vi giá tương đối ổn định, trong khi các phân khúc quá thấp hoặc quá cao vẫn là thách thức do tính không đồng nhất và thiếu đại diện trong dữ liệu huấn luyện.

RQ5: Phương pháp weighted ensemble dựa trên cross-validation prediction có giúp cải thiện hiệu suất dự báo so với từng mô hình đơn lẻ hay không?

Trong nghiên cứu này, phương pháp weighted ensemble dựa trên kết quả cross-validation đã cho thấy xu hướng cải thiện hiệu suất dự báo so với từng mô hình đơn lẻ như LightGBM, XGBoost và CatBoost. Điều này có thể lý giải từ đặc điểm của từng mô hình trong bài toán: dù đều thuộc nhóm boosting, mỗi mô hình lại học dữ liệu theo cách khác nhau nên sẽ tạo ra những sai lệch không hoàn toàn giống nhau. Khi các dự báo này được kết hợp bằng trọng số dựa trên kết quả cross-validation, mô hình tổng hợp có khả năng tận dụng tốt hơn những điểm mạnh riêng của từng thuật toán, đồng thời hạn chế ảnh hưởng của các sai số cục bộ.

Việc sử dụng cross-validation để xác định trọng số đóng vai trò quan trọng vì nó phản ánh hiệu quả của mô hình trên các phần dữ liệu chưa được quan sát trong quá trình huấn luyện. Nhờ đó, mô hình có hiệu suất ổn định hơn sẽ được ưu tiên đóng góp lớn hơn vào dự báo cuối cùng, thay vì chỉ dựa trên một lần đánh giá đơn lẻ. Cách tiếp cận

này giúp tăng tính tin cậy của mô hình tổng hợp trong điều kiện dữ liệu bất động sản có sự biến động giữa các phân khúc và không gian đặc trưng phức tạp.

Nhờ cơ chế kết hợp này, sai số giữa các mô hình thành phần có xu hướng được điều hòa, giúp giảm biến động tổng thể của dự báo và cải thiện khả năng tổng quát hóa trên dữ liệu chưa từng thấy. Tuy nhiên, mức độ cải thiện vẫn mang tính tương đối, đặc biệt trong trường hợp các mô hình thành phần có chất lượng tương đương hoặc cùng mắc các dạng sai lệch tương tự trên những nhóm dữ liệu khó.

6.3 Hạn chế của nghiên cứu

Bên cạnh những kết quả đạt được, nghiên cứu còn tồn tại một số hạn chế cần được nhìn nhận thẳng thắn.

Về chất lượng dữ liệu đầu vào, dữ liệu sử dụng trong nghiên cứu là giá niêm yết trên các nền tảng trực tuyến, không phải giá giao dịch thực tế. Mức chênh lệch giữa hai loại giá này có thể dao động tùy theo giai đoạn thị trường và từng phân khúc, làm giảm tính chính xác của mô hình khi áp dụng vào bài toán định giá thực tế.

Về phạm vi thu thập, thời gian crawl chỉ kéo dài từ cuối tháng 4 đến giữa tháng 5 năm 2026, trong khi bộ dữ liệu chứa các tin đăng từ năm 2023 đến 2026. Sự không đồng đều về mật độ dữ liệu theo thời gian này khiến mô hình tiếp xúc nhiều hơn với điều kiện thị trường năm 2026 và có thể kém nhạy cảm hơn với các giai đoạn trước đó. Bên cạnh đó, chỉ có 100 trong số 156 dự án mục tiêu có tin đăng thực tế tại thời điểm crawl, nghĩa là một phần thị trường không được đại diện trong tập dữ liệu.

Về hiệu suất theo phân khúc, mô hình có sự phân hóa rõ rệt giữa các nhóm giá. Ở phân khúc dưới 50 triệu VNĐ/m² và 100-200 triệu VNĐ/m², R² âm cho thấy mô hình chưa nắm bắt được cấu trúc giá ở những nhóm này, một phần do số lượng mẫu chưa đủ lớn, một phần do đặc điểm giá ở hai phân khúc này chịu ảnh hưởng của nhiều yếu tố vi mô chưa được biểu diễn trong tập đặc trưng. Đây là hạn chế đáng chú ý nếu mô hình được sử dụng cho mục đích tư vấn ở những phân khúc cụ thể này.

Về cold-start problem, target encoding của project_name, ward và investor phụ thuộc vào tần suất xuất hiện trong tập huấn luyện. Các dự án mới ra mắt, phường ít giao dịch hoặc chủ đầu tư chưa từng xuất hiện trong dữ liệu đều được gán giá trị trung bình toàn cục, làm mất đi tính đặc thù của từng nhóm và giảm khả năng dự báo chính xác cho những trường hợp này.

Cuối cùng, các yếu tố kinh tế vĩ mô có tác động đáng kể đến thị trường bất động sản như lãi suất cho vay, chính sách tín dụng bất động sản, tiến độ phê duyệt pháp lý dự án hay các quyết định quy hoạch của thành phố đều chưa được đưa vào mô hình do hạn chế về dữ liệu và phạm vi nghiên cứu. Trong bối cảnh thị trường TP.HCM vốn nhạy cảm với các thay đổi chính sách, đây là một khoảng trống đáng kể nếu mục tiêu là xây dựng mô hình có khả năng dự báo dài hạn.

6.4 Hướng nghiên cứu tiếp theo

Từ những kết quả đạt được, có thể thấy vẫn còn rất nhiều hướng phát triển thú vị để mở rộng nghiên cứu này. Dữ liệu có thể được mở rộng phạm vi sang các khu vực khác như Hà Nội, Đà Nẵng hoặc là toàn Việt Nam để so sánh mức độ ảnh hưởng của các yếu tố giá giữa các vùng miền. Đồng thời, nghiên cứu cũng có thể khai thác sâu hơn về khía cạnh không gian.

Ngoài ra, khi có thêm dữ liệu thu thập theo nhiều đợt, có thể bổ sung chiều thời gian để phân tích xu hướng biến động giá theo mùa vụ hoặc theo các cú sốc thị trường. Các yếu tố vĩ mô như lãi suất, tăng trưởng tín dụng, chỉ số CPI và tốc độ đô thị hóa cũng có thể được đưa vào mô hình nhằm phản ánh bối cảnh kinh tế tác động đến thị trường bất động sản một cách toàn diện hơn.

PHẦN 3: QUÁ TRÌNH NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH DỰ BÁO GIÁ BẤT ĐỘNG SẢN

CHƯƠNG 1: VAI TRÒ CÁ NHÂN TRONG DỰ ÁN

Trong dự án xây dựng hệ thống dự báo giá bất động sản tại Thành phố Hồ Chí Minh, em đảm nhận vai trò nghiên cứu và phát triển mô hình Machine Learning. Công việc chính bao gồm khảo sát các nghiên cứu học thuật liên quan đến định giá bất động sản, thiết kế quy trình tiền xử lý dữ liệu, xây dựng các đặc trưng mới (feature engineering), triển khai các kỹ thuật mã hóa biến phân loại, huấn luyện mô hình dự báo và phân tích khả năng giải thích của mô hình bằng SHAP.

Ngoài việc triển khai các thuật toán có sẵn, em còn tham gia vào quá trình đánh giá và cải tiến mô hình qua nhiều vòng thử nghiệm. Các quyết định như xây dựng interaction features, áp dụng K-Fold Target Encoding, lựa chọn bộ mô hình LightGBM, XGBoost, CatBoost hay thiết kế weighted ensemble đều được thực hiện dựa trên quá trình tìm hiểu tài liệu chuyên ngành và thử nghiệm thực tế trên dữ liệu dự án.

Thông qua vai trò này, em có cơ hội tiếp cận quy trình phát triển một hệ thống dự báo hoàn chỉnh, từ giai đoạn nghiên cứu bài toán, xử lý dữ liệu đến đánh giá và giải thích kết quả mô hình.

CHƯƠNG 2: QUÁ TRÌNH NGHIÊN CỨU TÀI LIỆU

2.1 Nghiên cứu các mô hình định giá bất động sản

Trong giai đoạn đầu của dự án, em tiến hành khảo sát các nghiên cứu liên quan đến bài toán định giá bất động sản bằng học máy nhằm xác định hướng tiếp cận phù hợp cho bộ dữ liệu bất động sản tại Thành phố Hồ Chí Minh. Qua quá trình tìm hiểu tài liệu, em nhận thấy định giá bất động sản là một trong những bài toán được nghiên cứu rộng rãi trong lĩnh vực Data Science và PropTech (Property Technology), do nhu cầu xây dựng các hệ thống thẩm định giá tự động phục vụ ngân hàng, tổ chức tài chính, sàn giao dịch bất động sản và cơ quan quản lý nhà nước.

Trước đây, phương pháp phổ biến nhất trong lĩnh vực định giá bất động sản là mô hình Hedonic Pricing Model (HPM). Mô hình này giả định giá bất động sản được hình thành từ tập hợp các thuộc tính cấu thành như diện tích, vị trí, số phòng ngủ, khoảng cách tới trung tâm, chất lượng môi trường sống và các đặc điểm hạ tầng xung quanh. Tuy nhiên, nhiều nghiên cứu cho thấy thị trường bất động sản thực tế chứa rất nhiều mối quan hệ phi tuyến và tương tác phức tạp giữa các biến, khiến các mô hình hồi quy tuyến tính truyền thống gặp khó khăn trong việc mô tả đầy đủ hành vi định giá của thị trường. Khi số lượng biến tăng lên và mối quan hệ giữa các biến trở nên phức tạp hơn, độ chính xác của các mô hình tuyến tính thường suy giảm đáng kể.

Bên cạnh các mô hình hồi quy truyền thống, nhiều nghiên cứu đã thử nghiệm các phương pháp học máy như Decision Tree và Random Forest cho bài toán định giá bất động sản. Fan và cộng sự (2006) cho thấy Decision Tree có khả năng mô hình hóa các quy tắc định giá phi tuyến tốt hơn so với hồi quy tuyến tính. Antipov và Pokryshevskaya (2012) áp dụng Random Forest trong định giá căn hộ và ghi nhận hiệu suất dự báo được cải thiện đáng kể.

Trong số các hướng tiếp cận hiện đại, nghiên cứu “An Application of XGBoost, LightGBM, CatBoost Algorithms on House Price Appraisal System” của Hong (2020) là tài liệu có ảnh hưởng lớn nhất đến định hướng phát triển mô hình trong đề tài này. Nghiên cứu sử dụng 620617 giao dịch căn hộ tại Seoul trong giai đoạn 2009 - 2019 để so sánh mô hình Hedonic truyền thống với ba thuật toán Gradient Boosting hiện đại gồm XGBoost, LightGBM và CatBoost.

Kết quả nghiên cứu cho thấy các mô hình Gradient Boosting vượt trội đáng kể so với mô hình Hedonic. Trong khi mô hình Hedonic đạt MAPE khoảng 11,5%, các mô hình XGBoost, LightGBM và CatBoost chỉ đạt lần lượt khoảng 3,7%, 3,8% và 3,6%. Đồng thời, hệ số xác định R^2 của ba mô hình học máy đều đạt trên 0,98, cao hơn đáng kể so với mô hình truyền thống.

Một phát hiện đáng chú ý của nghiên cứu là CatBoost đạt hiệu suất dự báo cao nhất trong ba thuật toán, không chỉ về sai số trung bình mà còn về mức độ ổn định của dự báo. Tần suất xuất hiện các dự báo ngoại lệ (outliers) của CatBoost thấp hơn so với XGBoost và LightGBM, cho thấy khả năng tổng quát hóa tốt hơn trên dữ liệu bất động sản thực tế.

Ngoài ra, nghiên cứu còn chứng minh rằng việc kết hợp nhiều mô hình thông qua kỹ thuật Ensemble có thể tiếp tục cải thiện hiệu suất dự báo. Tác giả xây dựng mô hình Soft Voting Ensemble bằng cách lấy trung bình dự báo của XGBoost, LightGBM và CatBoost. Kết quả cho thấy Ensemble đạt MAPE thấp hơn từng mô hình riêng lẻ, cho thấy các sai số đặc trưng của từng thuật toán có thể được bù trừ lẫn nhau khi kết hợp.

Sau khi nghiên cứu tài liệu trên, em nhận thấy có nhiều điểm tương đồng giữa bài toán trong nghiên cứu của Hong (2020) và bài toán dự báo giá căn hộ tại Thành phố Hồ Chí Minh. Cả hai đều là bài toán hồi quy trên dữ liệu bảng (tabular data), trong đó giá bất động sản chịu ảnh hưởng đồng thời của vị trí, quy mô căn hộ, đặc điểm dự án và các yếu tố hạ tầng xung quanh. Đồng thời, các thuật toán Gradient Boosting được đánh giá là đặc biệt phù hợp với dữ liệu có cấu trúc hỗn hợp giữa biến số và biến phân loại.

Từ những kết quả nghiên cứu đó, em quyết định lựa chọn ba thuật toán XGBoost, LightGBM và CatBoost làm nền tảng cho hệ thống dự báo giá bất động sản của đề tài. Bên cạnh đó, em cũng kế thừa ý tưởng sử dụng Ensemble Learning nhằm khai thác tính đa dạng giữa các mô hình để nâng cao độ chính xác và khả năng tổng quát hóa. Tuy nhiên, thay vì áp dụng trực tiếp kiến trúc của nghiên cứu gốc, em tiếp tục phát triển thêm nhiều bước tiền xử lý dữ liệu, feature engineering, target encoding, interaction features và chiến lược weighted ensemble phù hợp với đặc điểm của bộ dữ liệu bất động sản tại Việt Nam.

2.2 Nghiên cứu các biến tương tác

Nghiên cứu của Fik, Ling và Mulligan (2003) cho rằng ảnh hưởng của các thuộc tính bất động sản không cố định trên toàn bộ thị trường mà thay đổi theo vị trí địa lý. Thay vì xem diện tích, tuổi công trình hay các đặc điểm cấu trúc là những yếu tố có tác động độc lập, các tác giả đề xuất mô hình hóa sự tương tác giữa vị trí và các thuộc tính vật lý của bất động sản nhằm phản ánh chính xác hơn cơ chế hình thành giá. Kết quả thực nghiệm cho thấy việc đưa các hiệu ứng tương tác vào mô hình giúp cải thiện đáng kể khả năng dự báo giá nhà so với các mô hình hedonic truyền thống.

Quan điểm này tiếp tục được củng cố bởi nghiên cứu GeoShapley của Li (2023). Thông qua việc giải thích mô hình XGBoost bằng phương pháp GeoShapley trên dữ liệu nhà ở Seattle, tác giả cho thấy tác động của nhiều đặc trưng không hoàn toàn cố định mà thay đổi theo bối cảnh vị trí. Đặc biệt, hiệu ứng tương tác giữa tuổi công trình và vị trí ($\text{Age} \times \text{GEO}$) cho thấy nhà cũ thường làm giảm giá trị bất động sản trên toàn thị trường, nhưng tại một số khu vực trung tâm lịch sử như Queen Anne hay Capitol Hill, các bất động sản lâu năm lại được định giá cao hơn. Kết quả này chứng minh rằng giá trị kinh tế của một thuộc tính phụ thuộc không chỉ vào bản thân thuộc tính đó mà còn vào môi trường không gian nơi bất động sản tọa lạc.

Từ các nhận định trên, em xây dựng một số interaction features như `area_x_dist_cbd`, `tier_x_area`, `cbd_x_amenity`, `ward_te_x_area` và `ward_te_x_dist_cbd`. Các biến này được thiết kế nhằm phản ánh giả thuyết rằng tác động của diện tích, tiện ích hoặc khả năng tiếp cận không hoàn toàn độc lập mà phụ thuộc vào bối cảnh vị trí của bất động sản. Chẳng hạn, cùng một diện tích căn hộ nhưng nằm gần trung tâm thành phố hoặc trong khu vực có mức giá cao sẽ tạo ra giá trị kinh tế khác biệt so với các khu vực còn lại. Tương tự, giá trị của hệ thống tiện ích thường được khuếch đại khi kết hợp với các vị trí có khả năng tiếp cận tốt hoặc thuộc phân khúc cao cấp.

Ngoài ra, việc xây dựng các biến tương tác còn phù hợp với đặc điểm của các mô hình cây tăng cường như LightGBM, XGBoost và CatBoost. Mặc dù các thuật toán này có khả năng tự học các mối quan hệ phi tuyến, việc bổ sung trước các interaction features giúp cung cấp cho mô hình những tín hiệu kinh tế đã được xác định từ lý thuyết và các nghiên cứu trước, từ đó hỗ trợ quá trình học hiệu quả hơn trên tập dữ liệu có quy mô không quá lớn. Các biến tương tác được kỳ vọng giúp mô hình nhận diện tốt hơn

các hiệu ứng premium thường xuất hiện trên thị trường bất động sản, chẳng hạn như hiệu ứng kết hợp giữa vị trí và diện tích hoặc giữa vị trí và mức độ tiện ích của dự án.

2.3 Nghiên cứu về phương pháp Target Encoding cho các biến phân loại có số lượng giá trị lớn

Trong bài toán định giá bất động sản, nhiều thuộc tính phân loại như tên dự án (`project_name`), phường (`ward`) hay chủ đầu tư (`investor`) có số lượng giá trị rất lớn. Nếu sử dụng One-Hot Encoding, số chiều dữ liệu sẽ tăng mạnh, làm dữ liệu trở nên thưa và gây khó khăn cho các mô hình học máy. Để giải quyết vấn đề này, nghiên cứu của Daniele Micci-Barreca (2001) đã đề xuất cơ chế mã hóa dựa trên thống kê của biến mục tiêu dành cho các thuộc tính phân loại có lực lượng lớn.

Ý tưởng cốt lõi của phương pháp là thay thế mỗi giá trị phân loại bằng một đại lượng số phản ánh mối quan hệ giữa giá trị đó và biến mục tiêu. Đối với bài toán dự báo có biến mục tiêu liên tục, mỗi giá trị của thuộc tính phân loại được thay thế bằng giá trị trung bình của biến mục tiêu tương ứng trong nhóm đó. Nhờ đó, các thuộc tính phân loại được chuyển đổi thành các biến số liên tục nhưng vẫn bảo toàn phần lớn thông tin dự báo mà thuộc tính gốc mang lại.

Bài báo cũng chỉ ra rằng việc sử dụng trực tiếp giá trị trung bình của biến mục tiêu cho từng nhóm có thể dẫn đến hiện tượng overfitting, đặc biệt đối với các nhóm có số lượng quan sát nhỏ. Để khắc phục vấn đề này, tác giả áp dụng cơ chế shrinkage theo hướng Empirical Bayes, trong đó giá trị trung bình của từng nhóm được kết hợp với giá trị trung bình toàn bộ tập dữ liệu. Những nhóm có ít quan sát sẽ được điều chỉnh mạnh hơn về phía trung bình toàn cục, trong khi các nhóm có nhiều quan sát sẽ giữ lại nhiều thông tin đặc trưng hơn. Cơ chế này giúp tạo ra các biến mã hóa ổn định và có khả năng tổng quát hóa tốt hơn trên dữ liệu mới.

Dựa trên định hướng của Micci-Barreca (2001), nghiên cứu này áp dụng K-Fold Target Encoding cho các biến `project_name`, `ward` và `investor`. Thay vì tính giá trị mã hóa trên toàn bộ tập huấn luyện, dữ liệu được chia thành nhiều fold và giá trị target encoding của mỗi fold được tính từ các fold còn lại. Cách tiếp cận này giúp hạn chế hiện tượng rò rỉ thông tin, đồng thời vẫn khai thác được thông tin giá trị trung bình của giá bất động sản theo từng dự án, khu vực và chủ đầu tư. Các biến mới được tạo gồm `project_te`, `ward_te` và `investor_te`, phản ánh mức giá đặc trưng của từng nhóm phân

loại và cung cấp cho mô hình nhiều thông tin dự báo hơn so với các phương pháp mã hóa truyền thống.

CHƯƠNG 3: QUÁ TRÌNH CẢI TIẾN MÔ HÌNH

3.1 Khám phá dữ liệu và xác định hướng tiền xử lý

Trong giai đoạn đầu, em tiến hành khảo sát phân phối của các biến số liên tục thông qua histogram, boxplot và các chỉ số thống kê mô tả. Kết quả cho thấy nhiều biến như `area_m2`, `bedrooms`, `bathrooms`, `dist_river_lake_km`, `dist_market`, `construction_density`, `dist_highway_km` có phân phối lệch phải, xuất hiện một số giá trị rất lớn so với phần còn lại của dữ liệu. Điều này làm cho phân phối dữ liệu không tuân theo dạng gần chuẩn và có thể gây khó khăn cho quá trình học của mô hình. Vậy nên, để giảm ảnh hưởng của các giá trị cực đoan và ổn định phương sai, em áp dụng phép biến đổi logarit giúp các mô hình Gradient Boosting học tốt hơn trên toàn bộ dải giá trị.

3.2 Phát hiện tầm quan trọng đặc biệt của `project_name`

Kế tiếp, em nhận thấy tên dự án (`project_name`) cũng có thể là một biến đặc biệt quan trọng đối với giá bất động sản.

Để kiểm chứng giả thuyết này, em thực hiện kiểm định ANOVA nhằm đánh giá sự khác biệt về giá giữa các dự án. Kết quả thu được là $F\text{-statistic} = 253.1$ và $p\text{-value}$ xấp xỉ 0. Giá trị F rất lớn cùng $p\text{-value}$ gần bằng 0 cho thấy sự khác biệt về giá giữa các dự án có ý nghĩa thống kê rất mạnh. Nói cách khác, chỉ riêng yếu tố dự án đã có khả năng giải thích đáng kể sự biến động của giá căn hộ.

Tuy nhiên, `project_name` có số lượng giá trị rất lớn nên việc áp dụng One-Hot Encoding sẽ làm dữ liệu trở nên thừa và làm tăng số chiều của mô hình. Sau khi nghiên cứu phương pháp Target Encoding, em tiến hành mã hóa `project_name` bằng giá trị trung bình của giá bất động sản theo từng dự án. Hệ số tương quan của `project_te` là 0.8347, đồng nghĩa với việc trở thành giá trị lớn nhất trong toàn bộ tập dữ liệu, cho thấy thông tin về dự án mang sức mạnh dự báo vượt trội so với các đặc trưng vật lý hoặc khoảng cách. Từ kết quả này, em xác định Target Encoding của `project_name` là một trong những bước tiền xử lý quan trọng nhất của toàn bộ hệ thống.

3.3 Loại bỏ đặc trưng gây nhiễu

Trong quá trình phân tích tương quan, em phát hiện một trường hợp đặc biệt đối với biến `dist_school`. Kết quả tính toán cho thấy Pearson Correlation của `dist_school` là +0.319, còn Spearman Correlation = -0.009. Hai chỉ số đưa ra kết luận hoàn toàn trái ngược nhau.

Nếu Pearson cho thấy khoảng cách tới trường học có tương quan dương tương đối mạnh với giá bất động sản thì Spearman gần như bằng 0 lại cho thấy không tồn tại quan hệ đơn điệu giữa hai biến.

Sau khi kiểm tra trực quan bằng scatter plot, em nhận thấy kết quả Pearson bị ảnh hưởng bởi một số dự án cao cấp nằm xa trường học nhưng vẫn có giá rất cao. Các quan sát ngoại lệ này làm xuất hiện tương quan tuyến tính giả tạo. Trong khi đó, Spearman, vốn ít nhạy cảm với outlier hơn, cho thấy `dist_school` gần như không mang thông tin dự báo thực sự. Từ phân tích này, em quyết định loại bỏ `dist_school` khỏi tập đặc trưng nhằm giảm nhiễu cho mô hình.

3.4 Bổ sung các biến tương tác sau khi tham khảo tài liệu nghiên cứu

Sau khi hoàn thành phiên bản mô hình đầu tiên, em tiếp tục khảo sát các nghiên cứu về định giá bất động sản nhằm tìm kiếm những yếu tố chưa được khai thác.

Từ nghiên cứu của Fik và cộng sự (2003) cũng như nghiên cứu GeoShapley của Li (2024), em đặt giả thuyết rằng giá trị của diện tích, tiện ích và khả năng tiếp cận không hoàn toàn độc lập mà phụ thuộc vào bối cảnh vị trí của bất động sản. Dựa trên giả thuyết đó, em mới xây dựng thêm các biến tương tác.

Sau khi huấn luyện lại mô hình với tập đặc trưng mở rộng này, các chỉ số đánh giá đều cải thiện so với phiên bản trước đó. Đồng thời, nhiều biến tương tác xuất hiện trong nhóm feature có mức độ ảnh hưởng cao theo kết quả SHAP. Kết quả này cho thấy biến tương tác đã giúp mô hình mô tả tốt hơn những hiệu ứng premium thường xuất hiện trên thị trường bất động sản.

CHƯƠNG 4: ĐỊNH HƯỚNG PHÁT TRIỂN ĐỀ TÀI

Mặc dù mô hình xây dựng trong đề tài đã đạt được kết quả dự báo tương đối tốt, vẫn còn một số hướng phát triển có thể được nghiên cứu trong tương lai nhằm nâng cao hiệu quả của hệ thống.

Trước hết, nghiên cứu hiện tại chủ yếu khai thác các thuộc tính có cấu trúc như diện tích, vị trí, tiện ích và thông tin dự án. Trong khi đó, các tin đăng bất động sản còn chứa nhiều thông tin giá trị dưới dạng văn bản như tiêu đề (title) và mô tả (description). Các nội dung này thường phản ánh những đặc điểm khó lượng hóa bằng dữ liệu số, chẳng hạn như chất lượng nội thất, tầm nhìn hoặc các lợi thế đặc biệt của bất động sản. Do đó, trong tương lai có thể kết hợp các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) để trích xuất đặc trưng từ dữ liệu văn bản và tích hợp vào mô hình dự báo.

Bên cạnh đó, quá trình tối ưu tham số trong đề tài hiện chủ yếu được thực hiện dựa trên kinh nghiệm và các vòng thử nghiệm thủ công. Các nghiên cứu tiếp theo có thể áp dụng phương pháp tối ưu siêu tham số tự động như Optuna để tìm kiếm tham số một cách hiệu quả hơn. Điều này có thể giúp cải thiện hiệu suất mô hình đồng thời giảm đáng kể thời gian thử nghiệm và tinh chỉnh.

Ngoài ra, việc tiếp tục mở rộng dữ liệu và cập nhật mô hình định kỳ theo sự thay đổi của thị trường cũng là một hướng phát triển cần thiết nhằm duy trì độ chính xác và khả năng ứng dụng thực tế của hệ thống trong dài hạn.

CHƯƠNG 5: KIẾN THỨC, KINH NGHIỆM TÍCH LŨY ĐƯỢC

Quá trình thực hiện đề tài giúp em hiểu rõ hơn rằng xây dựng một mô hình dự báo không đơn thuần là lựa chọn một thuật toán tốt rồi đưa dữ liệu vào huấn luyện. Trong giai đoạn đầu, em dành khá nhiều thời gian để tìm kiếm các mô hình có độ chính xác cao và tập trung vào việc tối ưu tham số. Tuy nhiên, sau nhiều lần thử nghiệm, em nhận ra rằng hiệu quả của mô hình phụ thuộc rất lớn vào chất lượng dữ liệu và cách biểu diễn thông tin trong dữ liệu.

Một kinh nghiệm quan trọng em rút ra được là cần dành nhiều thời gian cho việc khám phá dữ liệu trước khi xây dựng mô hình. Thông qua quá trình phân tích dữ liệu, em phát hiện nhiều hiện tượng mà ban đầu khó có thể nhận ra chỉ bằng cảm quan, chẳng hạn như một số biến có tương quan cao nhưng thực chất không mang nhiều ý nghĩa dự báo do bị ảnh hưởng bởi các giá trị ngoại lệ. Điều này giúp em hiểu rằng không phải mọi kết quả thống kê đều có thể được sử dụng ngay mà cần được kiểm chứng dưới nhiều góc độ khác nhau.

Trong quá trình nghiên cứu, em cũng nhận thấy rằng việc hiểu bản chất của bài toán quan trọng không kém việc hiểu thuật toán. Giá bất động sản không chỉ phụ thuộc vào từng đặc trưng riêng lẻ mà còn chịu ảnh hưởng bởi sự kết hợp giữa nhiều yếu tố như vị trí, diện tích, khả năng tiếp cận và đặc điểm của dự án. Từ việc đọc các tài liệu nghiên cứu và đối chiếu với dữ liệu thực tế, em dần hình thành thói quen đặt ra các giả thuyết về dữ liệu, sau đó kiểm chứng bằng thực nghiệm thay vì chỉ dựa trên trực giác.

Một bài học khác em tích lũy được là không nên đánh giá mô hình chỉ dựa trên kết quả đạt được ở một lần huấn luyện. Trong nhiều trường hợp, một mô hình có kết quả rất cao nhưng nguyên nhân đến từ việc vô tình sử dụng những thông tin mà mô hình sẽ không có khi áp dụng trong thực tế. Điều này giúp em hiểu sâu hơn về tầm quan trọng của việc xây dựng quy trình đánh giá khách quan và hạn chế tối đa các nguồn gây sai lệch kết quả.

Bên cạnh các kiến thức chuyên môn, đề tài còn giúp em rèn luyện tính kiên nhẫn và tư duy nghiên cứu. Nhiều ý tưởng ban đầu không mang lại hiệu quả như kỳ vọng, thậm chí làm kết quả mô hình giảm xuống. Tuy nhiên, chính quá trình thử nghiệm, phân tích nguyên nhân và tiếp tục điều chỉnh đã giúp em hiểu rõ hơn về dữ liệu cũng như cách thức hoạt động của mô hình. Em nhận ra rằng phát triển một hệ thống dự báo là

một quá trình liên tục gồm nhiều vòng quan sát, giả thuyết, thử nghiệm và đánh giá, thay vì chỉ là một công việc mang tính kỹ thuật thuần túy.

Nhìn chung, kinh nghiệm giá trị nhất mà em thu được từ đề tài là khả năng tiếp cận một bài toán thực tế theo hướng dựa trên dữ liệu. Thay vì tìm kiếm một lời giải có sẵn, em học được cách phân tích vấn đề, đặt câu hỏi, kiểm chứng giả thuyết và đưa ra quyết định dựa trên bằng chứng thu được từ dữ liệu và kết quả thực nghiệm. Đây là những kinh nghiệm có ý nghĩa lâu dài đối với quá trình học tập và định hướng nghề nghiệp sau này của em.

CHƯƠNG 6: ĐỊNH HƯỚNG NGHỀ NGHIỆP CÁ NHÂN

Thông qua quá trình thực hiện đề tài, em có cơ hội tiếp cận tương đối đầy đủ với quy trình phát triển một dự án phân tích dữ liệu thực tế, từ giai đoạn tìm hiểu bài toán, xử lý và khám phá dữ liệu, xây dựng đặc trưng, huấn luyện mô hình đến đánh giá và giải thích kết quả dự báo. Những trải nghiệm này không chỉ giúp em củng cố các kiến thức đã học trên giảng đường mà còn cho em cái nhìn thực tế hơn về cách các phương pháp phân tích và học máy được áp dụng để giải quyết một bài toán cụ thể.

Trước khi thực hiện đề tài, em chưa có một định hướng nghề nghiệp thật sự rõ ràng. Tuy nhiên, quá trình nghiên cứu và phát triển mô hình đã giúp em nhận ra bản thân khá hứng thú với những công việc đòi hỏi tư duy phân tích, khả năng tìm kiếm nguyên nhân của vấn đề và đưa ra quyết định dựa trên các bằng chứng định lượng. Việc liên tục đặt câu hỏi, kiểm chứng giả thuyết, đánh giá kết quả và cải thiện mô hình cũng giúp em hiểu rõ hơn về những yêu cầu và đặc thù của các vị trí liên quan đến phân tích dữ liệu. Vì vậy, Data Analyst hiện là một trong những hướng nghề nghiệp mà em cân nhắc theo đuổi trong giai đoạn đầu sau khi tốt nghiệp, dựa trên những trải nghiệm và nền tảng mà em đã tích lũy được thông qua quá trình thực hiện các đồ án môn học.

Bên cạnh đó, trong thời gian gần đây em cũng bắt đầu quan tâm đến lĩnh vực Product Management, đặc biệt là vai trò Product Owner. Đây không phải là hướng phát triển trực tiếp từ đề tài này mà xuất phát từ sự tò mò và hứng thú cá nhân đối với quá trình xây dựng và phát triển sản phẩm công nghệ. Em mong muốn tìm hiểu sâu hơn về cách một ý tưởng được hình thành, chuyển hóa thành sản phẩm thực tế và tạo ra giá trị cho người dùng. Mặc dù hiện tại em chưa có nhiều trải nghiệm trong lĩnh vực này, em vẫn mong muốn từng bước trang bị thêm các kiến thức về tư duy sản phẩm, nghiên cứu người dùng, quản lý yêu cầu và phối hợp giữa các bên liên quan để có cái nhìn toàn diện hơn về công việc của một Product Owner.

Trong thời gian tới, em dự định tiếp tục hoàn thiện nền tảng chuyên môn về phân tích dữ liệu, đồng thời chủ động tìm hiểu thêm về lĩnh vực quản lý sản phẩm. Việc tiếp cận và trải nghiệm cả hai hướng đi sẽ giúp em có thêm cơ hội khám phá điểm mạnh của bản thân, mở rộng góc nhìn nghề nghiệp và đưa ra lựa chọn phù hợp hơn cho chặng đường phát triển sau này. Dù lựa chọn lĩnh vực nào, em cũng mong muốn duy trì tinh

thần học hỏi, không ngừng nâng cao năng lực chuyên môn và đóng góp những giá trị thiết thực thông qua công việc mình theo đuổi.

TÀI LIỆU THAM KHẢO

- Adetunji, A. B., Akande, O. N., Ajala, F. A., Oyewo, O., Akande, Y. F., & Oluwadara, G. (2022). House Price Prediction using Random Forest Machine Learning Technique. *Procedia Computer Science*, The 8th International Conference on Information Technology and Quantitative Management (ITQM 2020 & 2021), 199, 806-813. <https://doi.org/10.1016/j.procs.2022.01.100>
- Antipov, E., & Pokryshevskaya, E. (2010). Mass appraisal of residential apartments: An application of Random forest for valuation and a CART-based approach for model diagnostics. *MPRA Paper*, *MPRA Paper*, Article 27645. <https://ideas.repec.org/p/pra/mprapa/27645.html>
- Belcher, R. N., Suen, E., Menz, S., & Schroepfer, T. (2019). Shared landscapes increase condominium unit selling price in a high-density city. *Landscape and Urban Planning*, 192, 103644. <https://doi.org/10.1016/j.landurbplan.2019.103644>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Columbia University Mailman School of Public Health. (2022, October 3). Missing data and multiple imputation. <https://www.publichealth.columbia.edu/research/population-health-methods/missing-data-and-multiple-imputation>
- European Commission. (2008). *Recommended practices for editing and imputation in cross-sectional business surveys*. Eurostat. <https://ec.europa.eu/eurostat/documents/64157/4374310/30-Recommended+Practices-for-editing-and-imputation-in-cross-sectional-business-surveys-2008.pdf>
- Fan, G.-Z., Ong, S. E., & Koh, H. C. (2006). Determinants of House Price: A Decision Tree Approach. *Urban Studies*, 43(12), 2301–2315.
- Fik, T., Ling, D., & Mulligan, G. (2003). Modeling Spatial Variation in Housing Prices: A Variable Interaction Approach. *Real Estate Economics*, 31, 623–646. <https://doi.org/10.1046/j.1080-8620.2003.00079.x>

- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Gulati, J. (2025, October 6). *How to choose between mean, median, or mode for imputation*. Statology. <https://www.statology.org/how-to-choose-between-mean-median-or-mode-for-imputation/>
- Ha, M. T., Nguyen, T. C., Pham, T. H., & Nguyen, V. H. (2025). Using Machine Learning Regression Algorithms to Predict House Prices in Vietnam. *International Real Estate Review*, 28(4), 505-527. <https://doi.org/10.53383/100412>
- Hajiyianni, N., & Stylianou, V. (2024). Automated valuation models for residential real estate: A systematic review. *Journal of Property Research*, 41(2), 112-138.
- Hayat, A., & Hasan, M. R. (2024). *A context-aware approach for enhancing data imputation with pre-trained language models*. University of Nebraska-Lincoln. <https://aclanthology.org/2025.coling-main.380.pdf>
- Heymans, M., & Eekhout, I. (2019). *Missing data mechanisms*. In *Applied missing data analysis with SPSS and R*. <https://bookdown.org/mwheyman/bookmi/missing-data-mechanisms.html>
- Hoang, V.-N., Nguyen, K., Nguyen, M. T., & Blake, A. (2024). Unlocking visual data to enhance the accuracy of AI-enabled mass valuation of urban houses: An Australian city case study. *Expert Systems with Applications*, 255, 124784. <https://doi.org/10.1016/j.eswa.2024.124784>
- Honaker, J., & King, G. (2010). What to do about missing values in time-series cross-section data. *American Journal of Political Science*, 54(2), 561-581. <https://doi.org/10.1111/j.1540-5907.2010.00447.x>
- Hong, J. (2020). An Application of XGBoost, LightGBM, CatBoost Algorithms on House Price Appraisal System. *Housing Finance Research*, 4, 33-64. <https://doi.org/10.52344/hfr.2020.4.0.33>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.

- Li, Z. (2024). GeoShapley: A Game Theory Approach to Measuring Spatial Effects in Machine Learning Models. *Annals of the American Association of Geographers*, 114(7), 1365–1385.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774. <https://doi.org/10.48550/arXiv.1705.07874>
- Lundberg, S. M., Erion, G. G., & Lee, S.-I. (2018). Consistent individualized feature attribution for tree ensembles. *arXiv preprint arXiv:1802.03888*. <https://doi.org/10.48550/arXiv.1802.03888>
- Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. *ACM SIGKDD Explorations Newsletter*, 3(1), 27–32. <https://doi.org/10.1145/507533.507538>
- Molnar, C. (2022). *Interpretable machine learning: A guide for making black box models explainable* (2nd ed.). <https://christophm.github.io/interpretable-ml-book/>
- Naz, R., Jamil, B., & Ijaz, H. (2024). Real Estate Price Prediction. *International Journal of Innovations in Science & Technology*, 6(3), 1031-1044.
- Newsom, J. (2015). *Missing data and missing data estimation*. Portland State University. https://web.pdx.edu/~newsomj/cdaclass/ho_missing.pdf
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2025). *SimpleImputer*. Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.SimpleImputer.html>
- Pongprasert, P. (2022). Determinants of Luxurious Condominium Prices in Bangkok CBD: A Case study of Encouraging Housing Affordability in Bangkok, Thailand. *International Review for Spatial Planning and Sustainable Development*, 10, 167-182. https://doi.org/10.14246/irspsd.10.1_167
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638-6648.

- Rojas, A. (2024). Train stations' impact on housing prices: Direct and indirect effects. *Transportation Research Part A: Policy and Practice*, 181, 103979. <https://doi.org/10.1016/j.tra.2024.103979>
- Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the theory of games* (Vol. 2, pp. 307-317). Princeton University Press. <https://doi.org/10.1515/9781400881970-018>
- Tran, H.-L., Thi, T.-L. T., Tran, T.-V., Thi, D.-H. D., & Nguyen, T.-H. (2024). A Study on the Prediction of Apartment Prices using the GBRT model: A Case Study in Vinh City, Vietnam. *Engineering, Technology & Applied Science Research*, 14(3), 14546-14551. <https://doi.org/10.48084/etasr.7395>
- Truong, Q., Nguyen, M., Dang, H., & Mei, B. (2020). Housing Price Prediction via Improved Machine Learning Techniques. *Procedia Computer Science*, 174, 433-442. <https://doi.org/10.1016/j.procs.2020.06.111>
- Yamannage, S. (2024). *Comparative Analysis of Machine Learning Algorithms for Predicting House Prices*. <https://doi.org/10.21203/rs.3.rs-4019947/v1>